

THÈSE DE DOCTORAT
DE L'UNIVERSITÉ PSL

Contrôle optimal d'une station d'énergie autonome par optimisation robuste

Soutenue par
Arnold N'GORAN

Le 29 mai 2020

Ecole doctorale n° XXX
**Sciences et Technologies
de l'Information
et de la Communication**

Spécialité
**Contrôle, Optimisation,
Prospective**

Composition du jury :

Nadia MAÏZI	<i>Président</i>
Professeure d'Université, MINES ParisTech	
Ammar OULAMARA	<i>Rapporteur</i>
Professeur d'Université, Université de Lorraine	
Tuan TRAN-QUOC	<i>Rapporteur</i>
Professeur d'Université, Université Paris Saclay	
Sophie DEMASSEY	<i>Directrice de thèse</i>
Maître de Conférences, MINES ParisTech	

Résumé

Les besoins croissants en énergie, l'épuisement éventuel des ressources fossiles, et l'ambition de protéger l'environnement, ont motivé le développement des sources es prévisions de production renouvelable sont imparfaites. 1

Dans le contexte des micro-réseaux, de nombreuses stratégies de contrôle ont été développées, basées sur des choix différents dans la représentation du système physique et de sa dynamique, dans l'intégration des données prévisionnelles, ou encore dans l'algorithme d'optimisation. Les stratégies les plus sophistiquées sont les moins répandues en pratique, et leur plus-value est mal connue faute d'études comparatives variées, difficilement concevables sur des systèmes réels.

Cette thèse veut apporter un éclairage sur la performance pratique des stratégies de contrôle, avec la mise en œuvre de différentes méthodes d'optimisation en association avec un contrôleur temps-réel, au sein d'une plate-forme unique de simulation, sur des données d'instances réelles de micro-réseaux off- ou on-grid. 2

Nos expérimentations montrent un intérêt significatif à considérer avec précision la variabilité de la production à l'échelle de la journée, par des approches d'ordonnancement, et mettent en avant la capacité de la boucle de contrôle à absorber les défauts de modélisation de la dynamique du système, qui sont inhérentes à ces approches. Nous observons alors la supériorité d'une approche de programmation mathématique basée sur un modèle analytique fortement simplifié pour accélérer la résolution à l'optimum, comparée à une approche metaheuristique associée à un modèle numérique de simulation précis, mais sans garantie d'optimalité.

Cette thèse se focalise par ailleurs sur le modèle d'une station d'énergie photovoltaïque avec stockage, connectée à un réseau insulaire, et pilotée de manière indépendante à travers la notion d'*engagement*. Dans le contexte des appels d'offres de la Commission Française de Régulation de l'Énergie pour les zones non interconnectées, le producteur indépendant s'engage auprès du gestionnaire de réseau sur sa capacité d'injection, la veille pour le lendemain, et est enjoint de payer des pénalités pour les écarts à l'*engagement* observés le jour même. Dans ce contexte, la minimisation des pénalités s'ajoute à l'objectif de profit du problème de contrôle temps réel, et un nouveau problème de décision apparaît en amont, au niveau tactique, pour le calcul de l'*engagement* optimal. Nous proposons d'étendre les différentes méthodes de contrôle au calcul de l'*engagement* pour les comparer, et observons de nouveau, de manière empirique, un avantage de l'approche de programmation mathématique, à la fois en matière de profit et de temps de calcul. 3

Enfin, nous examinons dans cette thèse l'impact de la prise en compte des incertitudes des données prévisionnelles de production solaire. Comme pour les erreurs de modélisation, ces incertitudes peuvent être en partie compensées par un recalcul fréquent au sein de la boucle de contrôle. En revanche, les incertitudes étant plus fortes au moment du calcul d'*engagement*, les erreurs dans la décision d'*engagement* peuvent être la source de pénalités importantes.

L'approche de programmation mathématique se prête à l'intégration des incertitudes

par optimisation stochastique ou robuste. Nous avons ainsi réalisé deux extensions du modèle déterministe de calcul d'engagement, dans le but de les comparer : un modèle stochastique après génération et simulation de scénarios de production solaire, et une approche d'optimisation robuste par programmation bi-niveaux, avec génération progressive de coupes de Benders. L'évaluation expérimentale permet de constater l'importance de prendre en compte les incertitudes au niveau du calcul d'engagement, et une légère supériorité de l'approche robuste en matière de profit.

Abstract

Growing energy needs, the possible depletion of fossil resources, and the ambition 5 to protect the environment have motivated the development of renewable energy sources, particularly solar and wind power, in power generation systems. The intermittency of these sources makes it more complex to control power grids, which are based on the production-demand balance at all times. Storage systems, such as batteries, make it possible to compensate for this variability, but they require control to be considered over a longer future time horizon, which is difficult to reconcile with the short-term dynamics of the system, and over which renewable production forecasts are imperfect.

In the context of micro-grids, many control strategies have been developed, based on different choices in the representation of the physical system and its dynamics, in the integration of the forecast data, or in the optimization algorithm. The most sophisticated strategies are the least widespread in practice, and their added value is poorly known due to the lack of various comparative studies, which are difficult to conceive on real systems.

This thesis aims to shed light on the practical performance of control strategies, 6 with the implementation of different optimization methods in association with a real-time controller, within a single simulation platform, on data from real instances of off- or on-grid micro-grids.

Our experiments show a significant interest in accurately considering the variability of production on a daily scale, through scheduling approaches, and highlight the ability of the predictive control loop to absorb the system dynamics modeling flaws, which are inherent to these approaches. We then observe the superiority of a mathematical scheduling approach based on a highly simplified analytical model to accelerate the resolution to the optimum, compared to a metaheuristic approach associated with a precise numerical simulation model, but without any guarantee of optimality.

This thesis also focuses on the model of a grid-connected photovoltaic-based 7 micro-grid with storage, and independently driven through the notion of *engagement*. In the context of calls for tenders by the French Energy Regulatory Commission for non-interconnected areas, the independent producer commits to the grid operator on its production capacity in a day-ahead fashion, and is required to pay penalties for deviations from the commitment observed the next day. In this context, the minimisation of penalties is added to the profit objective of the real-time control problem, and a new decision problem appears upstream, at the tactical level, for the calculation of the optimal engagement. We propose to extend the different control methods to the calculation of the engagement for comparison purposes, and we observe again, empirically, an advantage of the mathematical programming approach, both in terms of profit and runtime.

Finally, we examine in this thesis the impact of taking into account the uncertainties 8 in the solar production forecast. As for modeling errors, these uncertainties

can be partly compensated by frequent recalculation within the control loop. On the other hand, the uncertainties being higher at the time of the engagement calculation, errors in the engagement decision can be the source of significant penalties. The mathematical programming approach lends itself to the integration of uncertainties through stochastic or robust optimization. Two extensions of the deterministic engagement calculation model have been realized for comparison purposes: a stochastic model after generation and simulation of solar production scenarios, and a robust optimization approach by bi-level programming, with progressive generation of Bender cuts. The experimental evaluation shows the importance of taking into account uncertainties in the engagement calculation, and a slight superiority of the robust approach in terms of profit.

Remerciements

Tout au long de mes études, j'ai reçu le soutien, les conseils, les encouragements, et la protection de nombre de personnes. Et je m'en voudrais de ne pas mentionner quelques-unes de ces généreuses personnes, sans le concours desquelles mon parcours aurait été bien difficile.

Je pense notamment à :

- mes maîtres et l'administration du Collège Kacou Joseph (KJ) d'Abengourou, Côte d'Ivoire (2002-2005) ; mes maîtres et l'administration du Lycée Technique d'Abidjan-Cocody (LTA), Côte d'Ivoire (2005-2008) ;
- mes maîtres et la direction de l'Institut National Polytechnique Félix HOUPHOUËT-BOIGNY (INP-HB) de Yamoussoukro, Côte d'Ivoire (2008-2013). Mentions spéciales aux professeurs Alphonse DIANGO, Mohamed SAKO, Patrice MEN-SAH, Paul EKOUN, Moustapha SANGARÉ, DGA de l'INP-HB, et à Dr Koffi N'GUESSAN, DG de l'INP-HB ;
- ma directrice de thèse, Sophie DEMASSEY, maître de conférences au Centre de Mathématiques Appliquées (CMA) de l'École Nationale Supérieure des Mines de Paris, devenue MINES ParisTech (2017-2020). C'est elle qui m'a fait docteur en mathématiques appliquées et spécialiste en Recherche Opérationnelle. J'associe à cet hommage mes collègues, mais aussi et surtout mes encadreurs, les professeurs Nadia MAÏZI, directrice du CMA, et Gilles GUE-RASSIMOFF ;
- M. Sébastien THIRY, responsable de la Business Unit "Smart Energy" chez Bertin Technologies, France. C'est grâce à lui que j'ai intégré Bertin Technologies, d'abord comme stagiaire, puis comme doctorant-ingénieur. J'associe à cet hommage, sa compagne dont le soutien ne m'a jamais fait défaut. Tous deux ont largement contribué à rendre mon séjour en France plus qu'agréable ;
- mes collègues et la direction du département Bertin Énergie et Environnement de Bertin Technologies ;
- Mme Sophie TANOH, cheffe de service à l'UNACOOPEC ;
- mon oncle Roland AVI, cadre supérieur à la Compagnie Ivoirienne d'Électricité (CIE). C'est sur sa recommandation que je suis devenu ingénieur de conception en génie énergétique ;
- l'Honorable Hubert Boko EHOUMAN, ex-député et ex-président du Conseil Régional de l'Indené-Djuablin, Côte d'Ivoire ;
- mes parents, le pasteur Germain-Lazare OULAÏ et son épouse ;
- ma grande sœur Sylvie AÏKO épouse DHOORE ;

- maman Joséphine BOKO épouse AÏKO, sage-femme et spécialiste en ORL ;
- M. Firmin ANGAMAND, spécialiste en sciences de l'éducation, et son épouse ;
- M. le juge Jérôme ALLOU, ex-fonctionnaire international ;
- Dr Ernest ADIÉKÉ, pharmacien ;
- M. Célestin DJAYA, cadre à l'UNACOOPEC-CI ;
- mon tuteur Roland-Armel APPINI, doctorant à l'INP-HB, et son épouse. C'est sur sa recommandation également que je suis devenu ingénieur de conception en génie énergétique ;
- feu M. Paul Atisso KOFFI, directeur de MONDIAL TAMPONS SERVICES ;
- M. Hamidou TRAORÉ, directeur des services socio-culturels à la Mairie de Fronan ;
- M. le sous-préfet Soiliho GRAMBOUTÉ ;
- M. Gabrel Esso N'GORAN, inspecteur principal d'Orientation. Aux côtés de mon père, il a contribué à opérer les meilleurs choix pendant mon parcours académique.

Je vous remercie infiniment !

À

Ma mère Marie Ahou KRA.
Elle m'a comblé d'amour et de tendresse. Mais, ironie du sort, elle a été rappelée à Dieu à seulement 28 jours de la défense de cette thèse. Telle une symphonie inachevée.

Ma belle-mère Marie-Claire M'BADAMAN épouse N'GORAN.
Je suis entre ses mains depuis l'âge de 10 ans, et elle ne m'a fait que du bien !

Mon père, l'artiste et autodidacte Adrien N'GORAN.
Il est mon mentor, mon modèle, mon inspirateur. Il m'a légué son génie, sa passion du travail et son obsession de l'esthétique. Il m'a toujours poussé à repousser mes limites. Il est, à la fois, le principal architecte et maître d'œuvre de mon parcours.
Pour tout dire, c'est pour lui et à cause de lui que j'ai fait cette thèse.

Préface

*Ce qui a été, c'est ce qui sera;
ce qui s'est fait, c'est ce qui se fera,
et il n'y a rien de nouveau sous le soleil.*

*Y a-t-il une chose dont on puisse dire: Vois ceci, c'est nouveau ?
Elle a déjà été dans les siècles qui furent avant nous.*

Ecclésiaste 1:9-10.

Au commencement était l'homme « primitif ». Il vivait de manière rustique car il avait des besoins primitifs. Avec le temps, il apprit à mieux connaître son environnement et à le contrôler. Ses besoins s'accrurent proportionnellement. Un des éléments qu'il apprit à bien contrôler est l'énergie. Il se rendit compte de tous les services que l'énergie pouvaient lui rendre. Dans son étude de l'énergie, il découvrit qu'elle pouvait prendre plusieurs formes et qu'on pouvait passer d'une vers l'autre (et vice-versa) en utilisant des techniques précises. Il fit donc une classification de quelques-unes de ces formes d'énergie et établit la liste des transformations possibles. Les techniques de transformation vont de la trivial à la très complexe. Toutes ont été utiles à une certaine période mais ont été soit abandonnées, lorsqu'elles s'avéraient nocives ou inefficientes, soit améliorées à d'autres périodes, à mesure que l'homme connaissait mieux son environnement. 9

Aujourd'hui, il est devenu un homme « avancé » (ou « évolué »), du moins il se qualifie comme tel. Il a tellement développé des technologies, toutes lui paraissant utiles et toutes consommatrices d'énergie, qu'il est à un stade où ses besoins énergétiques surpassent de loin ses capacités à produire *sainement* de l'énergie *utile*. Dans le jargon énergétique, on qualifie d'énergie utile, la forme d'énergie qu'on peut directement utilisée ou consommée dans un contexte précis. C'est donc une qualification relative. L'énergie utile est obtenue par transformation d'une autre forme d'énergie, appelée énergie *primaire*. 10

Les deux formes d'énergie utile dont l'homme fait plus usage sont : l'énergie calorifique (chaud et froid) et l'énergie électrique. Pour obtenir ces énergies, il se servit d'abord de certaines formes d'énergie qu'on qualifie de *fossile*. Ce sont des énergies (par exemple: le pétrole, le gaz naturel, le charbon) issues de la matière géologique. Cette matière étant relativement brute, son nombre est facilement quantifiable et après analyse, l'homme a conclu que la durée de régénération de cette matière, après consommation, est supérieure à sa (lui) durée de vie. Il comprit aussi, après exploitation de ce type d'énergie, que les procédés de transformation n'étaient pas respectueux de l'environnement. Mais, il n'y a pas que les procédés, il y a aussi la surexploitation. En effet, pour assouvir ses besoins énergétiques, l'homme va dans les tréfonds de la Terre pour extraire de l'énergie primaire. Ce faisant, il retire de la matière à la Terre. Sur le coup, il ne s'interroge pas sur les conséquences d'un tel acte sur la santé de sa planète, car pour lui, elle n'a pas de vie. C'est un peu comme si pour répondre à leurs besoins quelconques, les cellules du corps humain puisaient des ressources des reins, du foie, ou de tout autre organe vital de leur planète mère, qui est l'homme. Évidemment, on comprend aisément qu'un tel acte serait fatal. 11

pour l'homme. Mais, on n'est pas capable de faire l'analogie pour le cas de la Terre. Poursuivons notre analogie. Les cellules du corps humain se nourrissent de l'air que l'homme respire et des aliments qu'il ingère, et ces ressources vitales sont normalement infinies. De même, la Terre met à la disposition de l'homme des ressources qui lui permettent de vivre et d'avoir un environnement paisible afin qu'elle aussi (la Terre) évolue sainement. Il revient à l'homme (cellule de la Terre) de découvrir ces ressources et il est vrai que ce n'est pas une tâche aisée. L'homme procède donc par tâtonnements, blessant ainsi sa planète et lui-même.

12 Aussi, remarquant que son besoin en énergie va en croissant, que les ressources fossiles tendent à s'épuiser et surtout désireux de protéger l'environnement, l'homme se mit à chercher d'autres formes d'énergie primaire, plus durables et respectueuses de l'environnement. Évidemment, il en découvrit et les nomma *énergies nouvelles et renouvelables*. Cette dénomination parle d'elle-même. On peut citer parmi ces énergies, l'énergie solaire thermique/photovoltaïque, l'énergie éolienne, la géothermie, la biomasse, l'énergie houlomotrice, etc. Il remarqua qu'elles sont pratiquement inépuisables à l'échelle d'une vie humaine et moins nocives pour l'environnement.

13 Le dernier cinquantenaire a connu un développement croissant des technologies permettant de transformer ces sources d'énergie en chaleur et/ou électricité : cellules photovoltaïques, turbines éoliennes, réacteurs à biocarburants, etc. Ces technologies n'ont pas la même compétitivité, entre elles, en terme de rendement et elles sont généralement moins efficientes que les technologies conventionnelles de transformation des énergies fossiles en énergie utile. Toutefois, elles constituent une bonne alternative aux énergies fossiles dans le contexte de développement durable.

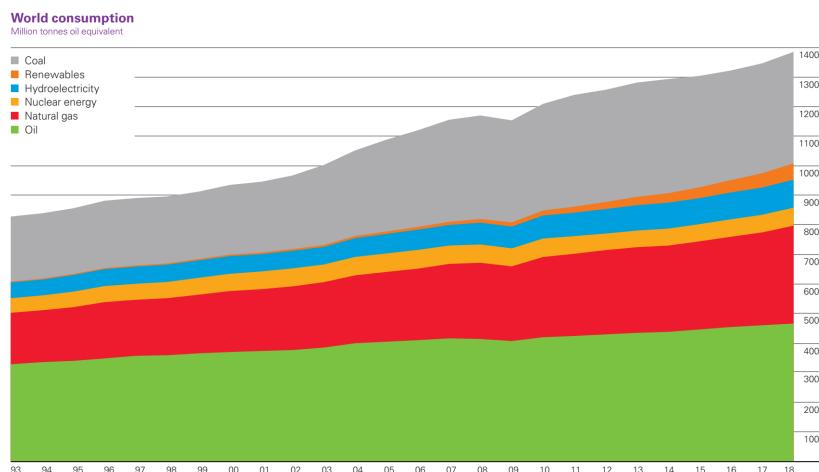


FIGURE 1: Consommation mondiale par énergie primaire de 1993 à 2018 (source: BP Statistical Review of World Energy 2019)

14 Même si cette thèse, portant principalement sur des aspects techniques et technologiques, n'a pas vocation à résoudre le problème énergétique global, il convient ici de donner notre avis sur la situation actuelle de l'homme et sur quelques voies de résolution de ladite crise énergétique. Comme nous l'avons déjà dit, l'homme avancé s'est créé des besoins, non tous justifiés, et puisque pour les assouvir, il utilise l'énergie, il s'est retrouvé dans une situation où son besoin en énergie défie sa capacité à en produire. Selon le rapport de British Petroleum (édition 2019), la consommation

d'énergie primaire mondiale a connu, en 2018, son plus grand taux de croissance (+2.9%), depuis l'année 2010 [Petroleum 2019]. La figure 1 montre l'évolution de cette consommation, par type d'énergie, depuis l'année 1993. Aucun commentaire supplémentaire n'est nécessaire.

On tente tant bien que mal à toujours satisfaire nos besoins croissants: cela nécessite donc d'augmenter proportionnellement nos capacités de production. Une autre manière de résoudre le problème est tout simplement de réduire notre consommation. Cela ne se fait pas sans changer notre comportement. Mais oui ! l'homme avancé est bien trop avancé, dans sa marche évolutive, pour vouloir reculer. Ce serait une digue à son évolution (croissante ou décroissante ?). Il qualifie de commodité, tout ce qui lui plaît, même si c'est superflu. Mais tout ceci est assez subjectif donc ne nous aventurons pas dans ce dédale. Il suffit de dire, sans non plus faire un exposé de science comportementale, qu'on peut, chacun, réduire notre besoin en énergie, en vivant d'après nature (et non contre elle). Le soleil se lève à un certain moment de la journée et se couche à un autre moment. Il le fait chaque jour de façon méticuleuse et sans jamais faillir. Raison pour laquelle, on parle de cycle. D'un certain point de vue, on peut dire que le soleil a des moments précis de repos et d'activité. Et il en est ainsi pour la plupart des autres êtres vivants, excepté l'homme (avancé) qui est en activité, agité, quasiment tout le temps. Il est *restless*, comme le disent les anglo-saxons. Cette attitude est en accord avec le monde qu'il s'est créé. Il est avancé mais agité ! N'est-ce pas paradoxal ? Eh bien ! si l'homme observait méticuleusement des périodes de repos, il réduirait considérablement sa consommation d'énergie. Oui ! vous m'objecterez que l'homme dort la nuit et se lève le matin, ce qui constitue sa période de repos. Mais voyons ça de plus près. Quand le soleil se couche et que l'environnement est pratiquement sombre, l'homme a besoin de lumière (donc d'électricité) pendant une bonne partie de la nuit car il a des choses à faire avant d'aller coucher. On ne parle que rarement de « pointe de la matinée » mais plus souvent de « pointe du soir », car même après avoir longuement travaillé dans la journée, l'homme reste actif pendant le soir. Même si on s'assoit juste devant sa télé, sans fournir un quelconque effort physique, on est en activité. L'activité mentale transcende l'activité physique. Et on a besoin d'électricité pendant cette période où on devrait être inactif. D'autre part, quand bien même l'homme serait en train de dormir, ses machines sont en constante activité. En fait, il s'est dédoublé pour rester constamment en activité. Alors, si les serveurs et machines qui fonctionnent 24h/24 étaient tous arrêtés les soirs, on réduirait grandement notre demande énergétique et l'homme aurait même une meilleure santé. Mais, ce n'est pas demain la veille. On ne change pas des habitudes, qu'on a longtemps forgé, en un clin d'œil et notre système économique global et individuel prendrait un coup si on faisait ce genre de transition aujourd'hui. Toutefois, c'est ce genre de transition qu'il faut réellement. Sinon parler de transition énergétique (passage des énergies fossiles aux énergies renouvelables) n'est qu'une vaine tentative de gagner du temps. Ce type de transition ne fait que déplacer le problème.

Bien que le paradigme de gestion de la demande ou de la charge (*demand-side management*), tente de résoudre le problème de réduction de consommation côté client, nous sommes encore loin du compte car il atteint ses limites lorsque l'homme commence à se sentir contraint, par des sources externes, de réduire sa

consommation. Par ailleurs, les technologies actuelles de production d'énergie à partir des ressources renouvelables ne sont pas suffisamment viables pour remplacer entièrement les technologies traditionnelles. Par exemple, le rendement des modules photovoltaïques est trop faible comparé à celui d'une turbine hydraulique ou à gaz et, à puissance utile égale, un champ photovoltaïque occupe nettement plus de surface qu'un système à turbine à gaz. Car même si une turbine à gaz est plus bruyante qu'un panneau solaire, elle est généralement isolée de la population. Ce qui n'est pas le cas des panneaux solaires qui, eux, peuvent être installés presque partout. « presque » car pour être efficient et vivre longtemps, un module photovoltaïque doit être bien exposé aux rayons du soleil. Il ne doit donc pas être couvert d'ombre, ce qui montre bien qu'il pose des problèmes environnementaux. Bien-sûr, ces problèmes environnementaux ne sont pas du même degré que ceux causés par les turbines à gaz, mais ils n'en sont pas moins des problèmes environnementaux. Ces technologies nouvelles doivent donc être améliorées ou remplacées par d'autres plus efficientes.

17 Une avancée encourageante est le passage des réseaux électriques traditionnels aux réseaux électriques modernes, dits intelligents ou *smart-grids* (anglicisme). Le concept de microgrid est vraiment apparu avec le concept de smart-grids. Essentiellement, un smart-grid est un réseau électrique qui est capable de supporter la connexion et déconnexion de micro-réseaux (ou microgrids), de façon efficiente en coût financier et en effort d'ingénierie. Ces réseaux sont donc modulaires, ce qui permet d'installer des microgrids partout, pourvu qu'il y ait une borne de connexion/déconnexion. Un avantage plus abstrait est que tout peut être microgrid. Par exemple, tout ménage peut être un microgrid, c'est-à-dire être capable de produire sa propre énergie. Ce paradigme est déjà en place dans certains pays développés, où le producteur indépendant (le ménage, par exemple) est même autorisé à injecter son excédent d'énergie sur le réseau principal. Et il reçoit une rémunération en contrepartie. C'est vraiment vers cet idéal qu'on doit tendre: donner à tout un chacun la capacité de produire sa propre énergie. Ceci rentre dans le concept de décentralisation, quoique celle-ci soit vraiment profonde. Cependant, en raison de la cherté des microgrids et de leur grand volume (comme évoqué au précédent paragraphe), ce paradigme ne peut actuellement être déployé à grande échelle.

18 Avant de fermer cette parenthèse philosophique sur le problème énergétique global, il convient de faire une précision. Le lecteur de cette préface qui se serait arrêté, dans sa lecture, avant le paragraphe 16, croirait que je suis un « écolo ». Celui qui aura, en plus, lu le paragraphe 16, se trouvera confus quant à ma position. Cette tendance à catégoriser est normale chez l'homme. Je précise donc que je ne suis ni « écolo » ni « climatosceptique ». Je mets d'ailleurs ces deux termes en guillemets car, pour moi, ils n'ont d'existence que dans l'esprit de certains. Je ne suis pas « écolo » car ceux qui s'attribuent ce titre ne savent même pas ce que c'est que la nature. Ils prétendent protéger la nature alors qu'ils n'ont même pas égard à leur propre bien-être, même pas à leur hygiène. Ils prétendent protéger la nature en s'affligeant devant la consommation des animaux, alors qu'ils consomment des plantes et qu'ils n'ont aucun respect pour l'homme. Ils prétendent protéger la planète et la race humaine future en détruisant la génération actuelle. Car ils prétendent que l'homme actuel, qui est pourtant l'homme évolué, a causé le réchauffement de la planète, entraînant ainsi sa destruction imminente. Je ne suis pas de ce lot car, pour

moi, tout est nature et que de même qu'il y a des saisons (ou cycles) dont les durées sont inférieures à la durée d'une vie humaine, il peut y avoir des saisons dont les durées sont nettement plus grandes que la durée d'une vie humaine. C'est un raisonnement analogique qui ne nécessite aucune démonstration. Suivant ce raisonnement, le réchauffement est un cycle dont la durée est tellement supérieure à la durée d'une vie humaine que nous sommes incapables de l'appréhender. Cela fait-il de moi un « climatosceptique » ? Je dis « non », car je sais que l'homme a une part de responsabilité dans cette dégénérescence de la planète. Mais cela est conforme à un autre cycle qui n'est pas appréhendé.

Introduction

Énergies conventionnelles et renouvelables

Le besoin croissant en énergie, l'épuisement éventuel des ressources fossiles et la volonté de protéger l'environnement, ont motivé ingénieurs et chercheurs à considérer de nouvelles sources d'énergie, plus durables et respectueuses de l'environnement : les énergies renouvelables que sont notamment l'énergie solaire thermique/photovoltaïque, l'énergie éolienne, la géothermie, la biomasse, l'énergie houlomotrice. Incidemment toutes ces énergies dérivent de la ressource solaire. 19

Le dernier cinquantenaire a connu un développement croissant des technologies permettant de transformer ces sources d'énergie en chaleur et en électricité : cellules photovoltaïques, turbines éoliennes, réacteurs à biocarburants, etc. Ces différentes technologies offrent des rendements variables, et sont généralement moins efficientes que les technologies conventionnelles de transformation des énergies fossiles en énergie utile. Toutefois, elles constituent une alternative profitable dans le contexte de développement durable. Dans ce qui suit, l'accent est mis sur l'énergie solaire.

Réseaux électriques et microgrids

Un réseau électrique (*grid* ou *power system*, en anglais) peut être défini comme un système de fourniture d'électricité à divers clients. Ce système est composé de 3 couches : la génération ou production, la transmission et la distribution. La génération est faite par des unités de production utilisant des ressources fossiles et/ou renouvelables. Dans les réseaux traditionnels, développés à partir du XX^e siècle, la génération est *centralisée* : le nombre des unités de production et leur répartition spatiale sont limités, et la couche transmission est importante car ces unités sont installées loin des charges. Les réseaux modernes du XXI^e siècle intègrent des générateurs à ressources renouvelables, et la génération devient *distribuée* : des unités de production de capacité plus modeste peuvent maintenant être installées localement, près de charges spécifiques à alimenter. Unités et charges locales forment des (sous-)réseaux électriques, qu'on appelle *microgrids*. Ces sous-réseaux utilisent leurs propres moyens de distribution, et la couche transmission y est accessoire, compte tenu de la proximité de la charge. On appelle *réseau principal*, un réseau connexe qui alimente plusieurs charges réparties sur une région donnée, typiquement à l'échelle d'un pays ou d'un continent. Lorsqu'un microgrid est connecté au réseau principal afin d'échanger de l'électricité avec lui, on dit que c'est un microgrid *connecté réseau* ou *on-grid*. Sinon, lorsqu'il est indépendant du réseau principal, on dit qu'il est *isolé*, *autonome* ou *off-grid*. 20

Dans cette thèse, nous considérons ces deux types de microgrid, mais nous étudions de manière plus poussée les microgrids connectés réseau dans le contexte des 21

Zones Non Interconnectées (ZNI) en France, comme les îles Corse, Guadeloupe, Martinique, la Réunion, entre autres. Cette dénomination vient du fait que les réseaux électriques principaux qui couvrent ces zones ou îles sont isolés : contrairement au réseau métropolitain par exemple, ils ne peuvent être connectés à des réseaux frontaliers. Ils assurent donc leur entière production d'électricité, qui repose actuellement, en grande partie, sur des ressources importées (charbon, pétrole). Dans l'objectif de la France de porter à au moins 23% la part des énergies renouvelables dans son mix énergétique à l'horizon 2020, l'installation d'unités de production indépendantes, notamment de micro-centrales photovoltaïques dans ces îles est encouragée, via un processus d'appel d'offres (AO) lancé annuellement par la Commission de Régulation de l'Énergie (CRE). Les installations sélectionnées voient toute leur production journalière rachetée par l'État, via le gestionnaire de réseau local, à un tarif fixe sur l'année. Ce tarif d'achat de l'électricité, propre à l'installation, est potentiellement mis à jour à chaque date d'anniversaire du contrat d'achat/vente qui lie l'exploitant au gestionnaire de réseau. Un critère essentiel de sélection des candidats de cet appel d'offres (qu'on note AOCREZNI dans la suite) est le caractère innovant du projet. Pour être éligible, le candidat doit proposer des solutions qui innovent dans une des catégories suivantes :

- innovation de composants : il s'agit de l'amélioration de la performance technique et/ou économique et/ou environnementale de tout composant du microgrid ;
- innovation du système de conversion d'énergie solaire et de sa conception ;
- innovation dans l'exploitation et la maintenance du microgrid : il s'agit de l'amélioration des modalités de gestion et d'optimisation des performances de l'installation (y compris de détection et de diagnostic de défauts).

Cette thèse s'inscrit dans ce contexte, et a précisément pour objet de proposer et d'étudier des solutions innovantes relevant de cette dernière catégorie : optimiser le pilotage du microgrid. Du point de vue de l'exploitant, il s'agit d'opérer le microgrid de manière à maximiser le revenu journalier, en minimisant notamment les pénalités financières relatives à l'écart à son engagement de production. Du point de vue du gestionnaire de réseau, cette même optimisation favorise la stabilité du réseau.

Pilotage des réseaux électriques

Piloter ou contrôler un réseau électrique, c'est premièrement assurer que la production électrique corresponde à la consommation (ou *charge*, ou *demande*) à chaque instant. La problématique s'est complexifiée avec l'évolution des réseaux, de leurs composants, de leurs objectifs, et des outils de suivi et de pilotage. Le contrôle des réseaux électriques a ainsi une longue histoire, dont les faits majeurs sont représentés sur la figure 2.

Jusque dans les années 40, le contrôle des réseaux électriques est réalisé manuellement par des opérateurs humains. Le contrôle est purement centralisé, avec un centre de contrôle à partir duquel les consignes sont transmises, par téléphone, aux opérateurs de terrain chargés de les appliquer. Le contrôle est alors limité à

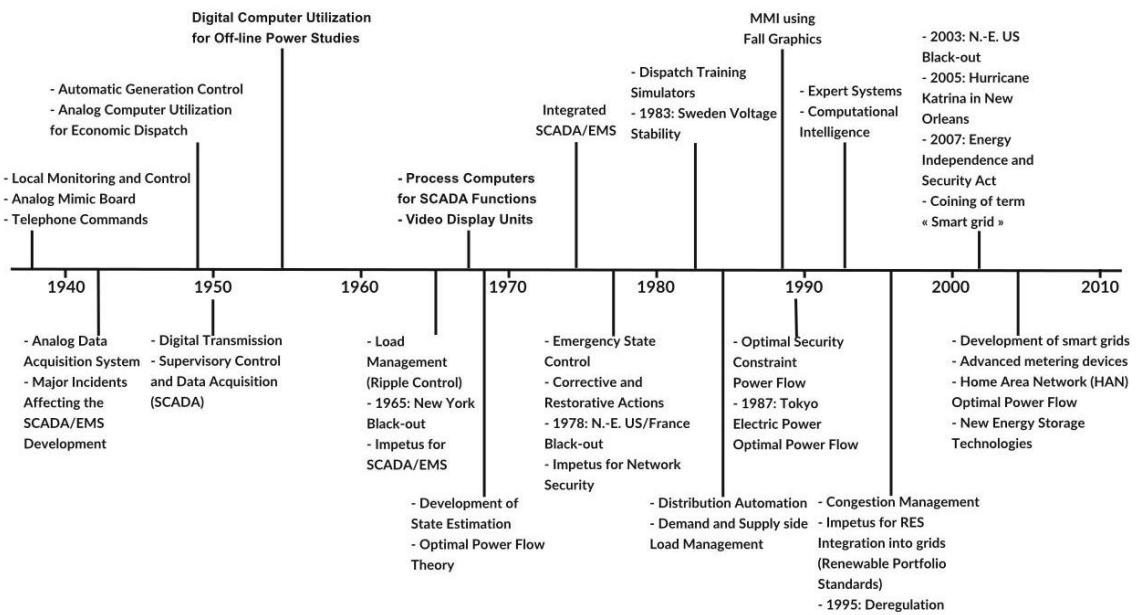


FIGURE 2: Faits majeurs dans l'évolution du contrôle des réseaux électriques. Adaptée de [Handschin 1991].

une unité de régulation. En effet, dans l'ensemble des unités de production, une seule unité est choisie et dédiée à la régulation de la fréquence et au maintien de l'équilibre production-demande. L'ajustement de cette unité se fait manuellement. Les systèmes analogiques d'acquisition de données et le contrôle automatique de la production (*Automatic Generation Control* ou AGC) sont développés, par la suite, pour permettre le contrôle coordonné de plusieurs unités de production. Grâce à ces systèmes, il est possible de dédier plusieurs unités à la régulation. Si l'objectif principal de l'AGC est de préserver l'équilibre génération-demande, ces outils commencent à considérer dans leurs choix de production, des critères préférentiels (limiter les démarrage/arrêt des générateurs, la consommation de carburant, les pertes en ligne, etc.) sujets à différentes contraintes opérationnelles (temps d'arrêt/fonctionnement et temps de réponse des générateurs, rampes de production, disponibilité des ressources renouvelables). Le problème d'optimisation sous-jacent, appelé *Economic Load Dispatch* ou ELD, consiste à déterminer les niveaux de production de chaque unité engagée. Le choix de l'ensemble des unités engagées à chaque instant de l'horizon de production, résulte d'un autre problème d'optimisation, appelé *Unit Commitment* ou UC. Ces problèmes d'optimisation, intégrés ou non et portant sur différents horizons temporels de planification, sont génériquement appelés *problèmes de contrôle optimal* (PCO).

Au début des années 60, les outils et ordinateurs utilisés sont analogiques, et rendent le transport de données délicat. Aussi, des systèmes numériques sont développés pour faciliter la compression, le stockage et le traitement des données. Le black-out survenu aux États-Unis en 1965, conduit à l'introduction d'un système de contrôle et d'acquisition de données (*Supervisory Control and Data Acquisition* ou SCADA) dans la couche transmission. À noter que chaque black-out — notamment ceux de 1978 aux États-Unis et en France, et celui de 2003 aux États-Unis — a conduit à la prise de décisions pour le renforcement des mesures de sécurité et de

fiabilité des réseaux. La fiabilité peut être définie comme la probabilité que le réseau accomplisse ses fonctions sur une certaine durée et sous certaines conditions bien définies. Plusieurs indicateurs permettent de mesurer la fiabilité d'un réseau, tels que la probabilité de perte de charge, la fréquence moyenne de réduction de la charge et la quantité moyenne d'énergie non fournie [Kueck 2004, Medjoudj 2017]. La sécurité du réseau électrique peut être définie comme la probabilité qu'un (ou plusieurs) de ses points de fonctionnement reste dans un état viable [Commission 2019].

La fin des années 60 est marquée par le développement de nouveaux axes de contrôle, notamment la gestion de la charge, l'estimation de l'état du réseau et la théorie du flux de puissance optimal (*Optimal Power Flow* ou OPF). L'ELD détermine la quantité de puissance que doit fournir chaque générateur engagé, sans considérer comment cette puissance doit être acheminée via les réseaux de transmission et de distribution. Le problème simple de flux de puissance (*Power Flow* ou PF) permet de déterminer la quantité de puissance qui doit être acheminée via ces réseaux, à un instant donné. De ce fait, les modèles de PF sont très souvent exprimés en courant-tension-phase, alors que ceux d'ELD sont principalement exprimés en puissance. OPF est la combinaison de ELD et PF.

Les années 70 voient le développement d'un système SCADA/EMS : *Energy Management System* ou *système de gestion d'énergie*. Quelques-unes des tâches assignées au système de gestion d'énergie sont les suivantes [Handschin 1991] :

- surveiller l'état du réseau en utilisant les données analogiques et numériques ;
- interagir avec le réseau de manière préventive ou corrective ;
- réguler la fréquence et la tension ;
- informer le réseau de façon complète et fiable, même en cas de données manquantes ou imprécises ;
- évaluer les risques opérationnels pour l'état présent ou futur du réseau ;
- proposer des actions d'amélioration de la sécurité du réseau ;
- exploiter le réseau de façon économique ;
- utiliser optimalement l'énergie primaire en observant les aspects environnementaux.

L'EMS est donc le garant du bon fonctionnement du réseau. Ses fonctionnalités impliquent la résolution périodique de problèmes d'optimisation, en particulier UC, ELD, OPF.

Vers la fin des années 70, des méthodes de contrôle des états d'urgence sont développées, et des actions correctives et réparatrices sont prises afin d'assurer la fiabilité du réseau. La notion de *stabilité de la tension* sur le réseau est introduite en Suède en 1983. La capacité d'un système à développer des forces réparatrices supérieures ou égales aux forces perturbatrices pour maintenir l'état d'équilibre du réseau — c'dà à restaurer son état d'équilibre lorsqu'il s'en écarte —, est appelée *stabilité*¹. Le début

¹© 2019 Kenneth Eloghene Okedu. Adapté à partir de Introductory Chapter: Power System Stability; publié à l'origine sous la licence CC BY-NC-SA 3.0. Disponible depuis: [10.5772/intechopen.4497](https://www.intechopen.com/4497)

des années 90 voit l'introduction des systèmes dits *experts* et de l'intelligence informatique. Un système expert est un programme informatique qui émule la capacité de prise de décision de l'expert humain [Peter 1998]. Ce programme est une suite de règles **Si condition Alors action** plutôt qu'une suite de procédures. L'intelligence informatique comprend des méthodes, telles que la logique floue, les réseaux de neurones, les algorithmes évolutionnaires et les méthodes probabilistes. Ces dernières s'assimilent aux métaheuristiques, dont nous parlerons par la suite. Ces méthodes d'intelligence artificielle ont été employées pour la protection des réseaux (protection contre les défaillances, diagnostic des événements singuliers, identification et localisation des défauts) [Enns 1994], pour la planification de la maintenance ou de la production, et pour divers types de contrôle (contrôle temps réel, contrôle de la puissance réactive) [Bretthauer 1992, Wong 1993, Ibrahim 2002, Liu 2010].

Le concept de *dérégulation* est introduit vers le milieu des années 90, aux États-Unis. Déréguler, c'est réduire ou supprimer la présence de l'État dans la construction et l'exploitation des réseaux électriques. L'argument principal donné pour l'application de cette réforme est qu'elle conduirait à une plus grande productivité, un meilleur rendement du réseau et une réduction des coûts. Concrètement, la dérégulation a permis d'avoir des réseaux dans lesquels chaque couche peut être gérée par différentes entités (la production par des particuliers, par exemple) distinctes de l'État. Cette réforme aurait notamment facilité l'intégration des sources d'énergie renouvelables (*Renewable Energy Sources* ou RES) dans les réseaux traditionnels, comme demandée par les normes de portefeuille d'énergies renouvelables (*Renewable Portfolio Standards*).

Les années 2000 sont marquées par l'introduction du concept de *smart-grid* aux États-Unis, dans la loi sur l'indépendance énergétique et la sécurité (*Energy Independence and Security Act* ou EISA). Un smart-grid est un réseau électrique qui est capable de supporter la connexion et déconnexion de microgrids, de manière efficace en coût financier et en effort d'ingénierie. Ces réseaux sont donc modulaires, ce qui permet d'installer des microgrids partout, pourvu qu'il y ait une borne de connexion/déconnexion. La spécification d'un smart-grid, et donc sa mise en œuvre, est complexe mais elle devient rapidement une réalité.

L'intégration des énergies renouvelables dans les réseaux traditionnels vient avec son lot de difficultés. En effet, la forte variabilité et imprévisibilité — nous ne sommes pas actuellement en mesure de prédire avec certitude l'ensoleillement pour le jour, voire l'heure à venir — de la plupart de ces ressources, engendre l'instabilité en fréquence et en tension des réseaux. Les microgrids qui intègrent ces ressources doivent développer des EMS indépendants afin de garantir leur contrôle. Ces EMS n'ont pas toutes les fonctionnalités de l'EMS du réseau principal, du fait de leur moindre portée. Cependant, ils doivent intégrer la variabilité non-contrôlable de la production d'origine renouvelable. 22

Le stockage de l'énergie est un moyen pour compenser cette variabilité. Des unités de stockage, telles que des batteries, sont ainsi intégrées aux microgrids pour assurer le stockage temporaire de l'électricité au cours des périodes de surproduction (par rapport à la charge), et sa restitution avec un fort rendement (de 92 à 96% pour les batteries au lithium et de 80 à 90% pour celles au plomb [IRENA 2017]) en périodes de sous-production. Elles servent ainsi à la gestion de l'alimentation de la charge, 23

au support au réseau par répartition du stockage ou nivellation de la charge, ou encore à assurer la qualité de l'alimentation et le stockage de l'énergie de pointe, par exemple dans les applications d'alimentation sans coupure [on Public Affairs 2010]. Les unités de stockage apportent donc de la flexibilité au réseau, mais elles complexifient la problématique du contrôle ; parce que, d'une part, elles ajoutent de nouvelles variables de décision (quand et combien charger/décharger ?), d'autre part, les processus dynamiques physiques qui les régissent sont difficiles à modéliser. En plus, si leur prix a considérablement baissé, à cause du développement rapide de nouvelles technologies, elles demeurent chères [IEA 2019], et leur durée de vie est faible, relativement aux autres composants d'un microgrid. L'optimisation de leur dimensionnement et, par conséquent, l'optimisation de leur contrôle sont donc des enjeux importants.

Optimisation et contrôle

- 24 La notion d'optimisation a ainsi été introduite dans la théorie et la pratique du contrôle, via l'AGC, pour donner naissance à la branche « contrôle optimal ». Comme il existe une grande variété de méthodes et outils mathématiques et informatiques pour l'optimisation des systèmes, différentes approches ont été appliquées au contrôle des réseaux électriques et des microgrids en particulier.
- 25 Les fonctions d'optimisation d'un EMS s'inscrivent dans l'une ou l'autre des deux approches: l'approche *prédictive* et l'approche *myope* [Powell 2016, Nunez 2013], selon qu'elles tiennent compte ou non, de manière explicite, des prévisions de demande et de production futures pour élaborer la décision d'opération à appliquer à un instant donné. L'approche myope s'appuie sur la connaissance implicite des experts et considère ainsi la variabilité de la demande et de la production de manière plus limitée. Les approches prédictives considèrent cette variabilité avec une précision et sur un horizon temporel qui dépendent de la dynamique du système qu'il est besoin de considérer pour le type de décision à prendre : l'allumage de centrales nucléaires est décidé sur un horizon de plusieurs semaines ou mois ; en revanche, l'opération des batteries d'un microgrid est décidée typiquement sur une journée, discrétisée avec un pas horaire ou infra-horaire (par exemple 15 minutes), puis raffinée en temps réel. Dans les approches prédictives, on peut distinguer ainsi les approches *globales* qui optimisent conjointement les décisions sur tout l'horizon, et les approches *glouttonnes*, typiques du temps réel, qui optimisent les décisions pas à pas, de manière chronologique, sans réexaminer les décisions passées. On peut également distinguer les approches *déterministes*, qui supposent la connaissance d'une prévision parfaite, les approches *stochastiques*, qui intègrent les probabilités d'incertitude sur la prévision, et les approches *robustes* qui envisagent le contrôle optimal dans un pire cas plausible.
- 26 Quant aux algorithmes d'optimisation utilisés, nous pouvons les distinguer en deux grandes classes : les algorithmes de type *boîte blanche* (ou analytiques) et les algorithmes de type *boîte noire*. Les premiers exploitent la structure de la fonction objectif (notamment sa différentiabilité et sa convexité) pour guider l'optimisation sur l'ensemble des solutions représenté de manière analytique, typiquement par un modèle de programmation mathématique ou de programmation dynamique. Les

seconds sont des méthodes itératives et reposent sur un simulateur numérique pour évaluer, à chaque itération, la réalisabilité et la valeur d'une solution donnée. Les solutions à évaluer à une itération sont généralement choisies de manière heuristique à partir des performances des solutions précédemment évaluées. Les algorithmes génétiques appliquent, par exemple, des règles de sélection et de croisement pour construire une nouvelle génération de solutions à partir de la précédente.

Chacune de ces deux approches a ses avantages et ses inconvénients. Nous relevons ici les plus importants. Les méthodes de type boîte blanche assurent généralement d'atteindre un optimum global ou, du moins, une solution réalisable et un certificat d'écart à l'optimum. Leur mise en œuvre n'implique souvent que la conception d'un modèle de programmation mathématique et peu de développements algorithmique et informatique: le programme mathématique peut être résolu par appel à un *solveur*, un algorithme pré-implémenté, éprouvé et perfectionné. La principale difficulté réside justement dans la modélisation de la dynamique physique du système et de la fonction économique à optimiser: il est généralement nécessaire d'effectuer un compromis entre la précision du modèle mathématique et la complexité de l'algorithme de résolution correspondant (variables continues ou discrètes, fonctions linéaires ou non-linéaires, convexes ou non-convexes) pour contenir les temps de calcul. Les approximations du modèle peuvent ainsi conduire à des solutions non physiquement viables ou dont le coût réel est mal estimé. Les méthodes de type boîte noire s'appliquent, quant à elles, directement à une représentation fine du problème: évaluer la fonction objectif en des points donnés ne nécessite de celle-ci aucune propriété analytique (contrairement à trouver un point optimal) et la faisabilité physique d'une solution peut être facilement vérifiée par des outils de simulation numérique existants, ergonomiques et performants. Parce qu'ils dissocient réalisabilité et optimalité, ces algorithmes itératifs souffrent toutefois de problèmes de convergence, pouvant résulter en des temps de calcul longs et en l'absence de garantie d'optimalité des solutions trouvées, notamment dans le cas des metaheuristiques comme les algorithmes génétiques.

Objet de la thèse

Optimisation du contrôle. La littérature scientifique présente une abondance de solutions algorithmiques pour les problèmes du contrôle optimal des réseaux électriques depuis des décennies. Quand bien même ces problèmes soient NP-difficiles en général, cela laisse penser que l'on sait comment les résoudre en pratique. Pourtant, force est de constater que de nombreux réseaux réels à travers le monde, et principalement les microgrids qui se multiplient, ne disposent pas de stratégies de contrôle optimal avancées, c'ad que leur EMS n'embarque pas de fonctionnalités telles que l'UC, l'ELD ou l'OPF. Même lorsqu'on constate une volonté d'implémenter l'ELD, les méthodes utilisées, qualifiées de systèmes experts, sont souvent élémentaires, basées sur des heuristiques et règles métier peu sophistiquées. Le principal inconvénient de ces méthodes est, qu'étant myopes, elles ne tiennent pas compte de la dynamique de la demande ou de la variabilité des ressources renouvelables. Elles semblent pourtant effectives car leurs utilisateurs en obtiennent des résultats satisfaisants. Nous nous posons

donc les questions suivantes dans le cadre des microgrids : **Q1** : Y a-t-il un intérêt à mettre en place des solutions d'optimisation plus avancées, notamment prédictives ? Ces approches prédictives qui portent sur un horizon de planification ont des temps de résolution potentiellement supérieurs à la seconde, et sont donc incompatibles avec un contrôle en temps réel. Leur mise en œuvre, effective et efficace, dans la boucle de contrôle nécessite de repenser l'architecture de l'EMS. **Q2** : Comment coupler alors l'optimisation court-terme et le temps réel dans la boucle de contrôle ?

Applicabilité des commandes optimales. Cette décomposition du problème de contrôle en deux couches, court-terme et temps-réel, et les erreurs inhérentes à la modélisation de l'état et de la dynamique du système dans le premier problème, font que la commande optimale obtenue du premier peut, à un instant donné, ne pas être applicable au microgrid réel, et donc suivie par le second. Quand bien même la commande puisse être réalisable en ce sens, i.e. applicable en pratique, son coût calculé peut différer du coût réel. Dans la littérature, il n'est fait mention que rarement de l'applicabilité des commandes optimales, et les méthodes prédictives proposées ne sont pas évaluées sur cet aspect pourtant crucial. Effectivement, concernant les approches de type boîte noire, elles embarquent un simulateur numérique qui possède généralement une représentation suffisamment fine de la dynamique du système pour être considérée comme réaliste. Pour autant, l'état du système, ainsi pris en compte par la simulation de manière périodique dans la boucle de contrôle, peut différer de l'état réel continu du système. La question se pose de manière plus prégnante encore pour les approches de type boîte blanche qui, elles, reposent sur un modèle analytique plus fortement approximé encore du système. Nous posons ainsi, dans nos cas d'études particuliers, la question **Q3** : quel est le degré d'approximation acceptable dans un modèle de programmation mathématique rendant les solutions applicables ?

Comparaison des algorithmes d'optimisation. L'abondante littérature sur le contrôle optimal des microgrids s'explique en partie par la variété des problématiques, le modèle étant propre à l'infrastructure et à ses contraintes opérationnelles. On distingue cependant deux approches de résolution un peu plus fréquentes que les autres: l'approche boîte noire couplant un algorithme génétique et un simulateur numérique, et l'approche boîte blanche de programmation mathématique, notamment de programmation linéaire en nombres entiers. Comme nous l'avons déjà dit, ces approches ont des avantages et des inconvénients respectifs connus dans l'absolu. En revanche, la performance relative de ces algorithmes dans le contexte du contrôle de microgrid est finalement rarement évaluée. En effet, de nombreux articles présentent des évaluations empiriques, plus ou moins poussées, d'un algorithme de contrôle donné sur un cas d'étude réel ou simulé, et concluent sur la capacité de l'algorithme à effectivement fournir une commande (quand ce n'est pas seulement une solution au modèle mathématique, voir le point précédent). Mais, ils ne discutent pas de la qualité de la solution en terme de coût (existe-t-il une solution plus avantageuse ? quel gain espérer ?), car les approximations des programmes mathé-

matiques ou l'incomplétude des algorithmes génétiques ne permettent pas de disposer de bornes valides pour estimer les écarts à l'optimum. Ils n'évoquent pas non plus les temps de calcul, qui sont pourtant un élément important de l'intégration de ces algorithmes dans la boucle de contrôle. Enfin, il n'existe pas à notre connaissance de comparatif entre ces différentes approches dans le cadre du contrôle de microgrid. Une raison probable est que la comparaison expérimentale nécessite un protocole dont la mise en oeuvre est beaucoup complexe dans ce contexte: l'algorithme n'est ici qu'une brique intermédiaire de la boucle de contrôle, qui doit tourner en environnement simulé pour assurer la reproductibilité et l'intégrité de la comparaison. **Q4** : Quelles sont donc les performances respectives du système expert, de l'algorithme génétique et de la programmation mathématique dans ce contexte ?

Contexte AOCRE et calcul d'engagement. La littérature est aussi principalement consacrée au contrôle de microgrids qui intègrent une charge locale. La production doit alors satisfaire la demande prévisionnelle de la charge, généralement à moindre coût. Dans le cas on-grid, la production peut être complétée par un soutirage au réseau principal, quand elle est insuffisante pour satisfaire la demande, ou bien écrétée ou injectée au réseau et revendue, dans le cas contraire. Le contexte de l'AOCRE ZNI que nous étudions plus particulièrement dans cette thèse, est différent : les microgrids considérés sont des centrales de production et n'ont pas de charge associée. En revanche, elles s'inscrivent dans un marché d'électricité : l'exploitant du microgrid s'engage, la veille, sur sa production effective. La production effective doit alors être égale à l'engagement pris, à chaque instant et dans un certain intervalle de tolérance ; au-delà, défauts et excès donnent lieu au paiement de pénalités. Si le marché décrit par l'AOCRE ZNI a ses spécificités, il a cependant une structure assez générique, et la dérégulation favorise le développement de ce type de marchés. L'étude du contrôle de microgrid dans ce contexte est pourtant très minoritaire dans la littérature. Or, le problème d'optimisation sous-jacent présente des spécificités importantes, principalement dans l'expression de la fonction objectif, qui intègre les pénalités d'écart à l'engagement, en plus des primes d'injection et des coûts de soutirage, et dans la contrainte d'équilibre $production + ecart = engagement$, par opposition à la traditionnelle contrainte de satisfaction $production \geq demande$. Par ailleurs, le contrôle optimal du microgrid dépend intimement ici de l'engagement. Pour que le producteur ait un meilleur revenu journalier, il faut qu'il détermine son engagement de sorte à maximiser l'injection tout en s'assurant de pouvoir le satisfaire, afin de minimiser les pénalités. Le problème de calcul de l'engagement est donc en soi un problème d'optimisation distinct du problème de contrôle, et que nous appelons *problème d'engagement optimal* (PEO). Cette thèse est ainsi en grande partie consacrée à cette question, peu considérée dans la littérature, **Q5** : Comment optimiser à la fois le contrôle et l'engagement dans ce contexte ?

Incertitudes des données de prévision solaire. La production photovoltaïque est sensible aux phénomènes météorologiques, y compris à des phénomènes extrêmement locaux tels que le passage stochastique des nuages. De fait, elle

est fortement variable, difficile à prévoir et, à ce jour, il n'existe pas de modèles probabilistes précis pour sa prévision. Cette incertitude sur la prévision solaire pose des problèmes techniques majeurs, qui freinent l'intégration des énergies renouvelables dans les réseaux électriques conventionnels. Comme dit précédemment, elle peut être partiellement compensée par la présence de batteries. Cependant, la recherche par l'algorithme de contrôle d'une utilisation optimale des batteries à partir d'une prévision de production imparfaite, peut conduire à des solutions qui excèdent les limites de fonctionnement des batteries en condition d'ensoleillement réel. Depuis récemment, il existe ainsi des travaux sur des algorithmes d'optimisation robustes aux incertitudes sur l'ensoleillement ou sur la demande dans le contexte d'une charge associée au microgrid. En pratique, la robustesse du contrôle peut aussi être assurée par un recalcul périodique fréquent en implémentant une stratégie de *rolling horizon*, une boucle de contrôle avec rétroaction. Cette approche permet d'exploiter des données prévisionnelles mises à jour, et donc plus sûres. Surtout, elle permet de corriger l'état supposé du système par l'état observé. Cette possibilité n'est en revanche pas envisageable dans le cas du calcul d'engagement. L'AOCREZNI offre, au mieux, un marché intra-day permettant au producteur de mettre son engagement à jour 3 fois dans la journée. Ces nouveaux engagements sont appelés *redéclarations*. Le PEO est donc plus vulnérable aux incertitudes que le PCO, et les erreurs sont amplifiées du fait (i) des prévisions solaires à plus long terme, donc moins bonnes, et (ii) de l'asservissement du contrôle à l'engagement. Ainsi, un engagement trop optimiste, sur la base de données de prévision surestimant la production solaire, peut entraîner des pénalités importantes. Les questions qui se posent sont donc **Q6** : Comment tenir compte des incertitudes ? Et **Q7** : peut-on en espérer un gain significatif ?

Organisation du manuscrit

Ce manuscrit de thèse comporte 7 chapitres regroupés en 3 parties, encadrés par cette introduction et une conclusion. La première partie porte sur les généralités sur les microgrids (chapitre 1) et sur l'optimisation (chapitre 2), et détaille les problématiques abordées ci-dessus (chapitre 3).

Dans la seconde partie, nous étudions le problème de contrôle optimal dans deux cas pratiques distincts. Le chapitre 4 s'intéresse au cas d'un microgrid isolé (ou autonome) intégrant générateurs contrôlables (diesel), non-contrôlables (solaire) et batteries pour alimenter une charge. Il présente un modèle classique de programmation linéaire en nombres entiers pour le problème de contrôle, et propose d'évaluer l'applicabilité de ses solutions sur un système simulé, en réponse aux questions **Q1**, **Q2** et **Q3**. Pour ce faire, nous avons conçu un système de contrôle composé d'un contrôleur (que nous appelons *Tracker*) couplé à un système de contrôle temps réel composé d'un contrôleur temps réel (appelé Power Management System ou **PMS**) et d'un simulateur (qui est un modèle du microgrid réel, appelé **Plant**). Ce système de contrôle temps réel est une boîte noire pour notre système de contrôle. Le couplage a été rendu possible par l'adéquation des interfaces logicielles. Nous exploitons la générnicité de cette approche pour l'étendre, dans le chapitre 5, au cas plus original

d'une micro-centrale solaire équipée de batteries pour alimenter le réseau électrique principal et répondant à l'AOCREZNI de l'année 2015. Nous exploitons aussi la modularité de cette architecture pour aborder **Q4** et comparer expérimentalement 3 différents types de contrôleur: un système expert, un algorithme génétique couplé au simulateur et un programme mathématique. Il ressort principalement de cette étude expérimentale que les contrôleurs basés sur des méthodes d'optimisation avancées présentent des performances meilleures que le contrôleur basé sur les règles d'expert. La boucle de rétroaction développée permet de relancer fréquemment le contrôleur avec le nouvel état du microgrid (retourné par le simulateur) et, potentiellement, de nouvelles prévisions solaires. Cette stratégie permet notamment de compenser les erreurs de modélisation, et d'assurer l'applicabilité des solutions retournées par le contrôleur. Ainsi, l'approche de programmation mathématique n'est ici pas pénalisée par les fortes approximations du modèle, et sa convergence rapide vers des optimums globaux lui permet de générer des plans de production plus profitables.

La troisième et dernière partie est consacrée au problème d'engagement optimal. Le chapitre 6 s'intéresse au cas déterministe, où les incertitudes sur la prévision solaire sont négligées. Ces incertitudes sont ensuite prises en compte dans le chapitre 7. L'intégration de ces calculs dans l'EMS nécessite l'ajout d'un nouveau module en amont du système de contrôle précédent. C'est le module de prédiction ou de détermination de l'engagement que nous appelons **Predictor**. Ce composant résout le PEO et envoie le profil d'engagement au **Tracker**, qui détermine le contrôle optimal, l'envoie au **PMS** qui applique la commande à **Plant**. Lorsque le **Predictor** est exécuté pour la première fois (la déclaration) et lors des redéclarations, il prend en entrée les prévisions solaires et l'état actuel de **Plant**. L'EMS comporte donc deux boucles de rétroaction, la boucle en charge de l'engagement étant relancée à une fréquence moindre (au maximum toutes les 6 heures). Le PEO peut être vu comme un problème bi-niveau combinant la recherche d'un profil d'engagement et l'évaluation du PCO associé. Nous montrons dans le chapitre 6 comment étendre les 3 approches du PCO (système expert, algorithme génétique et programme mathématique) au PEO (question **Q5**), et les comparons expérimentalement. Ici encore, l'approche de programmation mathématique présente les meilleures performances. Ces performances étant basées sur l'hypothèse non réaliste que les données de prévision sont parfaites, nous avons étudié le cas où les incertitudes sont prises en compte pour le calcul de l'engagement, au sein du **Predictor**. Nous avons implémenté, au-dessus du modèle de programmation mathématique, une approche de programmation stochastique, basée sur les probabilités d'ensoleillement, et une approche de programmation robuste, optimisant sur la pire réalisation plausible de l'ensoleillement. À partir des données de prévision dont dispose la centrale, données sous forme de déciles, nous proposons de générer des scénarios de réalisation pour l'approche stochastique, et de déterminer les intervalles et budgets d'incertitude pour le cas robuste (question **Q6**). Les résultats de l'expérimentation de ces deux stratégies montrent une certaine supériorité de l'approche robuste, et la comparaison avec la stratégie déterministe nous permet de conclure sur l'importance de prendre en compte ces incertitudes (question **Q7**).

Enfin, les principaux résultats de notre étude sont repris dans la conclusion où nous présentons également quelques éléments de réflexion concernant la généricté (comment ne pas redévelopper l'intégralité d'un EMS quand un nouveau microgrid,

avec d'autres composants ou une autre topologie, est considéré) et des perspectives sur l'intégration des services auxiliaires au réseau (réserve notamment) que peuvent fournir les micro-centrales étudiés dans cette thèse.

Liste des symboles

Paramètres

T	Horizon	1440 min
t	Instant	$[1 \dots T]$
t_{on}^{min}	Nombre d'instants consécutifs de marche du gенset	
t_{off}^{min}	Nombre d'instants consécutifs d'arrêt du gенset	
t_{prev}^G	Instants consécutifs de même état du gенset, à la fin de l'horizon précédent	
δ_t	Durée d'un pas de temps	min
P	Puissance totale installée sur le microgrid	kW
E_t	Production instantanée du champ PV	kW
L_t	Demande d'électricité	kW
η_c, η_d	Rendement de charge/décharge de la batterie	
B^{nom}	Capacité nominale de la batterie	kWh
B^{dam}	Vieillissement minimal de la batterie	
B_c^{max}, B_d^{max}	Puissance maximale de charge/décharge de la batterie	kW
η_{PV}^{inv}	Rendement du convertisseur DC/AC en sortie du champ PV	
$\eta_{PV}^{trs}, \eta_{Bat}^{trs}$	Rendement du transformateur en sortie du champ PV/de la batterie	
G^{min}, G^{nom}	Puissance minimale/nominale du gенset	kW
y_{prev}^G	État du gенset à la fin de l'horizon précédent	{0,1}
π_F	Prix du carburant	€/L
π_t	Prix de l'électricité	€/kWh
soc^{min}, soc^{max}	État de charge minimal/maximal de la batterie	
soh_t, soh_∞	État de santé de la batterie à l'instant t /en fin de vie	
C_F^{nom}, C_F^{idle}	Consommation de carburant nominale et lorsque le gенset est en inactivité	L/h
cop	Coefficient de performance du microgrid	
C_{bat_inv}	Coût d'investissement de la batterie	k€/kWh

Variables

u_t	Puissance fournie au réseau	kW
u_t^L	Puissance fournie à la charge	kW
u_t^D	Engagement	kW
u_t^{dev}	Déviation entre la demande et la puissance fournie à la charge	kW
u_t^E	Puissance effectivement fournie par le champ PV	kW
u_t^B	Puissance fournie par la batterie	kW
u_t^G	Puissance fournie par le générateur diesel	kW
u_t^{XB}	Puissance reçue par la batterie	kW
u_t^{MX}	Pertes sur le microgrid	kW
soc_t	État de charge de la batterie	
y_t^B	= 0 si batterie en mode charge, = 1 si mode décharge	
y_t^G	État on/off du genset	{0,1}
x_t^{on}, x_t^{off}	Changement d'état on/off du genset	{0,1}

1

Généralités sur les microgrids

Sommaire

- 1.1 Principaux composants d'un microgrid
- 1.2 Topologies des microgrids
- 1.3 Fonctionnement des marchés de l'électricité et du paradigme de l'AOCRE ZNI

UN MICROGRID peut être défini comme un système électrique de petite capacité à faible et moyenne tension, connecté au réseau électrique principal ou isolé [Minchala-Avilaa 2015]. Dans une région géographique, on peut avoir plusieurs microgrids, chacun ayant un fonctionnement indépendant des autres. Un microgrid fournit de l'électricité à une charge (une maison, un centre commercial, une ville, etc.) ou en échange (injection-soutirage, vente-achat) avec le réseau principal. Un microgrid, composé de générateurs à énergie renouvelable et de générateurs à énergie fossile, est qualifié de microgrid *hybride*. Par exemple, un microgrid composé d'un champ photovoltaïque (ressource renouvelable), d'une batterie de stockage et d'un générateur diesel (ressource fossile) est un microgrid hybride. Les systèmes off-grid sont généralement hybrides.

1.1 Principaux composants d'un microgrid

On peut distinguer les 3 principales classes suivantes de composants des microgrids : 27

Les générateurs électriques : Ce sont les dispositifs de production d'électricité à partir d'énergies fossiles (centrales thermiques, hydroélectriques et générateurs diesel) ou renouvelables (panneaux photovoltaïques, turbines éoliennes).

Les batteries de stockage : Ce sont des dispositifs capables de stocker de l'électricité sous forme d'énergie mécanique ou chimique, puis de la restituer.

Les charges contrôlables : Ce sont les consommateurs d'électricité, qualifiés de contrôlables car ils peuvent augmenter ou réduire leur niveau de consommation au besoin et avec une plus ou moins bonne réactivité.

S'ajoute également la classe des équipement auxiliaires, tels que les bus et convertisseurs, permettant l'interconnexion de ces différents composants et le transport de l'énergie.

Nous décrivons, dans cette partie, les composants des microgrids qui ont fait l'objet de notre étude : systèmes photovoltaïques, batteries de stockage, générateurs

diesel et convertisseurs d'énergie et auxiliaires. Nous relevons ci-après les caractéristiques physiques de ces composants, qui guident un énergéticien dans le choix de ces composants. Nous ne mentionnons donc pas des caractéristiques liées à la physique théorique ou à la chimie.

1.1.1 Systèmes photovoltaïques

- 29 Un système photovoltaïque (PV) est un ensemble de cellules solaires (photovoltaïques) et de composants électroniques de conversion et de régulation d'énergie.
- 30 Une cellule solaire est composée de matériaux semi-conducteurs comme le Silicium (Si), l'Arsénure de Gallium (GaAs), de Sulfure de Cadmium (CdS), etc. Son fonctionnement est gouverné par les lois de la mécanique quantique. Fondamentalement, chaque matériau semi-conducteur a une énergie de gap. Lorsqu'un panneau photovoltaïque est exposé au soleil, les cellules se chargent de photons et leur énergie augmente : c'est l'*effet photovoltaïque*. Dès que cette énergie devient supérieure à l'énergie de gap du matériau, qui constitue les cellules, celui-ci devient un conducteur d'électricité. Cette énergie électrique peut donc être recueillie et rendue utile, notamment dans un microgrid.
- 31 Un module (respectivement, un panneau) photovoltaïque est un ensemble de cellules (resp. de modules) solaires agencées en série et/ou en parallèle. Deux caractéristiques importantes d'un module sont sa puissance nominale, exprimée en Watts crête (W_c), mesurée dans les conditions standards de test (température de 25 °C à la surface du module et ensoleillement de 1000 W/m²) et sa puissance maximale instantanée, obtenue grâce à un dispositif appelé traqueur de point de puissance maximale (Maximum Power Point Tracker ou MPPT).
- 32 La puissance fournie par un panneau photovoltaïque dépend de l'ensoleillement, qui est une quantité aléatoire, difficilement prévisible et non contrôlable. Cette intermittence est la cause d'instabilité du réseau. C'est pourquoi la pénétration des sources d'énergie renouvelables (celles à fort taux de variabilité), dans les smart-grids, est un challenge pour les gestionnaires de réseau.

1.1.2 Batteries de stockage

Rôle des batteries dans les smart-grids

- 33 Les batteries de stockage aident à résoudre un grand nombre de problèmes dans les smart-grids, parmi lesquels nous pouvons citer [Carbone 2011] :
- la participation à la stabilité en tension et en fréquence du réseau par le contrôle, en compensation de l'instabilité engendrée par l'intégration des RES ;
 - la réduction des coupures intempestives de courant ;
 - la réduction de la réserve d'exploitation nécessaire pour satisfaire la demande de pointe ;
 - la réduction de la congestion des réseaux de transmission et de distribution ;
 - la restitution de l'énergie stockée au moment voulu, notamment en période où l'électricité est la plus chère, et

- l'amélioration de la qualité de l'alimentation et de la fiabilité du service fourni.

La batterie est donc non seulement un fournisseur d'électricité, c'est également un composant contrôlable, avec une grande rapidité de réaction [Piao 2015, Delille 2012]. C'est donc un composant crucial des microgrids .

Différentes technologies de batteries

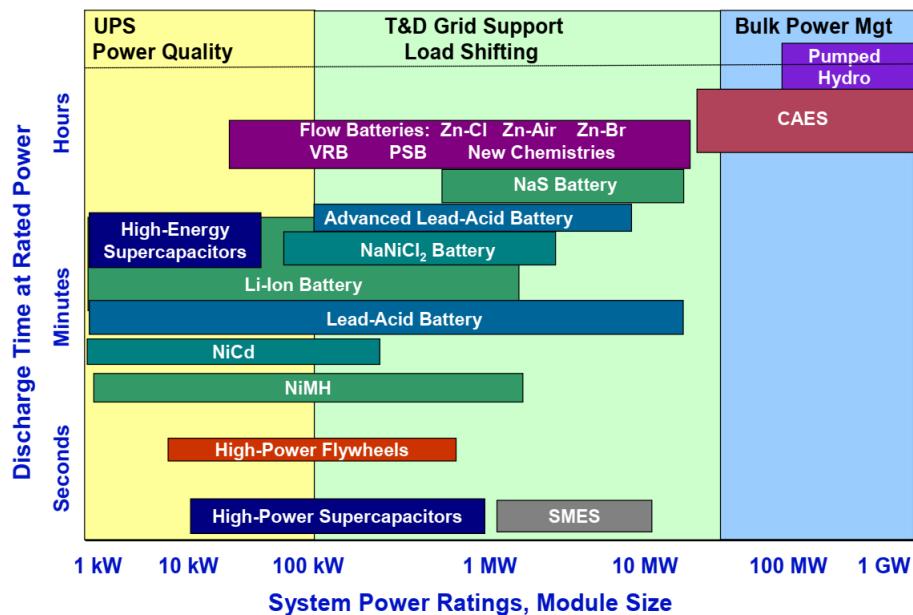


FIGURE 1.1: État de l'art des technologies de stockage d'énergie et leurs positionnements (source : [DOE/EPRI 2013])

On distingue aujourd’hui un grand nombre de technologies de stockage d’énergie. **34**
La figure 1.1 relève la plupart de ces technologies, et leurs domaines d’application. Les batteries, majoritairement intégrées dans les microgrids, sont des dispositifs qui convertissent l’énergie chimique, contenue dans un matériau électrochimiquement actif, en énergie électrique, à travers une réaction d’oxydo-réduction. On distingue les batteries au plomb-acide, aux ions lithium, au nickel cadmium, au sulfure de sodium, etc.

Les batteries au plomb représentent plus de 90% du marché de batterie. Elles sont d’une grande fiabilité, et sont relativement peu coûteuses, mais ont une faible densité d’énergie due à leur grande densité de plomb. Les batteries aux ions lithium étaient initialement conçues pour les appareils électroniques portables. Parmi toutes les technologies de batteries, elles ont la plus grande densité d’énergie et le plus grand nombre de cycles de charge/décharge, mais sont beaucoup plus coûteuses. Les batteries au nickel-cadmium, quant à elles, représentent le meilleur compromis entre l’énergie/puissance spécifique, la durée de vie et la fiabilité. Toutefois, la toxicité du cadmium a conduit à sa substitution à d’autres corps, tels que les métaux hybrides. [Carbone 2011]

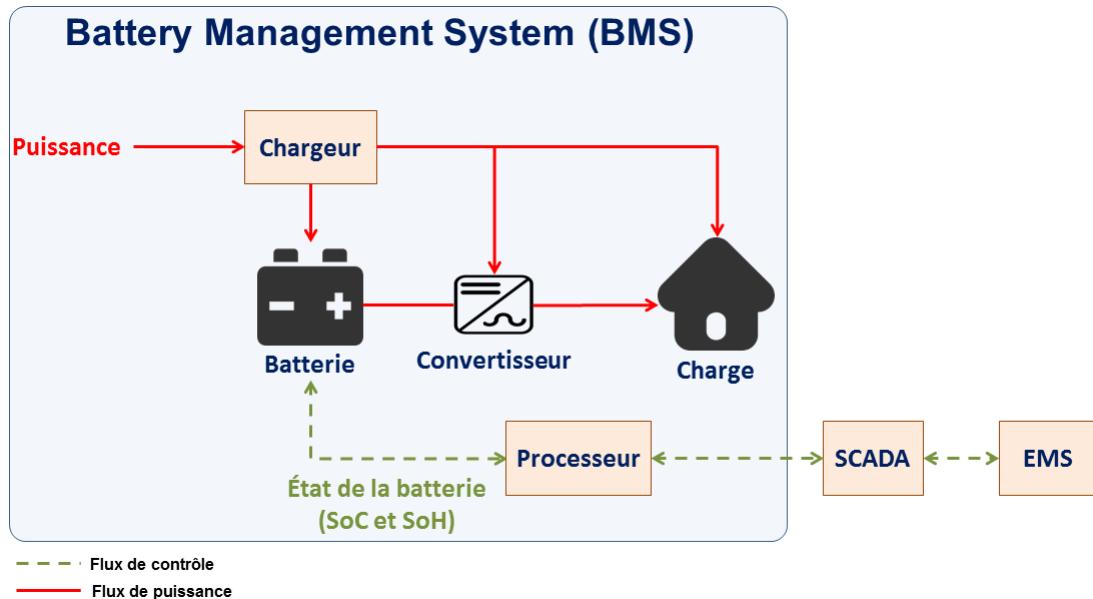


FIGURE 1.2: Architecture générale d'un BMS. Adaptée à partir de [Pop 2008])

Fonctionnement des batteries électrochimiques et leur contrôle

- 35 Pour expliquer le fonctionnement interne d'une batterie, on peut utiliser le concept cinétique. Selon ce concept, l'architecture interne d'une batterie est un système à deux tanks [Manwell 1993, Woon 2008] : un tank d'énergie disponible, qui fournit l'énergie immédiate pour la charge et la décharge, et un tank d'énergie liée, auquel l'énergie non utilisée est liée chimiquement. Le rendement de conversion dépend de la différence de hauteur entre ces tanks.
- 36 La gestion d'une batterie est réalisée par un composé nommé système de gestion de batterie (Battery Management System ou BMS, en anglais). La tâche principale du BMS est d'assurer l'utilisation optimale de l'énergie interne de la batterie, et de limiter la dégradation de la batterie. Cette tâche est accomplie en surveillant et en contrôlant le processus de charge et décharge de la batterie [Pop 2008]. La figure 1.2 présente l'architecture générale d'un BMS. Le chargeur est un équipement qui sert à charger la batterie à partir de la puissance reçue d'un générateur ; il convertit cette puissance en une puissance adaptée à la batterie. Le convertisseur (onduleur, hacheur ou bidirectionnel) adapte la tension de sortie de la batterie à celle requise par la charge. Cette dernière convertit l'énergie reçue en l'énergie appropriée pour accomplir sa fonction. L'état de la batterie peut être exprimé par son état de charge (State of Charge ou SoC, en anglais) et par son état de santé (State of Health ou SoH, en anglais). Ces deux paramètres peuvent être utilisés pour estimer la durée de vie restante de la batterie.

Le processeur — le logiciel de gestion de la batterie — reçoit l'état de la batterie sous forme de signal et, à l'aide d'algorithmes, déduit le SoC et le SoH. Cette information est ensuite envoyée au SCADA, qui l'envoie enfin à l'EMS du microgrid.

- 37 À un instant donné, une batterie peut recevoir ou bien fournir une quantité d'électricité limitée. L'état de charge (SoC) de la batterie est le pourcentage de charge maximale disponible à un instant donné. La valeur 0 % indique que la batterie

est entièrement déchargée : elle ne peut plus fournir d'énergie. La valeur 100 % indique que la batterie est entièrement chargée : elle ne peut accepter d'énergie. L'état de charge peut être estimé, à partir de la tension de la batterie, en utilisant une table de correspondance. Mais, l'implémentation de cette table est rendue difficile par le fait que la tension de la batterie dépend d'autres paramètres, tels que sa température, son taux de décharge et son vieillissement ; ce dernier étant, lui-même, difficile à estimer.

L'état de santé (SoH) d'une batterie indique sa capacité actuelle à fournir ou à recevoir de l'énergie, en comparaison avec une nouvelle batterie. L'estimation de la valeur de SoH est encore plus difficile que celle de SoC, car elle dépend de cette dernière, du nombre de cycles de charge/décharge réalisés et d'autre paramètres environnementaux qui sont imprévisibles. La solution usuelle d'estimation passe par l'implémentation de systèmes adaptatifs, tels que les réseaux de neurones, les filtres de Kalman et la logique floue [Pop 2008, Murnane 2017, Krewer 2018].

Le tableau 1.1 présente les principales méthodes de détermination de SoC et/ou SoH. Comme on peut le voir, il y a un grand nombre de méthodes de détermination de l'état de la batterie ; chacune ayant ses avantages, ses inconvénients et ses domaines d'utilisation.

Dans notre étude, nous avons adopté la version en temps discret de la méthode de comptage de Coulomb, car cette méthode est facile à linéariser et nous disposons des paramètres qu'elle requiert sans avoir à faire des calculs intermédiaires. Ces paramètres sont : l'énergie nominale (quantité maximale d'énergie que la batterie peut fournir à un instant), l'état de charge initial, et la puissance fournie/reçue. Dans notre version, nous supposons que l'énergie nominale est constante, pour que le modèle soit linéaire. En réalité, l'énergie nominale baisse à mesure que le SoH de la batterie diminue. Ce modèle est exprimé comme suit :

$$soc_t = soc_{t-1} + \left(\eta_c P_t^{ch} - \frac{P_t^{disch}}{\eta_d} \right) \frac{\delta_t}{B^{nom}} \quad \forall t = 1, \dots, T$$

où les paramètres η_c , η_d et B^{nom} relatifs à la batterie désignent, respectivement, les rendements de charge et de décharge, et la capacité nominale de la batterie. δ_t est la valeur d'un pas de temps, et T désigne l'horizon sur lequel le calcul est effectué. Les variables P^{ch} et P^{disch} représentent la puissance de charge et la puissance de décharge, de la batterie, respectivement. Ces variables sont reliées par la relation :

$$P_t^{disch} * P_t^{ch} = 0$$

qui exprime le fait que la batterie ne peut pas être simultanément en charge et en décharge.

Dans [Palma-Behnke 2013], les auteurs intègrent un coût de dégradation de la batterie (fonction de SoH), dans leur fonction objectif, mais le modèle de SoH est non linéaire et aucune forme analytique n'est fournie.

P. Rong et M. Pedram, dans [Rong 2006], présentent un modèle analytique non linéaire, pour la détermination de l'état de charge SoC et de l'état de santé SoH, pour les batteries aux ions Lithium.

Dans [Woon 2008], Siew F. Woon *et al* présentent un modèle linéaire par morceaux de la dynamique de la batterie, dépendant des puissances fournies par les

Méthode	Domaine d'application	Avantages	Inconvénients
Test de décharge	Détermination de la capacité en début de vie	Facile et précis ; indépendant de SoH	Hors-ligne, gourmande en temps, modifie l'état de la batterie, perte d'énergie
Comptage de Coulomb	Tous systèmes de batterie, la plupart des applications	Précis si suffisamment de points de recalibrage disponibles et de bonnes mesures du courant	Sensible au réactions parasites ; nécessite le recalibrage fréquents des points
OCV (Open Circuit Voltage)	Plomb, Lithium, Zn/Br	En ligne, moins chère, Prédition de l'OCV	Nécessite un long temps de repos (courant = 0)
EMF (Electro-Motive Force)	Plomb, Lithium	En ligne, moins chère, Prédition de l'EMF	Nécessite un long temps de repos (courant = 0)
Modèle linéaire	Plomb, Photovoltaïque	En ligne, facile	Nécessite des données de référence pour déterminer les paramètres
Observateur adaptatif non linéaire [Lakkis 2015]	Lithium	Ne nécessite aucun calcul itératif, calcul combiné de l'état et des paramètres	Difficile à implémenter
Spectroscopie d'impédance	Tous systèmes	Donne des informations sur SoH	Sensible à la température et chère
Résistance interne DC	Plomb, NiCd	Donne des informations sur SoH ; possibilité de mesures en ligne	Bonne précision mais seulement pour un intervalle de temps court
hline Réseaux de neurones	Tous systèmes	En ligne	Nécessite des données d'apprentissage pour une batterie similaire, implémentation coûteuse
Logique floue	Tous systèmes	En ligne	Requiert une grande quantité de mémoire dans des applications réelles
Filtres de Kalman	Tous systèmes	En ligne, dynamique	Difficile à implémenter

TABLE 1.1: Principales méthodes de détermination de SoC / SoH. Adaptée à partir de [Pop 2008])

autres composants du microgrid, notamment le champ PV et le générateur diesel. Ce modèle reste atypique, eu égard aux autres modèles que nous avons vus.

Comme c'est le cas dans la plupart des études sur le contrôle optimal des microgrids, avec batteries, l'état de santé n'a pas été considéré comme variable d'optimisation, dans notre étude. Cela s'explique d'abord par le fait qu'il y a pas véritablement de modèles analytiques linéaires, pour estimer le SoH. Ensuite, même si un tel modèle était disponible, cette complexité supplémentaire du modèle mathématique, ne serait pas justifiée car, sur un horizon de 24 heures, la baisse de SoH est assez négligeable. Aussi, son impact sur la solution optimale est marginale. En outre, la boucle de rétroaction permet de compenser l'erreur qu'on fait en négligeant SoH. Un modèle numérique (complexe) peut donc être utilisé *a posteriori* pour estimer SoH et donc une nouvelle valeur de B^{nom} , et estimer le coût de dégradation de la batterie.

Une manière de réduire la dégradation de la batterie, sans avoir à modéliser SoH, est d'imposer des contraintes de rampe sur la puissance instantanée de charge ou de décharge [Kanwar 2015]. Mais, cette pratique étant peu courante, nous ne l'avons pas adopté.

1.1.3 Générateurs diesel

Un générateur diesel (ou Genset ou groupe électrogène) est un générateur d'électricité entraîné par un moteur diesel. Il utilise donc du carburant fossile. Il peut être utilisé en production ou comme secours.

Historiquement, les générateurs des réseaux traditionnels étaient principalement composés de générateurs diesel. Une autre application classique des gensets est dans les systèmes off-grids (dans les zones n'ayant pas accès au réseau principal) ou semi-autonomes (secours en cas de coupure de l'électricité principale). La transition vers des systèmes *verts* (respectueux de l'environnement) a entraîné l'hybridation des systèmes off-grids traditionnels [Komor 2012]. Nous avons donc maintenant des systèmes composés de RES et de gensets, avec éventuellement des batteries.

Les gensets sont très réactifs, démarrent rapidement (10 à 15 s pour démarrer et alimenter la charge contrairement aux générateurs à combustion interne qui prennent environ 2 mn [Sechilariu 2016, Hazel 2000]), ont une bonne disponibilité, fiabilité, durabilité [Taşçikaraoglu 2019], mais leur temps d'arrêt est plus ou moins long et ils sont sensibles à la fréquence des cycles marche/arrêt. Bien qu'ils démarrent relativement vite, le temps de démarrage est un facteur à compenser dans les applications temps réel. Les gensets sont conçus pour fonctionner entre 30 et 80% de leur capacité nominale — la puissance qu'ils peuvent délivrer dans des conditions dites nominales —, fixées par le fabricant [Woon 2008] ou puissance maximale théorique, spécifiée par le fabricant. Cela veut dire que, dans la pratique, le plus souvent, un gенсет ne peut pas fournir exactement sa puissance nominale : il n'en fournit qu'une fraction à chaque instant. Mais, la plupart des études considèrent que le gенсет peut même fournir 100% de sa puissance nominale. Dans [Woon 2008], il est mentionné qu'afin d'éviter le glaçage des parois des cylindres du gенсет — ce qui entraîne une consommation élevée de carburant —, il est recommandé de ne pas faire fonctionner le gенсет en dessous de 40% de sa puissance nominale.

Le contrôle des gенsets est une tâche très difficile à cause de leur comportement fortement non linéaire et de leur inertie qui cause des délais. Toutefois, dans le

cas du contrôle des microgrids, lorsque le contrôle se fait au niveau énergétique (donc puissance), un modèle linéaire du genset peut être suffisant [Sechilariu 2016]. L'approche classique est de considérer que la puissance que peut fournir le genset est comprise dans un ensemble continu borné, dont la valeur maximale est la puissance nominale [Tazvinga 2015, Sechilariu 2016, Kusakana 2015]. Une autre approche est de considérer que le genset ne peut fournir qu'un ensemble fini de puissances, dont chaque élément est le pourcentage de sa puissance nominale [Woon 2008]. Une autre approche est de considérer que le genset ne peut fournir que sa puissance nominale, lorsqu'il est en marche [Kusakana 2015].

- 45 L'utilisation d'un genset implique un coût : le coût financier pour l'achat du carburant diesel utilisé et le coût environnemental des émissions de gaz à effet de serre. Le contrôle du genset doit tenir compte de ces coûts. Dans notre étude, nous ne modélisons que la consommation de carburant et le coût financé associé. Nous appliquons un modèle standard [Viana 2013, Sichilalu 2015, Tazvinga 2015, Kusakana 2015, Nemati 2018] de la consommation de carburant comme une fonction quadratique de la puissance produite. D'autres modèles existent, fortement non linéaires [Woon 2008] ou linéaires [Barley 1995] comme celui utilisé dans le logiciel HOMER.

1.1.4 Convertisseurs électroniques et auxiliaires

- 46 Un microgrid contient également des équipements auxiliaires comme des convertisseurs d'énergie, des câbles électriques, des compteurs électroniques, des capteurs, des bus, etc.
- 47 Les convertisseurs sont souvent requis dans les microgrids. Par exemple, un microgrid fournissant du courant alternatif (AC) et équipé de panneaux photovoltaïques, nécessite un *onduleur* à la sortie des panneaux pour convertir le courant continu (DC) délivré en courant alternatif. Il est souvent nécessaire aussi d'avoir un *hacheur* (convertisseur de courant continu en courant continu) à la sortie des panneaux, juste avant l'onduleur, afin de réguler la tension à la sortie des panneaux. Inversement, pour les microgrids délivrant du courant continu, il est nécessaire d'installer des *redresseurs* (convertisseur de courant alternatif en courant continu) à la sortie des batteries et des générateurs diesel ou de tout autre générateur de courant alternatif.
- 48 À part lorsque le but est de contrôler la tension au bus du microgrid [Bidram 2014, Guo 2015, Sahyoun 2015], la prise en compte des convertisseurs n'est pas une priorité dans la plupart des études susmentionnées, et celles que nous verrons dans la suite. Lorsqu'ils sont pris en compte, leur modèle se réduit une valeur constante de leur rendement de conversion.

1.2 Topologies des microgrids

Dans cette section, nous présentons quelques topologies des microgrids. Dans ce contexte, par topologie, on entend comment les composants du microgrid sont connectés entre eux et, éventuellement, au réseau.

La figure 1.3 montre un système off-grid composé de deux générateurs à énergie

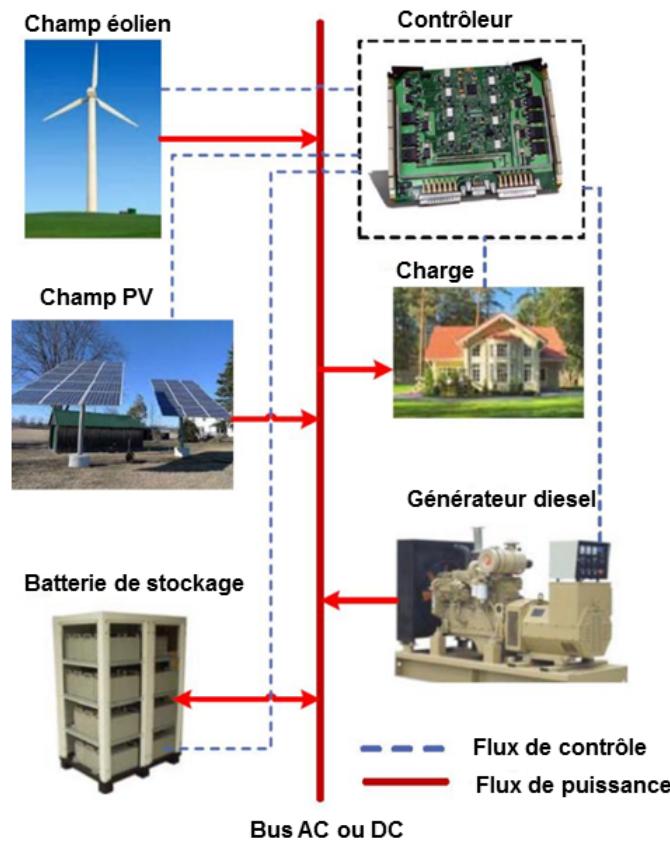


FIGURE 1.3: Microgrid hybride à un bus (AC ou DC) alimentant une charge domestique (adaptée de [Tazvinga 2015], p.20)

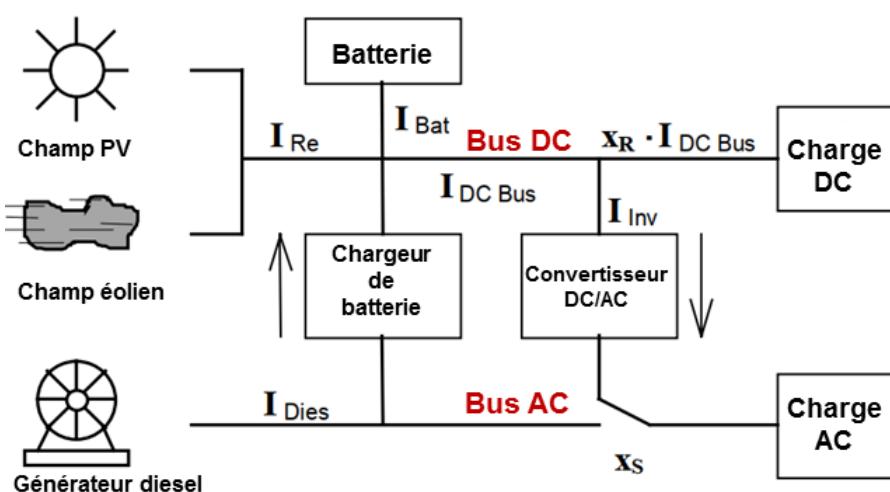


FIGURE 1.4: Microgrid hybride à deux bus (AC et DC) alimentant deux types de charge (adaptée de [Seeling-Hochmuth 1998], p.69)

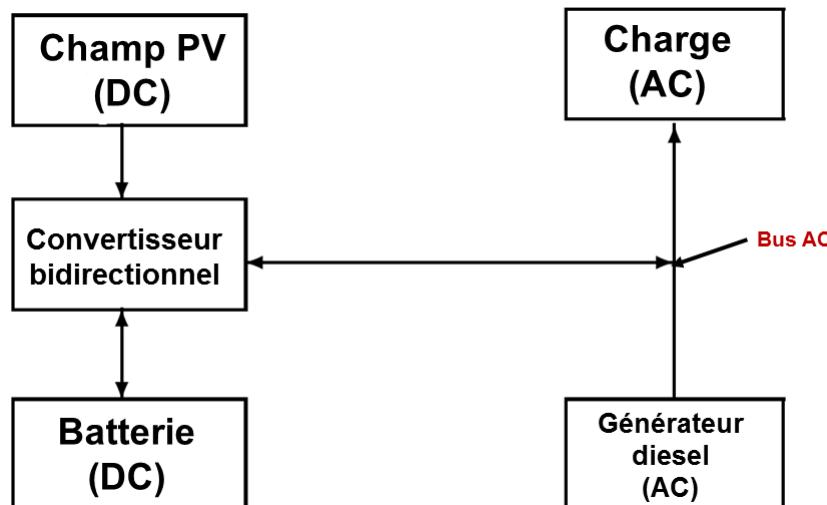


FIGURE 1.5: Microgrid hybride à un bus AC alimentant une charge AC (adaptée de [Woon 2008], p.1)

renouvelable (un champ PV et un champ éolien), d'un générateur diesel et d'une batterie de stockage. Ce microgrid alimente une charge domestique à travers un seul bus. Les convertisseurs n'étant pas représentés, on ne peut pas déduire le type de bus (courant AC ou DC) à travers la figure. Dans tous les cas, en fonction du type de courant que la charge demande, les convertisseurs seront disposés de sorte à satisfaire cette contrainte.

Comme sur la figure 1.3, la figure 1.4 montre un système off-grid composé d'un champ PV, d'un champ éolien, d'un générateur diesel et d'une batterie de stockage. Mais ce microgrid alimente deux types de charge: une charge AC et une charge DC, à travers deux bus (AC et DC). Un convertisseur DC/AC (ou onduleur) est utilisé pour convertir le courant continu provenant des champs PV et éolien en courant AC pour la charge AC. Le chargeur de batterie est un régulateur de courant/tension provenant du générateur diesel pour alimenter la batterie. Lorsque la batterie est chargée, le générateur peut fournir du courant alternatif directement à la charge AC. Dans cette topologie, il est clair que le gенсет ne fournit pas d'électricité à la charge DC.

La figure 1.5 présente un système off-grid, composé un champ PV, d'une batterie, fournissant du courant DC, et un gенсет. Le système alimente un charge AC. La particularité de ce système est l'utilisation d'un convertisseur bidirectionnel, c'est-à-dire qu'il joue le double rôle de redresseur et d'onduleur. Cela simplifie grandement la topologie.

Le dernier exemple (Voir la figure 5.1 du chapitre 6) est un microgrid connecté réseau, composé d'un champ PV, du groupe de batteries et de convertisseurs et transformateurs. L'objectif primaire de ce microgrid est de vendre de l'énergie au réseau via un bus AC (c'est sa charge). Il lui est également permis de soutirer (acheter) de l'électricité du réseau. Nous étudierons ce type de microgrid au chapitre 6.

1.3 Fonctionnement des marchés de l'électricité et du paradigme de l'AOCRE ZNI

1.3.1 Généralités sur les marchés et les marchés de l'électricité

Un marché peut être défini comme un système composé d'*acheteurs*, de *vendeurs* et de *commodités*. Ce dernier composant constitue l'élément échangé entre les deux premiers composants. Un acheteur peut être un vendeur et vice-versa ; on peut donc génériquement les appeler *agents*. Une commodité peut être tangible ou intangible ; elle a une valeur ou *prix*, fixée par le vendeur ou par une entité externe au marché. L'acheteur s'approprie une commodité en payant le prix spécifié. 49

D'après ce qui vient d'être dit, on comprend qu'un marché ne fonctionne que s'il y a échange permanent de commodités. Chaque agent cherche à maximiser son utilité. Le vendeur veut vendre sa commodité au meilleur prix ; l'acheteur veut également acheter la commodité au meilleur. Le sens de « meilleur » est relatif à chacun d'eux. Chacun définit donc sa fonction d'utilité et agit sur le marché de sorte à la maximiser. Lorsque le prix est fixé de sorte que la quantité de commodités mises à disposition par les vendeurs est égale à la quantité de commodités recherchées par les acheteurs, on dit que le marché est *équilibré*. On distingue plusieurs types d'équilibre de marché dont les plus communs en micro-économie sont l'*équilibre compétitif* ou *concurrentiel* et l'*équilibre de Nash* [Chen 2016]. Le premier suppose un environnement compétitif dans lequel chaque agent base sa décision d'achat/vente sur une quantité de commodités qui est tellement petite, par rapport à la quantité totale de commodités disponibles sur le marché, que leurs transactions individuelles n'a aucune influence sur les prix. L'équilibre de Nash est une situation stratégique dans laquelle chaque agent prend sa décision (optimale) en fonction de celles des autres (mais les choix sont simultanés). On estime que de cette façon, l'agent ne regrette pas son choix, contrairement à l'environnement compétitif où les agents subissent les prix.

Dans un marché de l'électricité, les principaux agents sont les producteurs, les propriétaires des réseaux de transmission et de distribution, les agrégateurs, les courtiers, les commerciaux, les utilisateurs finaux (potentiellement les ménages) et le gestionnaire de réseau. Ce dernier est l'opérateur du marché ; il est le garant du bon fonctionnement du marché, il doit donc être indépendant des autres agents, établir des règles saines, gérer le système de transport de manière équitable et non discriminatoire, faciliter la couverture des outils de protection contre les risques du marché et surveiller le marché pour s'assurer qu'il est libre de tout pouvoir [Shahidehpour 2002]. 50

Les agents peuvent être à la fois des vendeurs et des acheteurs. La commodité principale est évidemment l'électricité, mais des services peuvent être vendus.

Les marchés de l'électricité sont souvent plus complexes que les marchés d'autres commodités, à cause du fait que l'électricité n'est pas économiquement stockable. L'électricité produite doit être utilisée, donc vendue, ou stockée (dans des systèmes de stockage comme les batteries) sinon elle est perdue. Mais, le stockage de l'électricité a un coût ; alors il peut être plus économique de vendre directement que de stocker et vendre plus tard, même si, le plus souvent, le marché est structuré de

sorte que le stockage soit économiquement viable.

- 51 La dérégulation du marché de l'électricité a permis d'avoir un marché concurrentiel, dans lequel des producteurs indépendants sont en compétition pour alimenter les consommateurs. Chaque producteur a sa fonction d'utilité, et tente de maximiser son profit (en se servant de tous les outils possibles), indépendamment du profit global sur le marché.

1.3.2 Les modèles de marché de l'électricité

- 52 Il existe plusieurs modèles de marché de l'électricité, nous n'en présentons brièvement que trois [Shahidehpour 2002] dans cette section et un — celui que nous considérons dans cette étude — dans la section suivante.

Modèle PoolCo : c'est un marché centralisé, dans lequel les acheteurs (resp. les vendeurs) enchérissent sur la quantité d'énergie qu'ils veulent, et le prix auquel ils souhaitent acheter (resp. vendre). Si un acheteur fait une enchère trop faible, il n'est pas sûr d'acheter. De même, si un vendeur fait une enchère trop élevée, il n'est pas sûr de vendre. Le gestionnaire de réseau reçoit toutes les enchères, détermine et fixe un prix (unique) appelé *prix d'équilibre du marché* — la plus grande enchère des vainqueurs — pour tous les agents. Ce modèle récompense essentiellement les producteurs peu chers.

Dans la pratique, les producteurs/consommateurs soumettent leurs enchères — sous la forme d'une série temporelle de paires (prix, quantité) — d'injection/soutirage d'électricité sur/du réseau. Le pas de temps (ou résolution temporelle) est généralement d'une heure ou 30 minutes, quelques fois d'une minute, et l'horizon de 24 heures. Le gestionnaire du marché (ou le gestionnaire de réseau) reçoit ces enchères et déduit les courbes de vente et achat agrégés en rangeant les offres de vente par ordre croissant des prix et les offres d'achat par ordre décroissant des prix. Si le réseau de transmission n'est pas pris en compte, l'intersection entre ces deux courbes définit le prix d'équilibre du marché. Les offres de vente de prix inférieur au prix d'équilibre du marché sont acceptées et les autres, rejetées. Sinon si le réseau de transmission est pris en compte, au lieu d'un prix unique, un prix sera déterminé pour chaque nœud du réseau électrique. La détermination de ces prix devra dépendre des facteurs techniques tels que la congestion et les pertes sur les lignes de transmission.

Modèle d'accès direct appelé aussi **modèle de contrats bilatéraux**: Dans ce modèle, deux agents (acheteur et vendeur) peuvent passer des contrats — dont ils définissent eux-mêmes les termes — sans passer par le gestionnaire de réseau. Ce dernier doit toutefois s'assurer que la capacité de transmission permet l'accomplissement de la transaction en toute sécurité.

Modèle hybride : ce modèle combine les fonctionnalités des deux autres. C'est un modèle dans lequel l'un ou l'autre des deux autres modèles peut être choisi par les agents. Les clients sont autorisés à négocier la fourniture d'électricité directement avec les fournisseurs ou choisir d'accepter ou pas le prix de compensation du marché.

Les marchés peuvent être également classés suivant la durée entre l'instant où l'enchère est soumise et l'instant où la production physique est réalisée, ou suivant le mode de paiement des producteurs. Les plus communs sont les suivants [Morales 2014] :

Les marchés *day-ahead* : certainement les plus répandus. Ce sont des marchés à court-terme dans lesquels les enchères sont faites (et le prix du marché est déterminé) la veille du jour de la production réelle.

Les marchés *intra-day* : ce sont des marchés à court-terme dans lesquels les agents peuvent ajuster leurs contrats day-ahead (éventuellement plusieurs fois), le jour de la fourniture. Aussi, on les appelle également *marchés d'ajustement*. Ils sont nécessaires pour augmenter la compétitivité de la production à partir de RES. En effet, puisque la production renouvelable est difficilement prévisible et très variable, la prévision la veille peut grandement changer le jour J. Sans la possibilité d'ajuster leur engagement — grâce à la mise à jour des données de prévision —, les producteurs ne pourraient potentiellement pas honorer leur engagement. Vu les pénalités qu'ils encourrent, ils ne seraient pas enclins à participer aux marchés de l'énergie.

Les marchés *d'équilibre* : ce sont des marchés temps-réel, dits « de dernier recours », car ils assurent l'égalité entre la production et la consommation en tout point du réseau. En effet, même la présence de marchés intra-day ne compensent pas totalement la forte variabilité des RES. Alors, pour maintenir l'équilibre du réseau, il faut des marchés dans lesquels des unités de secours flexibles peuvent être utilisées. On les appelle également marchés *de régulation*.

Les marchés *de capacité de secours* : ce sont des marchés temps-réel qui garantissent la disponibilité de suffisamment d'énergie pour équilibrer le réseau pendant son fonctionnement temps-réel.

Les marchés de capacité de secours s'apparentent aux marchés d'équilibre. Ce qui les différencie principalement est la fonction de rémunération des producteurs. Dans les premiers, la rémunération est proportionnelle à la capacité disponible, alors que dans les derniers (et les autres marchés susmentionnés), elle est proportionnelle à la fourniture/soutirage.

1.3.3 L'AOCRE ZNI

L'AOCREZNI¹ est un appel d'offres, lancé par la Commission française de régulation de l'énergie, portant sur la réalisation et l'exploitation d'installations de production d'électricité à partir de techniques de conversion du rayonnement solaire d'une puissance supérieure à 100 kWc et situées dans les zones non interconnectées (les îles françaises) [de Régulation de l'Energie (CRE France) 2015]. Notre étude a porté sur l'appel d'offres de l'année 2015. Les candidats sélectionnés s'engagent à fournir, sur le réseau, toute l'électricité produite ou à justifier une situation d'auto-consommation. Ils envoient leur engagement de production la veille au gestionnaire de réseau. Le gestionnaire de réseau, quant à lui, s'engage à acheter toute l'électricité

¹Appel d'Offres de la Commission de Régulation d'Énergie pour les Zones Non Interconnectées

que les producteurs se sont engagés à lui fournir. Les producteurs sont autorisés à acheter de l'électricité auprès du gestionnaire de réseau.

54 On a donc un marché de l'électricité dans lequel les agents sont les producteurs indépendants (les candidats sélectionnés) et le gestionnaire de réseau. Ce dernier fixe un prix, par producteur, (exprimé en €/kWh) en fonction de son offre. Une majoration de ce prix est prévue pour la période de pointe du soir, entre 19:00 et 21:00, pour les producteurs qui ont choisi de participer à cette pointe. Le gestionnaire de réseau a également fixé la fonction de profit journalier des producteurs.

Le producteur reçoit une rémunération qui est proportionnelle à sa production, à chaque instant de l'horizon. Le coefficient de proportionnalité étant le prix de l'électricité. Lorsque le producteur ne respecte pas son engagement, càd qu'à chaque instant de l'horizon, il fournit une quantité d'électricité supérieure (surproduction) ou inférieure (sousproduction), avec une tolérance de 5% de la puissance totale installée, il est pénalisé. Nous étudions cette fonction à la section 5.2.2 du chapitre 5.

55 Les producteurs, l'acheteur et la fonction de profit journalier restent fixes sur la durée d'existence du marché. Le prix de l'électricité est potentiellement mis à jour à chaque date d'anniversaire du contrat qui lie le producteur au gestionnaire de réseau, mais il est fixe pour chaque producteur et dépend de son offre initiale. Il n'y a donc pas réellement de compétition sur le marché. Néanmoins, chaque producteur tente de maximiser son utilité journalière.

Ce modèle de marché s'apparente au modèle PoolCo par le fait que le contrat lie le gestionnaire de réseau aux producteurs. Les producteurs ne peuvent pas faire de contrats avec les utilisateurs finaux. Mais, il n'implémente pas totalement le modèle PoolCo car il n'y a pas d'enchères. C'est surtout un marché day-ahead et intra-day. La veille, le producteur fournit le profil de production, appelé *déclaration*, qu'il s'engage à respecter le lendemain. En intra-day, càd le jour-J, le producteur peut ajuster son engagement 3 fois, appelé *redéclarations*. Il y a également un marché d'équilibre — pour la régulation de la fréquence et de la tension — mais ce marché est optionnel.

2

Littérature sur l'optimisation

Sommaire

- 2.1 Classification des méthodes d'optimisation
- 2.2 La programmation mathématique
- 2.3 Les métaheuristiques
- 2.4 L'optimisation sous incertitudes

Puisse chacun avoir la chance de trouver justement la conception de la vie qui lui permet de réaliser son maximum de bonheur.

Friedrich Nietzsche.

DANS L'ÉTUDE DES QUANTITÉS, nous sommes souvent intéressés de savoir quelle est la plus grande valeur (appelée *maximum*) ou plus petite valeur (appelée *minimum*) d'une suite ou collection de quantités.

La recherche des maxima et minima (ou, indifféremment, *optima*) occupe une place de choix en mathématique, et dans toutes les activités humaines. L'*optimisation* est la branche des mathématiques dédiée.

Un *problème d'optimisation* consiste à chercher la valeur optimale d'une fonction réelle — appelée *fonction objectif* ou *fonction coût* ou *profit* ou *fonction d'utilité* — sur un ensemble de définition généralement multi-dimensionnel et contraint, typiquement un sous-espace de \mathbb{R}^n défini par un vecteur de variables, dites de *décision* ou de *contrôle* et des relations analytiques sur ces variables, appelées *contraintes* qui doivent être toutes satisfaites. Les éléments de cet ensemble de définition sont appelés *solutions réalisables*, et *solutions optimales* si la fonction objectif y atteint sont optimum. Cette modélisation s'applique à une infinité de problèmes pratiques d'opération ou de conception de systèmes, où les variables figurent les états du système, et les contraintes, les diverses restrictions sur ces états, contraintes physiques ou opérationnelles.

Dans ce chapitre, nous faisons un tour des principales méthodes d'optimisation. Sans en faire une présentation exhaustive, nous donnons plus de détails des méthodes que nous avons utilisées dans cette étude: la programmation linéaire/quadratique en nombres entiers, les algorithmes génétiques, la programmation stochastique et robuste.

2.1 Classification des méthodes d'optimisation

On distingue un grand nombre de méthodes (ou techniques) d'optimisation. On 56 distingue de même plusieurs classifications de ces méthodes. Nous en présentons quelques-unes dans cette section.

La méthode la plus intuitive pour rechercher un optimum est d'évaluer la fonc- 57

tion objectif en les différents points de l'ensemble de définition. C'est la méthode d'*énumération exhaustive* quand la fonction est évaluée en tout point et l'optimum est déduit ainsi, mais elle est rarement applicable en pratique. Une alternative viable est l'évaluation de l'objectif en un sous-ensemble de points. Comme évoquées en introduction, les méthodes de type *boîte noire* telles que les *métaheuristiques* appliquent ce principe en faisant appel à différentes stratégies pour la construction de la famille de points à évaluer. Parmi ces méthodes, on peut citer les algorithmes évolutionnaires dont les stratégies simulent les évolutions naturelles du vivant: *algorithmes génétiques*, *évolution différentielle*, *algorithme mémétique*, *colonie de fourmis*, etc [Michalewicz 1994, Dasgupta 1997, Jong 1997, Dréo 2006]. Ces approches ne garantissent cependant pas l'obtention d'un optimum. Une seconde approche, dite *boîte blanche*, consiste à exploiter la structure analytique du problème et étudier le sens de variation de la fonction objectif, par des arguments de différentiabilité et/ou de séparation de l'espace de recherche notamment, pour atteindre un optimum par une évaluation implicite de la fonction objectif sur l'ensemble de définition. Cette approche ne converge en pratique, que si la structure analytique du problème est suffisamment simple.

- 58 En effet, la complexité algorithmique d'un problème d'optimisation dépend de la forme de la fonction objectif et des contraintes et de leurs caractéristiques en termes de différentiabilité et de convexité. On distingue premièrement deux grandes classes d'optimisation : l'*optimisation sous contraintes* et l'*optimisation non-contrainte* [Gill 1981, Fletcher 2000, Ravindran 2006, Chong 2013, Luenberger 2015]. Lorsque fonction objectif et contraintes s'expriment par des fonctions convexes (resp. linéaires), on parle de *programmation convexe (resp. linéaire)* [Luenberger 2015, Dantzig 1997, Bertsimas 1997, Dantzig 2003, Boyd 2004, Vanderbei 2014, Pan 2014]. Lorsque la fonction objectif est quadratique et les contraintes sont linéaires (resp. quadratiques), on parle de *programmation quadratique (resp. à contraintes quadratiques)*. Si toutes ou certaines variables ne prennent que des valeurs discrètes, on parle d'*optimisation combinatoire* ou de *programmation en nombres entiers* [Floudas 1995, Martin 1999, Aardal 2005, Lee 2012, Arora 2015]. Ces modèles sont fréquents car ils permettent, notamment grâce aux variables binaires 0/1, l'expression de conditions logiques. L'optimisation combinatoire est un cas tout à fait particulier de l'optimisation non-convexe (donc difficile) avec ces techniques de résolution propres. Le terme "*programmation*" est utilisé en lieu et place du terme "*optimisation*". Ce terme n'est pas en lien avec la programmation informatique, mais comme synonyme de "*planification*".
- 59 Le *contrôle optimal* est une branche spécifique de l'optimisation qui concerne la recherche d'une commande, une suite chronologique d'actions, optimale pour un critère de performance donné et permettant à un système d'atteindre un état final, cela connaissant la loi de transition d'état du système. Parmi les méthodes qui y sont employées, on peut citer la *programmation dynamique*, l'*apprentissage par renforcement (reinforcement learning)*, en anglais et le *contrôle prédictif (Model Predictive Control ou MPC)*, en anglais). Les méthodes plus générales d'optimisation, metaheuristiques ou programmation mathématique si la loi de transition est suffisamment régulière, peuvent également être appliquées à ces problèmes particuliers (variables d'état et de contrôle sont alors considérées indifféremment comme des variables de décision). Inversement, la programmation dynamique n'est pas limitée au cadre du contrôle;

elle est notamment très usitée dans les problématiques d'optimisation statique de transport.

Dans le chapitre 1, nous avons parlé des microgrids et de leur contrôle. Nous avons dit que la plupart des fonctionnalités d'un EMS sont basées sur l'optimisation. L'EMS conventionnel réalise cette optimisation dans un environnement où les données de production sont supposées connues: ce type d'optimisation est appelé *programmation déterministe*. Dans le cadre du contrôle, il s'agit d'une *optimisation en temps réel* où l'on doit faire, rapidement, le choix d'une commande en estimant, de manière approximative, l'état futur du système. Comme l'état observé du système après application de la commande peut différer de l'état estimé, il peut être nécessaire de relancer régulièrement l'optimisation, dans une boucle de contrôle, afin de réparer cette erreur. C'est ce que nous avons mis en place dans nos solutions.

Par ailleurs, l'intégration des générateurs à ressources renouvelables dans les microgrids introduit un autre facteur aléatoire. La production des RES étant variable et difficilement prévisible, l'EMS doit aussi prendre en compte les incertitudes sur les données prévisionnelles de production: cela relève de l'*optimisation sous incertitudes*. Celle-ci est scindée en deux courants : la *programmation stochastique*, qui part de l'hypothèse que la loi de probabilité que suit chacune des variables incertaines est connue, et la *programmation robuste*, qui cherche à trouver la décision optimale dans un pire cas de réalisation des variables incertaines. S. Twahaa *et al* [Twahaa 2018] et Luis I. Minchala-Avilaa *et al* [Minchala-Avilaa 2015] ont réalisé un état de l'art assez complet sur l'utilisation des méthodes d'optimisation pour le contrôle optimal des microgrids. Il en ressort que toutes les méthodes indiquées ci-dessus sont utilisées.

2.2 La programmation mathématique

Nous considérons le modèle général de programmation mathématique suivant:

$$OP := \begin{cases} z^* = \min_{\mathbf{x} \in X \subset \mathbb{R}^n} f_0 \\ \text{s.t. } f_i(\mathbf{x}) \leq 0 \end{cases}$$

Le problème 2.1 est écrit comme un problème de minimisation. Le but est de trouver une *solution réalisable*, i.e. une solution $\mathbf{x}^* \in X \subset \mathbb{R}^n$ satisfaisant l'ensemble des contraintes d'inégalités (2.1a), telle que la fonction objectif f_0 y atteint sa valeur minimale. Notez au passage l'équivalence entre problèmes de minimisation et de maximisation :

$$\min_{\mathbf{x}} f(\mathbf{x}) = - \max_{\mathbf{x}} (-f(\mathbf{x})) \quad (2.2)$$

Le problème 2.1 peut ne pas être réalisable ($z^* = +\infty$) si l'ensemble des solutions réalisables est vide, ou ne pas être borné ($z^* = -\infty$) s'il admet au moins une solution réalisable mais aucune solution optimale.

2.2.1 Programmation linéaire et programmation quadratique convexe

Le programme 2.1 est dit linéaire si la fonction objectif f_0 est linéaire et les fonctions $f_i, 1 \leq i \leq m$ sont affines. Soit \mathbf{x} un vecteur de \mathbb{R}^n tel que $\mathbf{x} = (x_1, x_2, \dots, x_n)$.

Rappelons qu'une fonction affine f s'écrit $f(\mathbf{x}) = c_1x^1 + c_2x^2 + \dots + c_nx^n + d$ ou sous forme vectorielle $f(\mathbf{x}) = \mathbf{c}^T\mathbf{x} + d$ avec $\mathbf{c} = (c_1, c_2, \dots, c_n)$ un vecteur de \mathbb{R}^n et d une quantité réelle, avec $d = 0$ dans le cas où f est linéaire. L'exposant T dénote la *transposée*.

Un problème linéaire peut donc s'écrire comme suit :

$$LP := \begin{array}{ll} \min_{\mathbf{x} \in \mathbb{R}^n} & c_1x^1 + c_2x^2 + \dots + c_nx^n & (2.3) \\ \text{s.t.} & a_{11}x^1 + a_{12}x^2 + \dots + a_{1n}x^n = b_1 & (2.3a) \\ & a_{21}x^1 + a_{22}x^2 + \dots + a_{2n}x^n = b_2 & (2.3b) \\ & \dots & (2.3c) \\ & a_{k1}x^1 + a_{k2}x^2 + \dots + a_{kn}x^n = b_k & (2.3d) \\ & a_{k+1,1}x^1 + a_{k+1,2}x^2 + \dots + a_{k+1,n}x^n \geq b_{k+1} & (2.3e) \\ & \dots & (2.3f) \\ & a_{m1}x^1 + a_{m2}x^2 + \dots + a_{mn}x^n \geq b_m & (2.3g) \end{array}$$

Avec $a_{ij} \in \mathbb{R}$ ($1 \leq i \leq m, 1 \leq j \leq n$) et $b_i \in \mathbb{R}$ ($1 \leq i \leq m$).

65 En utilisant la notation matricielle et le fait qu'une inégalité peut être transformée en égalité en ajoutant une variable d'écart, nous pouvons écrire le programme linéaire sous forme standard :

$$PL := \begin{array}{ll} \min_{\mathbf{x} \in \mathbb{R}^n} & \mathbf{c}^T\mathbf{x} & (2.4) \\ \text{s.t.} & \mathbf{Ax} = \mathbf{b} & (2.4a) \\ & \mathbf{x} \geq 0 & (2.4b) \end{array}$$

Avec \mathbf{A} une matrice réelle de taille $m \times n$, \mathbf{x} un vecteur de \mathbb{R}^n et \mathbf{b} un vecteur de \mathbb{R}^m . L'expression $\mathbf{x} \geq 0$ signifie que chaque composante x_i du vecteur \mathbf{x} est supérieure ou égale à 0 ($x_i \geq 0$, $1 \leq i \leq n$). Elle est appelée *hypothèse de non-négativité*.

66 Tout programme linéaire 2.4 possède les trois (3) caractéristiques suivantes :

Proportionnalité : Si une variable du problème est multiplié par une quantité constante, sa contribution dans la fonction objectif et dans les contraintes est également multipliée par la même constante.

Additivité : (ou séparabilité) La valeur de la fonction objectif et des fonctions contraintes est égale à la somme algébrique des contributions de chaque variable. Il n'y aucune relation entre les variables autre que l'addition (et la soustraction). Cela veut également dire que ces valeurs sont additivement séparables en ces variables.

Continuité : (ou divisibilité) Chaque variable peut prendre toutes les valeurs de l'ensemble des réels ou d'un de ses sous-ensembles. Ces ensembles sont donc indénombrables (potentiellement finis).

67 Il y a une littérature extensive sur la programmation linéaire et cette méthode

jouit de fondements théoriques très solides. Le pionnier de cette classe d'optimisation est le mathématicien George Dantzig qui a caractérisé la structure géométrique et algébrique des programmes linéaires et a développé l'algorithme du *simplexe* pour les résoudre. D'autres méthodes de complexité polynomiale ont plus tard été développées, telles que les algorithmes de point intérieur et de Karmarkar. L'algorithme du simplexe et ses variantes restent les plus utilisés grâce à leur performance en général et ce malgré leur complexité théorique exponentielle.

Géométriquement, l'ensemble des solutions d'un PL est délimité par des plans (définis par les inégalités linéaires) et appelé un *polyèdre*. On montre aisément qu'il est convexe: le segment entre deux éléments de cet ensemble appartient également à cet ensemble. Par convexité, la fonction objectif (linéaire et donc convexe) d'un PL atteint son minimum, si borné, en un des sommets du polyèdre.

Un résultat fondamental de la programmation linéaire et le théorème de dualité forte: l'optimum du programme linéaire 2.4, s'il existe, est égal à l'optimum du programme linéaire de maximisation suivant, dit *programme dual*:

$$D := \left| \begin{array}{l} \max_{\mathbf{u} \in \mathbb{R}^m} \mathbf{u}^T \mathbf{b} \\ \text{s.t. } \mathbf{u}^T \mathbf{A} \leq \mathbf{c}^T \end{array} \right. \quad (2.5)$$

$$(2.5a)$$

En programmation quadratique, les contraintes sont linéaires mais la fonction 68 objectif peut intégrer des produits de variables. La forme générale est la suivante:

$$QP := \left| \begin{array}{l} \min_{\mathbf{x} \in \mathbb{R}^n} Q(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{H} \mathbf{x} + \mathbf{c}^T \mathbf{x} \\ \text{s.t. } \mathbf{A} \mathbf{x} = \mathbf{b} \end{array} \right. \quad (2.6)$$

$$(2.6a)$$

Avec $\mathbf{H} \in \mathbb{R}^{n \times n}$, $\mathbf{A} \in \mathbb{R}^{m \times n}$, $\mathbf{c} \in \mathbb{R}^n$ et $\mathbf{b} \in \mathbb{R}^m$. La fonction objectif (2.6) est convexe si et seulement si la matrice H est symétrique positive semi-définie, càd $\forall x, \mathbf{x}^T \mathbf{H} \mathbf{x} \geq 0$. Si les problèmes quadratiques sont NP-difficiles en général, ils sont, dans le cas convexe, de complexité polynomiale et les raisonnements et algorithmes de la programmation linéaire se généralisent directement dans ce cas.

2.2.2 Programmation linéaire en nombres entiers

Il est très souvent nécessaire dans les problèmes d'optimisation pratique, de modéliser des choix discrets, notamment binaires. Par exemple, à la question "Doit-on démarrer le générateur diesel à 20h?", la réponse est soit "Oui", soit "Non", mais pas "à 15%" ou "à 30%", etc. Cette décision associée au démarrage du générateur peut-être modélisée par une variable à valeurs dans l'ensemble \mathbb{Z} des entiers, en l'occurrence ici 0 ou 1. On parle ici de variable *binaire* ou *booléenne*. Un programme linéaire intégrant des variables booléennes ou entières est appelé généralement *programme linéaire en nombres entiers*. Nous adoptons dans ce document l'abréviation anglaise MILP (Mixed-Integer Linear Program).

Un MILP peut être formulé de manière générale comme suit (avec $p \leq n$):

$$MILP := \begin{cases} \min_{\mathbf{x}} \mathbf{c}^T \mathbf{x} & (2.7) \\ \text{s.t. } \mathbf{Ax} = \mathbf{b} & (2.7a) \\ x_i \geq 0 (1 \leq i \leq n) & (2.7b) \\ x_i \in \mathbb{Z} (1 \leq i \leq p) & (2.7c) \end{cases}$$

71 Si objectif et contraintes sont bien linéaires, le MILP général 2.7 ne vérifie pas le critère de continuité, défini au paragraphe 66, de la programmation linéaire. L'ensemble des solutions réalisables n'est notamment pas convexe et le problème est NP-difficile en général. Les résultats de programmation linéaire peuvent cependant être exploités pour résoudre ce problème, en considérant restrictions et relaxations de 2.7 qui sont des programmes linéaires: la *restriction linéaire* est obtenue en fixant l'ensemble des variables entières (à des valeurs entières de leur domaine) et la *relaxation linéaire ou continue* est obtenue en *relâchant*, i.e. en supprimant, la *contrainte d'intégrité* (2.7c). La première retourne une borne supérieure de l'optimum de 2.7 et la seconde, une borne inférieure.

Les algorithmes de résolution de MILP sont essentiellement basés sur la recherche d'encadrement de l'optimum par restrictions et relaxations, notamment l'algorithme de résolution optimale *branch-and-bound*. Cet algorithme repose sur l'énumération progressive des solutions entières (considérant ainsi des restrictions partielles) et sur l'évaluation implicite de ces restrictions partielles par relaxation linéaire. En effet, l'énumération complète exhaustive de toutes les solutions entières est une méthode naïve qui n'est applicable que si le nombre de variables entières p est très limité du fait de phénomène de l'explosion combinatoire. Pour seulement $p = 30$ variables binaires, par exemple, il existe 2^{30} solutions binaires, soit plus d'un milliard de restrictions linéaires à évaluer. Le branch-and-bound est donc une procédure itérative qui, à chaque itération, sépare l'espace de recherche courant en fixant une des variables entières du problème (non précédemment fixée) à chacune des valeurs de son domaine de définition. Chaque sous-problème définit ainsi un *nœud* et une *branche* d'un arbre de recherche correspondant à une instanciation partielle des variables entières. Si on générerait l'arbre entier sans conditions, ce serait une énumération totale. Pour éviter cela, on évalue progressivement chaque nœud/sous-problème construit en résolvant la relaxation continue associée. En effet, la valeur optimale de la relaxation continue à un nœud (éventuellement égale à $+\infty$ si irréalisable) fournit une borne inférieure de la valeur de la meilleure solution entière contenue dans la branche issue de ce nœud. On compare alors cette borne inférieure (BI) avec la plus petite borne supérieure (BS) globale connue, donnée par la valeur de la meilleure solution entière déjà visitée, appelée l'*incumbent*. Trois cas sont possibles: (1) si la valeur BI de la relaxation est supérieure ou égale est la valeur BS de l'*incumbent* alors cette branche ne contient pas de solution strictement meilleure que l'*incumbent* et on arrête son exploration; (2) sinon, si la relaxation possède une solution optimale qui est entière alors il s'agit de la meilleure solution entière dans cette branche, et on l'enregistre comme nouvel *incumbent*; (3) sinon, on continue l'exploration de la branche en la séparant de nouveau le nœud.

Le branch-and-bound est la base de résolution dans la majorité des solveurs

MILP actuels, commerciaux ou non. Il est généralement associé à diverses procédures de prétraitement et de génération de contraintes (dites *coupes*, on parle alors de branch-and-cut) pour renforcer le modèle mathématique et améliorer les valeurs de bornes inférieures associées à la relaxation continue. Les branch-and-bounds modernes sont également équipés d'heuristiques sophistiquées diverses pour choisir la prochaine variable à brancher, l'ordre des nœuds à visiter, les coupes à générer/-supprimer du modèle linéaire, ou encore des heuristiques primales pour calculer des solutions entières à partir des solution relâchées et améliorer ainsi le calcul de borne supérieure. Tous ces ingrédients intégrés dans les solveurs modernes, ainsi que les implémentations distribuées de cet algorithme, font qu'il est possible aujourd'hui de résoudre à l'optimum des MILP de très grandes tailles en des temps limités malgré la complexité théorique de ces problèmes.

Pour les problèmes plus gros ou quand la relaxation linéaire seule est difficile à résoudre, il existe des procédures basées sur la décomposition du modèle. Pour résoudre le modèle robuste de calcul d'engagement, nous appliquons l'une de ces procédures: la décomposition de Benders. Cette méthode évalue de manière itérative les restrictions linéaires – ou plus exactement leurs duals – associées à des instanciations complètes des variables entières. La résolution retourne une borne supérieure. De plus, les concepts de dualité permettent de déduire, de chaque résolution, une nouvelle contrainte, qui sera intégrée au modèle linéaire à l'itération suivante afin d'éliminer de la recherche future à la fois la solution entière qui vient d'être évaluée mais aussi d'autres solutions entières comparables. La solution entière à évaluer à l'itération suivante est obtenue en résolvant un MILP simplifié mais qui intègre l'ensemble des contraintes duals précédemment générées. La résolution fournit une borne inférieure, strictement croissante à chaque itération, ce qui assure la converge théorique de l'algorithme vers un optimum en un nombre fini d'itérations. Nous reviendrons plus en détail sur cette approche dans la section 7.2.2.

2.3 Les métaheuristiques

2.3.1 Les métaheuristiques

Les métaheuristiques sont des méthodes (directes) de recherche « stochastique » et « itérative » d'une solution réalisable de bonne qualité d'un problème d'optimisation. La recherche est stochastique (ou aléatoire) car l'agent qui effectue la recherche, dans l'espace de solutions, peut aller dans des directions imprévisibles, dans un but de diversification des solutions testées. La recherche itérative permet a contrario d'intensifier l'exploration des parties de l'espace de recherche les plus prometteuses, i.e. dans lesquelles se trouvent les meilleures solutions au sens du critère d'optimalité. La procédure est repétée jusqu'à ce qu'un certain critère d'arrêt (temps, nombre d'itération, amélioration, etc.) soit satisfait.

Les métaheuristiques reposent sur la capacité d'évaluer rapidement la réalisabilité et le coût d'une solution donnée. Ainsi, si elles ne garantissent pas de converger vers des solutions optimales, les métaheuristiques permettent souvent en pratique de les atteindre ou de s'en approcher, en effectuant, en un temps limité, l'évaluation d'une multitude de solutions potentielles. Les grandes familles de métaheuristiques

diffèrent sur la manière d'explorer l'espace de recherche, et de choisir les solutions à évaluer d'une itération à l'autre.

- 73** Les algorithmes évolutionnaires sont notamment basés sur l'évolution d'une *population* de solutions. À chaque itération de l'algorithme, la population de solutions à évaluer est générée à partir de la génération précédente, par clonage, couplage, ou altération des *individus*. La raison de l'utilisation d'une population d'individus (solutions) est évidente : augmenter la probabilité de trouver « rapidement » la solution globale. Pour y arriver, il faut nécessairement que la population soit bien diversifiée, sinon on augmente le risque d'être piégé par un optimum local. L'évaluation des individus se fait de manière indépendante et donc peut être distribuée sur plusieurs processeurs. Pour certains problèmes, il est parfois possible d'accélérer l'évaluation d'un individu en exploitant l'évaluation réalisée à une itération précédente des individus dont il est issu.
- 74** Les métaheuristiques diffèrent des heuristiques en ce sens qu'elles ne sont pas conçues pour un problème spécifique. Elles s'appliquent à tout type de problèmes d'optimisation et, contrairement à la programmation mathématique par exemple, elles ne nécessitent aucune caractéristique analytique (convexité, linéarité, etc.) des modèles. Elles peuvent ainsi facilement intégrer un simulateur numérique pour l'évaluation des solutions. Toutefois, elles peuvent être difficiles à configurer car elles font usage d'un grand nombre de paramètres. De plus, les temps de résolution peuvent devenir considérables pour trouver une solution de bonne qualité quand l'espace de solutions est grand et que l'évaluation individuelle des solutions (par simulation notamment) est coûteuse [Dréo 2006].

2.3.2 Les algorithmes génétiques

Présentation générale

- 75** Principaux représentants des algorithmes évolutionnaires, les algorithmes génétiques simulent l'évolution du vivant et les notions d'adaptabilité et d'hérédité. C'est John Holland qui, entre la fin des années 60 et le début des années 70, en a développé les bases.

Une population d'individus (ou de *chromosomes*) de taille constante est considérée à chaque itération. Au début de l'exécution, une population initiale $P(0)$ est générée, aléatoirement, par heuristique, ou par une connaissance experte. Chaque individu représente une solution potentielle du problème d'optimisation. Ces individus sont évalués à travers d'une fonction de *mérite*, qui est généralement la fonction objectif, et la valeur obtenue pour chaque individu est appelée *fitness* de l'individu. Les individus de $P(0)$ passent par une étape de *sélection* dans laquelle (généralement) les individus ayant une performance supérieure à la moyenne ont plus de chance d'être sélectionnés que ceux ayant une performance pire que la moyenne. Les individus sélectionnés, formant une sous-population $M(0)$, sont candidats pour l'étape de *reproduction*. Cette étape consiste à faire subir aux individus des transformations génétiques afin d'engendrer de nouveaux individus : leur progéniture. Parmi ces transformations, les plus importantes sont la *recombinaison*, qui consiste à tirer aléatoirement deux (ou plusieurs) individus et à les combiner (d'une certaine manière) de sorte à générer deux (ou plusieurs) individus, et la *mutation* qui consiste

à tirer aléatoirement un individu et à le modifier génétiquement de sorte à générer deux individus. Une nouvelle population $P(1)$ est créée à l'issue des étapes de sélection et de reproduction. À ce stade, une attention particulière doit être observée afin de maintenir la taille de la population. La population $P(1)$ est ensuite évaluée et le processus reprend jusqu'à ce qu'une condition d'arrêt soit vérifiée [Chong 2013]. Le plus souvent la condition d'arrêt est un nombre défini d'itérations, mais on peut la définir par des critères de convergence. Au terme de cette boucle d'optimisation, l'individu (ou les individus) ayant les meilleurs fitness sont retournés. Ils représentent les solutions de l'optimisation.

Nous venons ainsi de décrire littéralement le fonctionnement général d'un algorithme génétique. Dans la section 75, nous donnons une description plus détaillée.

Description détaillée

Algorithm 1 Structure d'un algorithme évolutionnaire

```

1: function EVOLUTION-PROG( $P$ )
2:    $f \leftarrow \text{eval}(P)$ 
3:   if termination-condition( $f, P$ ) then
4:     return get-optimum( $f, P$ )
5:   else
6:      $M \leftarrow \text{select}(P)$ 
7:      $P \leftarrow \text{reproduct}(M)$ 
8:     EVOLUTION-PROG( $P$ )
9:   end if
10: end function
```

L'algorithme 1 montre la structure générale d'un algorithme évolutionnaire. Il a été exprimé sous forme d'une fonction récursive qui prend en argument la population initiale. Il prend également des paramètres spécifiques au type d'algorithme évolutionnaire. Dans la suite, nous parlons des paramètres les plus importants de l'algorithme génétique. Passons à la description de l'algorithme 1, ligne par ligne, appliquée à l'algorithme génétique.

Ligne 0: Choix de la représentation et génération de la population initiale

Il n'y a pas de ligne 0 dans l'algorithme. Elle désigne juste l'étape préliminaire avant l'exécution de l'algorithme.

Un individu étant une solution potentielle du problème, il symbolise l'ensemble des variables d'optimisation. Sa représentation est donc un aspect important de l'algorithme génétique. En effet, la performance de ce dernier en dépend grandement.

La représentation la plus adoptée et aussi la plus ancienne est la représentation *binaire* : chaque individu est vu comme une longue chaîne de caractères binaires (ou *bits*), c'est une chaîne de 0 et 1. Cette chaîne encode chaque variable, l'une à la suite de l'autre. Dans la seconde représentation, un individu est vu comme un *vecteur de nombres réels* ; chaque élément du vecteur étant une valeur d'une variable d'optimisation. La représentation binaire est la plus intuitive mais elle n'est

pas très appropriée quand les variables ont des valeurs réelles [Michalewicz 1994, Chong 2013]. Nous avons donc adopté la représentation réelle dans cette étude.

79 Après avoir choisi la représentation des individus, on génère la population initiale de l'algorithme génétique, de taille $POPSIZE$. Comme on l'a dit plus haut, cette génération peut être aléatoire ou en utilisant des connaissances expertes.

Pour la suite, on note par ν_i ($i = 1, \dots, POPSIZE$) un individu de la population.

Ligne 2: Évaluation de la population

80 Chaque individu de la population est évalué à travers la fonction objectif et l'ensemble des fitness est retourné. Si on note par f la fonction objectif, on pourrait représenter l'ensemble des valeurs de fitness par un vecteur $[f_1, \dots, f_{POPSIZE}]$ où $f_i = f(\nu_i)$ ($i = 1, \dots, POPSIZE$).

Lignes 3-4: Test de la condition d'arrêt et retour de l'optimum

81 Après l'évaluation de la population, on teste s'il est nécessaire de continuer le processus d'évolution ou si on peut arrêter. La condition d'arrêt la plus utilisée est un nombre constant d'itérations, $NGEN$; mais on peut utiliser un critère de convergence si on connaît approximativement la valeur optimale du problème. On peut même combiner ces deux approches.

Si la condition d'arrêt est vérifiée, le processus s'arrête et on retourne l'optimum (ou les optima) et leur fitness. Sinon, on continue le processus.

Ligne 6: Sélection des candidats à la reproduction

82 La *roulette* (ou *roue de la fortune*) et le *tournoi* sont les méthodes communes de sélection. Expliquons comment la roulette fonctionne.

La sélection par roulette est faite en fonction de la distribution de probabilité des valeurs de fitness. La roulette est construite comme suit¹:

- déterminer la fitness totale de la population : $F = \sum_{i=1}^{POPSIZE} f_i$;
- calculer la fitness relative (probabilité d'être sélectionné) de chaque individu ν_i ($i = 1, \dots, POPSIZE$) : $p_i = f_i/F$;
- calculer la probabilité cumulative de chaque individu ν_i ($i = 1, \dots, POPSIZE$) : $q_i = \sum_{i=1}^{POPSIZE} p_i$.

La procédure de sélection est basée sur la rotation de la roulette $POPSIZE$ fois; à chaque rotation, on sélectionne un seul individu (candidat pour la reproduction) de la manière suivante :

- générer un nombre réel aléatoire r dans l'intervalle $[0, 1]$;
- if $r < q_1$, alors sélectionner le « premier » individu ν_1 , sinon sélectionner le $i^{\text{ème}}$ individu ν_i ($i = 2, \dots, POPSIZE$) tel que $q_{i-1} \leq r \leq q_i$.

Il ressort de ce mode de sélection que certains individus pourraient être sélectionnés plus d'une fois. On remarque aussi que cette méthode conserve la taille de la population.

Ligne 7: Reproduction

Cette étape comporte deux sous-étapes : la recombinaison (ou *crossover*) et la mutation. Ce sont des opérations génétiques qui modifient les individus de la population sélectionnée — appelés *parents* — pour engendrer de nouveaux individus — appelés *enfants* ou *progéniture*. 83

Crossover : C'est une opération durant laquelle deux individus, sélectionné aléatoirement, sont combinés (d'une certaine manière) pour engendrer deux enfants. La probabilité de crossover p_c est un paramètre de l'algorithme qui donne le nombre attendu, $p_c \times \text{POPSIZE}$ d'individus qui subiront l'opération. Voici la procédure :

- générer un nombre réel aléatoire r dans l'intervalle $[0, 1]$;
- if $r < p_c$, alors sélectionner l'individu pour le crossover.

Notez que la procédure doit être développée de sorte que si le nombre d'individus sélectionnés est **impair**, un individu — choisi aléatoirement — soit ajouté ou supprimé. La manière de recombiner chaque deux individus dépend de la représentation choisie. Dans le cas de la représentation binaire, supposons que les deux individus sont représentés par les chaînes binaires :

$$(b_1 b_2 \cdots b_{\text{pos}} b_{\text{pos}+1} \cdots b_m) \text{ et } (c_1 c_2 \cdots c_{\text{pos}} c_{\text{pos}+1} \cdots c_m)$$

où les b_i et c_i sont des valeurs 0 ou 1, m est la longueur de la chaîne et pos est un entier tiré aléatoirement dans l'intervalle $[1, m - 1]$, qui spécifie le point de recombinaison. Les individus précédents engendrent les individus suivants :

$$(b_1 b_2 \cdots b_{\text{pos}} \mathbf{c}_{\text{pos}+1} \cdots \mathbf{c}_m) \text{ et } (c_1 c_2 \cdots c_{\text{pos}} \mathbf{b}_{\text{pos}+1} \cdots \mathbf{b}_m)$$

Comme on peut le voir, la sous-chaîne d'un individu a été remplacé dans l'autre individu et vice-versa.

Dans le cas de la représentation réelle, on peut utiliser la *moyenne arithmétique*, qui consiste pour deux parents x et y , à générer un enfant $z = (x+y)/2$ et ce dernier remplace un des parents ou à générer deux enfants $z_1 = (x+y)/2 + w_1$ et $z_2 = (x+y)/2 + w_2$, où w_1 et w_2 sont deux quantités générées aléatoirement. On peut également utiliser la *combinaison convexe* des parents x et y pour générer $z_1 = \lambda x + (1 - \lambda)y$ et $z_2 = (1 - \lambda)x + \lambda y$, où λ est un nombre réel généré aléatoirement dans $[0, 1]$ [Chong 2013].

La combinaison convexe a l'avantage qu'elle génère des individus qui sont directement dans l'espace des solutions réalisables, contrairement à la moyenne arithmétique qui pourrait générer des individus hors de cet espace.

Mutation : C'est une opération qui consiste à altérer un individu choisi aléatoirement. La procédure dépend également de la représentation des individus.

Si les individus sont des chaînes binaires de taille m , l'opération est réalisée par bit. La probabilité de mutation p_m permet d'obtenir le nombre attendu de bits mutés : $p_m \times m \times \text{POPSIZE}$. Dans la méthode de mutation dite *uniforme*,

¹On suppose que les valeurs de fitness sont positives. Si elles peuvent être négatives, un mécanisme de mise à l'échelle pour les rendre positives peut être employé [Michalewicz 1994].

chaque bit, de chaque individu, a la même chance de subir une mutation, càd de voir son bit passer de 0 à 1 ou vice-versa. Voici la procédure :

- générer un nombre réel aléatoire r dans l'intervalle $[0, 1]$;
- if $r < p_m$, alors muter le bit.

Dans le cas de la représentation réelle, la méthode la plus simple est, à partir d'un parent x , de produire un individu $x' = x + w$, où w est une quantité aléatoire. Mais l'individu généré pourrait être hors de l'espace des solutions réalisables. Une autre méthode est de générer un individu qui est la combinaison convexe de x et d'un autre individu w généré aléatoirement dans l'ensemble des solutions réalisables, soit $x' = \lambda x + (1 - \lambda)w$. Cette fois, l'individu est directement compris dans cet ensemble.

- 84 Quoique non explicitement mentionné dans l'algorithme 1, il peut être utile de sauvegarder, à chaque génération, le meilleur individu jusqu'à là. De cette façon, l'algorithme retournerait la meilleure valeur obtenue au cours de tout le processus plutôt que la meilleure valeur de la population finale.

2.4 L'optimisation sous incertitudes

- 85 Jusqu'ici, l'approche que nous avons (implicitement) employée suppose que tous les paramètres, intervenant dans le problème, sont connus (ou peuvent être estimés) avec certitude. Cette approche est dite *déterministe*. Bien qu'elle convienne dans bien des cas (par exemple le problème de dispatch de la production des centrales thermiques), elle n'est pas réaliste dans d'autres cas (par exemple, le problème de dispatch de la production des microgrids à RES). En effet, dans ces derniers, certains paramètres ne peuvent être déterminés avec certitude car ils dépendent de facteurs hors de contrôle de l'homme. C'est notamment le cas de la plupart des sources d'énergie renouvelables. L'ensoleillement instantané, la vitesse du vent ou la force des marées, dépendent de facteurs naturels que, en l'état actuel de la recherche, nous ne savons pas prédire avec certitude. On dit qu'elles sont *incertaines*, *aléatoires* ou encore *stochastiques*. Dans ce contexte, la valeur que nous supposons pour une variable aléatoire est appelée valeur *prédictive* ou *prévue* et la valeur réelle de cette variable est appelée valeur *réalisée* ou *réalisation* de la variable.

- 86 On peut très bien résoudre les problèmes, faisant intervenir des paramètres stochastiques, en supposant que ces paramètres sont connus avec certitude. Cependant, en situation réelle, si ces paramètres prennent des valeurs totalement différentes de celles que nous avons supposées, la solution optimale que nous avions trouvée pourrait ne plus l'être : elle pourrait juste être réalisable voire ne même pas l'être. Cette dernière situation est problématique car elle pourrait avoir un coût énorme dans des situations où la réalisabilité est critique.

Il est donc parfois nécessaire de considérer des problèmes sous leur aspect stochastique. Cette approche est appelée *optimisation sous incertitudes*. En effet, toutes les méthodes d'optimisation, que nous avons vues, peuvent avoir leurs versions stochastiques. Mais nous nous limitons à la programmation linéaire dans notre présentation.

On distingue deux principaux courants d'optimisation sous incertitudes : la programmation *stochastique* et la programmation *robuste*.

2.4.1 La programmation stochastique

C'est certainement l'approche la plus intuitive. On estime que la valeur de chaque variable aléatoire du problème suit une loi mathématique précise, qu'on appelle *loi de probabilité*. Les lois de probabilité les plus utilisées sont la loi uniforme, la loi normale (ou loi de Gauss), la loi beta et la loi de Weibull. Ce choix dépend de la nature de la variable. 87

Soit W une *variable aléatoire* suivant une loi de probabilité \mathcal{L} (on note $W \rightsquigarrow \mathcal{L}(\cdot)$, où \cdot représente les paramètres de la loi). Soit $W_\omega = W(\omega)$ la valeur prise par W à chaque expérience (ou scénario) $\omega \in \Omega$ où Ω est un ensemble fini dénombrable². Grâce aux paramètres de la loi \mathcal{L} , il est possible de déterminer plusieurs indicateurs liés à la variable aléatoire tels que sa *variance*, son *écart-type* et son *espérance mathématique*. Ce dernier étant le plus important dans cette approche. En effet, il indique la valeur que W est plus susceptible de prendre si on répète plusieurs fois l'expérience de réalisation de la variable (la mesure, par exemple). On l'appelle aussi *valeur moyenne* de la variable aléatoire. 88

L'espérance mathématique s'exprime comme suit :

$$\mathbb{E}[W] = \sum_{\omega \in \Omega} W_\omega p_\omega \quad (2.8)$$

Où p_ω est la probabilité que W prenne la valeur W_ω ($0 \leq p_\omega \leq 1$ et $\sum_{\omega \in \Omega} p_\omega = 1$).

En général, lorsqu'une fonction f dépend d'une variable aléatoire W_ω , elle devient elle-même une variable aléatoire et son espérance mathématique est liée à W_ω par la relation suivante :

$$\mathbb{E}[f] = \sum_{\omega \in \Omega} f(W_\omega) p_\omega \quad (2.9)$$

La relation 2.9 est importante dans la mesure où, en général, on est amené à déterminer l'espérance mathématique d'une variable aléatoire dont on n'a pas la distribution de probabilité mais qui est fonction d'une autre variable aléatoire dont on connaît la distribution de probabilité. C'est le cas des problèmes d'optimisation sous incertitudes où la fonction objectif et/ou les contraintes sont des fonctions de variables aléatoires, quoique, dans ce cas, c'est seulement l'espérance mathématique de la fonction objectif qui soit d'intérêt.

Soit le problème linéaire « stochastique » 2.10 obtenu en remplaçant les paramètres (\mathbf{A} , \mathbf{c} et \mathbf{b}), supposés certains, du problème linéaire 2.4 par les paramètres \mathbf{A}_ω , \mathbf{c}_ω et \mathbf{b}_ω , fonctions d'une variable aléatoire ω (avec $\mathbf{A}_\omega = \mathbf{A}(W_\omega)$, $\mathbf{c}_\omega = \mathbf{c}(W_\omega)$ et $\mathbf{b}_\omega = \mathbf{b}(W_\omega)$). 89

$$PLS(\omega) := \begin{cases} \min_{\mathbf{x} \in X \subset \mathbb{R}^n} \mathbf{c}_\omega^T \mathbf{x} & (2.10) \\ \text{s.t. } \mathbf{A}_\omega \mathbf{x} = \mathbf{b}_\omega & (2.10a) \\ \mathbf{x} \geq 0 & (2.10b) \end{cases}$$

Le problème 2.10 dépend du scénario $\omega \in \Omega$. Il est donc différent du problème 2.4. La programmation stochastique permet de résoudre un grand nombre de problèmes

²Nous nous limitons à la probabilité discrète car les valeurs des variables aléatoires, que nous supposons dans notre étude, sont des scénarios finis.

d'optimisation sous incertitudes, notamment les problèmes dits avec *décisions de recours*.

Les problèmes stochastiques avec recours

90 Les problèmes avec recours sont une famille de problèmes stochastiques dans lesquels on suppose que les décisions se prennent en plusieurs étapes (ou phases ou *étages*). C'est donc une prise de décisions séquentielle où chaque étage représente un point temporel où les décisions sont prises. La notion de « recours » vient du fait que les décisions prises au premier étage peuvent être ajustées aux étages suivants. Le nombre d'étages dépend des différents instants auxquels on reçoit les informations nécessaires pour la résolution du problème. Le plus simple est le problème à deux étages dans lequel les décisions sont divisées en deux groupes qui sont :

- les décisions à prendre avant la réalisation des incertitudes. On les appelle décisions du premier étage ou décisions *here-and-now* (*ici-et-maintenant*, en français). Notons-les \mathbf{x} ;
- les décisions qui ne peuvent être prises qu'après la réalisation des incertitudes. On les appelle décisions du second étage ou décisions *wait-and-see* (*attends-
et-vois*, en français). Notons-les \mathbf{y} .

La prise de décisions se déroule donc comme suit :

1. on décide de la valeur de \mathbf{x} ;
2. W_ω se réalise, on obtient donc sa valeur ;
3. à l'aide des valeurs de W_ω et de \mathbf{x} , on détermine $\mathbf{y}(\mathbf{x}, \omega)$.

91 Un principe important à observer dans la modélisation des problèmes à plusieurs étages est le principe de *non anticipativité* [Birge 2011, Morales 2014] : les décisions à un étage ne doivent pas dépendre de (anticiper sur) la réalisation d'informations qui ne survient que plus tard ; elles doivent dépendre uniquement des informations obtenues aux étages précédents. En d'autres termes, si toutes les réalisations des variables aléatoires sont identiques jusqu'à un certain étage, alors les valeurs des décisions doivent être les mêmes jusqu'à cet étage.

92 Un problème stochastique linéaire à deux étages peut être exprimé comme suit [Birge 2011, Morales 2014] :

$$PLS := \begin{cases} \min_{\mathbf{x}} \mathbf{c}^T \mathbf{x} + \mathbb{E}_\omega \left\{ \min_{\mathbf{y}_\omega} d_\omega^T \mathbf{y}_\omega \right\} & (2.11) \\ \text{s.t.} \quad \mathbf{A}\mathbf{x} = \mathbf{b} & (2.11a) \\ \mathbf{Q}_\omega \mathbf{x} + \mathbf{T}_\omega \mathbf{y} = \mathbf{h}_\omega & (2.11b) \\ \mathbf{x}, \mathbf{y}_\omega \geq 0 & (2.11c) \end{cases}$$

Où $\omega \in \Omega$, \mathbf{x} et \mathbf{y}_ω sont les variables du premier étage et second étage, resp., $\mathbf{c}, d_\omega, \mathbf{b}, \mathbf{h}_\omega, \mathbf{A}, \mathbf{Q}_\omega$ et \mathbf{T}_ω sont des vecteurs et matrices de taille appropriée.

Le problème 2.11 comporte deux problèmes de minimisation correspondant aux deux étages. Il peut être mis sous la forme suivante, dans laquelle la distinction des deux étages est plus claire.

$$PLS := \begin{cases} \min_{\mathbf{x}} \mathbf{c}^T \mathbf{x} + \mathbb{E}_\omega \{D(x, \omega)\} & (2.12) \\ \text{s.t. } \mathbf{Ax} = \mathbf{b} & (2.12a) \\ \mathbf{x} \geq 0 & (2.12b) \end{cases}$$

Avec :

$$D(x, \omega) = \begin{cases} \min_{\mathbf{y}_\omega} d_\omega^T \mathbf{y}_\omega & (2.13) \\ \text{s.t. } \mathbf{Q}_\omega \mathbf{x} + \mathbf{T}_\omega \mathbf{y}_\omega = \mathbf{h}_\omega & (2.13a) \\ \mathbf{y}_\omega \geq 0 & (2.13b) \end{cases}$$

Le second étage 2.13, appelé problème de recours, dépend de la variable aléatoire W . Ainsi pour chaque réalisation de W_ω de W , le problème 2.13 devient un problème linéaire déterministe équivalent au problème linéaire 2.4. On peut donc définir, pour $\omega \in \Omega$ (où Ω est un ensemble fini dénombrable) et en utilisant la définition 2.9 de l'espérance mathématique, le programme équivalent déterministe (PED) suivant [Morales 2014, Birge 2011] :

$$PED := \begin{cases} \min_{\mathbf{x}, \mathbf{y}_\omega} \mathbf{c}^T \mathbf{x} + \sum_{\omega \in \Omega} p_\omega d_\omega^T \mathbf{y}_\omega & (2.14) \\ \text{s.t. } \mathbf{Ax} = \mathbf{b} & (2.14a) \\ \mathbf{Q}_\omega \mathbf{x} + \mathbf{T}_\omega \mathbf{y}_\omega = \mathbf{h}_\omega, \quad \omega \in \Omega & (2.14b) \\ \mathbf{x} \geq 0 & (2.14c) \\ \mathbf{y}_\omega \geq 0, \quad \omega \in \Omega & (2.14d) \end{cases}$$

Où p_ω est la probabilité de réalisation de chaque scénario.

2.4.2 L'approche robuste

Suivant l'approche robuste, les paramètres incertains ne sont plus représentés par leurs distributions de probabilité mais par des intervalles, appelés *intervalles* (ou *domaines*) *d'incertitude*. Une fois ces intervalles déterminés, l'objectif est de déterminer une solution du problème qui est « réalisable » pour toutes les réalisations possibles de ces variables aléatoires dans les intervalles correspondants et « optimale » pour le *pire cas* de leurs réalisations. La notion de *pire cas* étant relative à chaque paramètre — généralement l'une des bornes de l'intervalle — et au problème.

Cette approche est justement appelée *approche de pire cas*, car après avoir déterminé les intervalles d'incertitude, il est nécessaire de trouver la valeur de chaque paramètre incertain qui représente son pire cas.

Même si la connaissance de l'intervalle d'incertitudes suffit pour implémenter une 94

approche robuste, des connaissances de la répartition³ des valeurs, du paramètre incertain, dans l'intervalle d'incertitude pourraient faciliter la résolution du problème. Le concept de *budget d'incertitude* a donc été introduit pour prendre en compte cette idée. Un budget d'incertitude est en général un ensemble de contraintes. Par exemple, si la valeur du paramètre incertain dépend du temps, un budget modéliserait le fait qu'à certaines périodes, ce paramètre est plus susceptible de prendre sa plus petite valeur et qu'à d'autres périodes, sa valeur moyenne, etc.

95 Ensemble, le choix de l'intervalle et du budget d'incertitude sont un facteur clé de la performance de l'approche robuste. En effet, si le budget fait en sorte que le paramètre incertain **ne prenne pas** souvent sa pire valeur, l'approche pourrait être trop *conservatrice*. En revanche, si le budget permet que le paramètre incertain **prenne trop** souvent sa pire valeur, l'approche pourrait être trop *pessimiste*. Ce choix est donc très délicat.

96 Les principales raisons qui motivent l'utilisation de l'approche robuste, pour la gestion des incertitudes, plutôt que l'approche stochastique sont les suivantes :

- la détermination de la distribution de probabilité d'une variable aléatoire est une tâche difficile, surtout lorsque le comportement de la variable est pratiquement imprévisible comme c'est le cas de l'ensoleillement. En effet même s'il est commun d'utiliser les distributions normale et bêta pour la modéliser, il n'y a aucun consensus à ce sujet ;
- il faut un nombre de scénarios important pour pouvoir prendre en compte toutes les éventualités de réalisation de chaque paramètre. La taille du problème s'accroît donc encore plus avec le nombre de scénarios et de paramètres incertains, rendant ainsi le problème très difficile voire impossible à résoudre.

97 La programmation robuste est applicable aux problèmes avec ou sans recours, dans le même sens que dans la programmation stochastique. Les deux prochaines sections traitent brièvement de chacun de ces problèmes, à partant du problème linéaire 2.4.

Programmation robuste sans recours

98 Puisque l'approche robuste consiste à trouver une solution optimale d'un problème d'optimisation sous incertitudes dans le pire cas de réalisation des paramètres incertains, c'est donc un problème d'optimisation bi-niveaux (à deux niveaux). En d'autres termes, il comporte deux sous-problèmes d'optimisation de sens opposés : une minimisation et une maximisation ou vice-versa. Le premier niveau — on suppose que c'est une minimisation — est la détermination d'une décision qui soit réalisable, pour toutes les réalisations des paramètres incertains, et optimale dans le pire cas de leurs réalisations dans le second niveau — donc une maximisation. Un programme linéaire robuste peut donc s'exprimer comme suit :

³Sans toutefois avoir recous à la distribution de probabilité

$$PRSR := \begin{cases} \min_{\mathbf{x} \in X} \max_{\mathbf{w} \in \mathcal{W}} \mathbf{c}_w^T \mathbf{x} & (2.15) \\ \text{s.t. } \mathbf{A}_w \mathbf{x} = \mathbf{b}_w & (2.15a) \\ \mathbf{x} \geq 0 & (2.15b) \end{cases}$$

Où \mathbf{x} est le vecteur de décisions à prendre avant la réalisation des paramètres incertains \mathbf{w} , \mathcal{W} est le domaine d'incertitudes de \mathbf{w} . L'indice w associé aux paramètres \mathbf{c} , \mathbf{b} et \mathbf{A} indique que les incertitudes peuvent porter sur le coefficient de la fonction objectif, le membre de droite des contraintes ou sur la matrice des contraintes. En effet, un traitement particulier est donné au problème robuste est fonction de l'endroit du problème où apparaissent les incertitudes [Ben-Tal 2009, Bertsimas 2011].

Dans le problème 2.15, il n'est pas possible de prendre une décision après la réalisation des incertitudes, il n'y a donc pas de recours. On verra à la section suivante le cas avec recours.

La méthode la plus commune pour résoudre le problème 2.15 est de prendre le dual du problème de second niveau, ce qui conduit à un problème **min-min** et à le combiner en un seul problème **min**. Cette méthode est également applicable à tous les problèmes convexes [Morales 2014].

99

Programmation robuste avec recours

C'est le même principe que le problème stochastique avec recours ; c'est la formulation qui fait la différence. En effet, s'il est possible de prendre des décisions de recours, alors les variables de décision se scindent en variables *here-and-now* \mathbf{x} et en variables *wait-and-see* \mathbf{y} et donc au lieu d'un problème à deux niveaux, on a maintenant un problème à trois niveaux : **min-max-min** dans le cas présent. Le problème peut être formulé comme suit :

$$PRAR := \begin{cases} \min_{\mathbf{x} \in X} \max_{\mathbf{w} \in \mathcal{W}} \min_{\mathbf{y} \in Y} \mathbf{c}_w^T \mathbf{x} + \mathbf{d}_w^T \mathbf{y} & (2.16) \\ \text{s.t. } \mathbf{A}_w \mathbf{x} + \mathbf{Q}_w \mathbf{y} = \mathbf{b}_w & (2.16a) \\ \mathbf{x}, \mathbf{y} \geq 0 & (2.16b) \end{cases}$$

100

2

2.4.3 De la nécessité de la gestion des incertitudes

Comme nous l'avons vu à la section 2.4, la prise en compte des incertitudes dans un problème d'optimisation ajoute une couche de complexité, en modélisation et en résolution. La question qui survient naturellement c'est la nécessité de la gestion des incertitudes. En d'autres termes, n'est-il pas préférable de résoudre la version déterministe du problème plutôt que sa version stochastique ? On a vu qu'il y a des risques à le faire mais le concept de risque dépendant du contexte, c'est une bonne pratique de toujours développer les versions déterministe et stochastique (et/ou robuste) d'un problème — en commençant naturellement par la version déterministe. Ensuite, évaluer la valeur économique de la prise en compte des incertitudes.

101

Une autre inquiétude lorsqu'on fait de l'optimisation sous incertitudes, c'est l'assurance d'avoir des prévisions parfaites des paramètres incertains. On tend à se demander quel est le degré de fiabilité de ces prévisions. La question qui se pose, c'est quel est l'avantage d'avoir des données de prévisions parfaites. Encore une fois, cela dépend du contexte. Cet indicateur doit donc être évalué par problème.

102 Dans la littérature sur l'optimisation stochastique, on définit deux indicateurs pour répondre aux deux questions que nous venons de poser. Ce sont [Morales 2014] :

La valeur moyenne de l'information parfaite : (Expected Value of Perfect Information ou EVPI, en anglais). Cet indicateur mesure le prix que le preneur de décision est prêt à payer pour obtenir des prévisions parfaites du futur. Il est déterminé comme suit :

1. résoudre le programme stochastique 2.14 et obtenir la valeur optimale V^{ss*} . L'exposant s désigne « stochastique »;
2. résoudre le programme stochastique 2.14 en **relâchant** le principe de non anticipativité des décisions, càd que toutes les variables de décision deviennent dépendantes des scénarios. Il s'agit donc d'un problème *wait-and-see*, défini par :

$$P := \left| \begin{array}{ll} \min_{\mathbf{x}_\omega, \mathbf{y}_\omega} V^{ws} = \sum_{\omega \in \Omega} p_\omega (\mathbf{c}^T \mathbf{x}_\omega + d_\omega^T \mathbf{y}_\omega) & (2.17) \\ \text{s.t.} \quad \mathbf{A} \mathbf{x}_\omega = \mathbf{b}, \omega \in \Omega & (2.17a) \\ \mathbf{Q}_\omega \mathbf{x} + \mathbf{T}_\omega \mathbf{y}_\omega = \mathbf{h}_\omega, \omega \in \Omega & (2.17b) \\ \mathbf{x}_\omega, \mathbf{y}_\omega \geq 0, \omega \in \Omega & (2.17c) \end{array} \right.$$

Obtenir la valeur optimale V^{ws*} .

3. Calculer $EVPI = V^{ws*} - V^{ss*}$.

La valeur de la solution stochastique : (Value of Stochastic Solution ou VSS, en anglais). Cet indicateur mesure le gain économique que fait le preneur de décision en utilisant l'approche stochastique plutôt que déterministe. Pour un problème à deux étages, il est déterminé comme suit :

1. résoudre le programme stochastique 2.14 et obtenir la valeur optimale V^{ss*} . L'exposant s désigne « stochastique »;
2. résoudre le problème déterministe qui consiste à remplacer les paramètres incertains du problème 2.14 par leurs valeurs moyennes. Il s'agit donc d'un problème défini par :

$$P := \left| \begin{array}{ll} \min_{\mathbf{x}^d, \bar{\mathbf{y}}} \mathbf{c}^T \mathbf{x} + \bar{d}^T \bar{\mathbf{y}} & (2.18) \\ \text{s.t.} \quad \mathbf{A} \mathbf{x}^d = \mathbf{b} & (2.18a) \\ \bar{\mathbf{Q}} \mathbf{x}^d + \bar{\mathbf{T}} \bar{\mathbf{y}} = \bar{\mathbf{h}} & (2.18b) \\ \mathbf{x}^d, \bar{\mathbf{y}} \geq 0 & (2.18c) \end{array} \right.$$

Où x^d représente la décision déterministe et $\bar{\cdot} = \mathbb{E}_\omega\{\cdot_\omega\}$ (\cdot représente un paramètre incertain).

Obtenir la solution optimale x^{d*} .

3. résoudre le programme stochastique 2.14 en remplaçant les variables du premier étage x par la valeur optimale x^{d*} obtenue à l'étape précédent. On

$$P := \begin{cases} \min_{\mathbf{y}_\omega} V^d = \mathbf{c}^T \mathbf{x}^{d*} + \sum_{\omega \in \Omega} p_\omega d_\omega^T \mathbf{y}_\omega & (2.19) \\ \text{s.t. } \mathbf{Q}_\omega \mathbf{x}^{d*} + \mathbf{T}_\omega \mathbf{y}_\omega = \mathbf{h}_\omega, \quad \omega \in \Omega & (2.19a) \\ \mathbf{y}_\omega \geq 0, \quad \omega \in \Omega & (2.19b) \end{cases}$$

Obtenir la solution optimale V^{d*} . Notez que puisque x^{d*} n'est pas une variable du problème, toutes les contraintes du problème 2.14 portant spécifiquement sur x ont été supprimées.

4. Calculer $VSS = V^{s*} - V^{d*}$.

Cette procédure peut être également employée pour comparer la solution stochastique avec la solution robuste. Il suffit de remplacer dans le problème 2.19, x^{d*} , par la solution optimale, x^{r*} , du problème robuste. Et on détermine $VSS = V^{s*} - V^{r*}$.

3

Problématique

Sommaire

- 3.1 Cadre général de contrôle
- 3.2 Optimisation du contrôle
- 3.3 Applicabilité des commandes optimales
- 3.4 Contexte AOCRE et calcul d'engagement
- 3.5 Incertitudes des données de prévision solaire

LA LITTÉRATURE SUR LE CONTRÔLE OPTIMAL DES MICROGRIDS est très vaste et les méthodes employées sont nombreuses (§21, [Minchala-Avilaa 2015, Natesan 2015, Twahaa 2018, Karthik 2018, Pourbehzadi 2019]). Toutefois, la plupart des études ou applications existantes se limitent à la résolution du problème sans couplage avec un simulateur. La conséquence immédiate est que les commandes obtenues, quoique optimales en simulation, peuvent ne pas l'être en situation réelle — où les commandes sont appliquées au microgrid — ; aussi elles ne seraient pas applicables. Cela s'explique par le fait qu'il y a un écart entre le modèle mathématique et le simulateur (qu'on suppose être égal au microgrid réel). D'autre part, très peu d'études font cas de l'optimalité même des solutions obtenues en boucle ouverte. La question de la gestion des incertitudes liées à la production solaire est traitée dans la littérature. Les méthodes d'optimisation déterministes sont adaptées pour prendre en compte ces incertitudes. Cependant, dans la pratique, puisque les méthodes d'optimisation employées sont peu sophistiquées, il est difficile voire impossible de gérer les incertitudes. Les performances apparemment bonnes de ces méthodes, dans le cas déterministe, confortent encore plus les praticiens dans la non considération des incertitudes. Tous les faits que nous venons d'énoncer constituent des problèmes que nous avons tenté de résoudre dans cette étude.

Comme mentionné dans l'introduction, notre étude s'est articulée autour de 5 axes principaux qui ont conduit à la considération de 7 questions fondamentales. Nous y avions exposé ces axes de façon générale. Dans ce chapitre, nous reprenons cette exposition de façon plus détaillée et technique.

3.1 Cadre général de contrôle

Le but de cette section est de fixer ce qui constitue, dans le cadre de notre étude, un système de contrôle. Il s'agit de donner une représentation de ce système et d'expliquer comment nous avons interagi avec lui.

Tout système de contrôle optimal (appelons-le Contrôleur) suppose un système

103

104

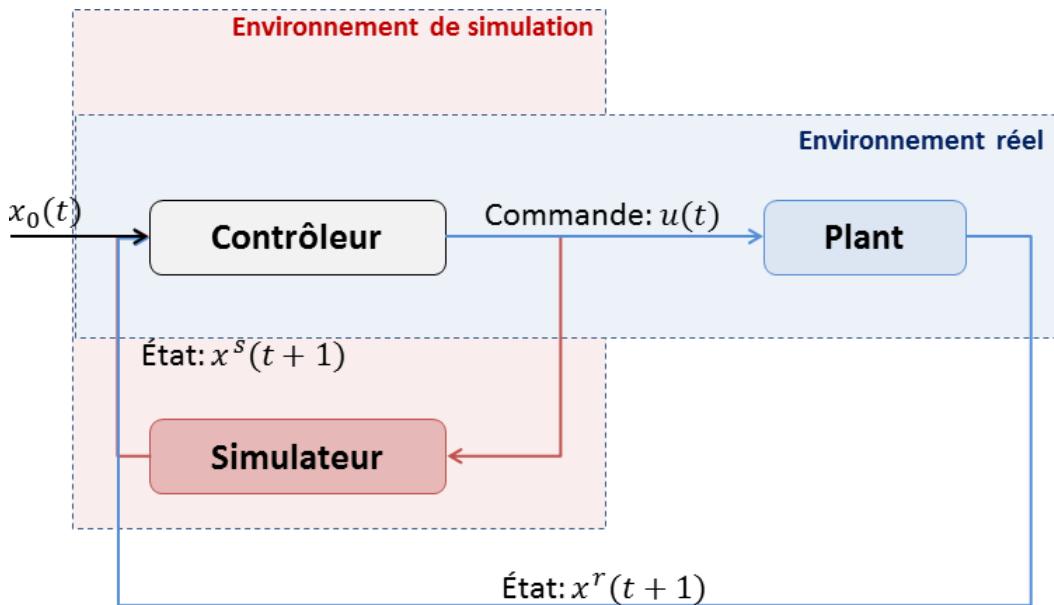


FIGURE 3.1: Représentation d'un système de contrôle composé d'un environnement de simulation et d'un environnement réel.

réel (appelons-le **Plant**) à contrôler. Les solutions obtenues par le module optimisation de ce système sont destinées à être appliquées à **Plant**. En environnement *hors ligne*, càd en environnement de simulation, une représentation de **Plant** (appelons-la **Simulateur**) doit être disponible afin d'émuler la situation *en ligne*, càd la situation réelle. Le simulateur est supposé être une représentation parfaite de **Plant** dans l'environnement de simulation.

105 La figure 3.1 est une représentation de ces deux environnements. Dans l'environnement de simulation, le **Contrôleur**, à l'aide de l'état actuel $x_0(t)$ de **Plant**, détermine une commande optimale $u(t)$ et l'applique au **Simulateur**. Ce dernier lui retourne le nouvel état $x^s(t+1)$. Cette boucle continue jusqu'à ce qu'il soit temps d'envoyer la commande à **Plant**. Alors, on passe dans l'environnement réel. La commande est appliquée à **Plant** et il retourne son nouvel état $x^r(t+1)$ au **Contrôleur**.

3.2 Optimisation du contrôle

3.2.1 Comparaison de 3 approches d'optimisation du contrôle

106 La principale question, que nous nous posons, est : Y a-t-il un intérêt à mettre en place des solutions d'optimisation plus avancées, notamment prédictives, pour le contrôle optimal des microgrids ? En effet, même si des techniques d'optimisation, de plus en plus sophistiquées, ont été introduites dans l'activité de contrôle des microgrids, au fil des ans, comme nous l'avons indiqué dans l'introduction de ce rapport, et que leur utilisation pourrait justifier leur intérêt, la question de leur intérêt n'a pas été traitée à suffisance ; en tout cas, pas au point de convaincre les praticiens. C'est ce que nous tentons de faire, mais à une échelle restreinte. Nous nous proposons en effet de comparer 3 principales techniques employées pour le contrôle optimal des microgrids. Ce sont : les règles d'expert, l'algorithme génétique couplé à un simulateur,

et la programmation mathématique. Nous considérons que cet ordre correspond à l'ordre croissant de sophistication. Il s'agit donc de montrer que la programmation mathématique est plus performante que l'algorithme génétique et les règles d'expert, et que l'algorithme génétique est, lui-même, plus performant que les règles expertes. Dans la pratique, l'ordre d'emploi de ces techniques est inversé, même si dans la littérature, une place de choix est donnée aux deux dernières [Gelleschus 2018], comme nous le verrons dans les paragraphes suivants.

Dans [Michalewicz 1990], Z. Michalewicz *et al* comparent l'algorithme génétique à la programmation mathématique — via le logiciel GAMS —, sur la résolution de 2 problèmes abstraits de contrôle optimal, l'un du type linéaire-quadratique unidimensionnel et l'autre, du type non linéaire unidimensionnel. Ces problèmes sont suffisamment simples pour être résolus analytiquement et servir de référence aux solutions retournées par GAMS et l'algorithme. La conclusion de cette étude est que pour le premier problème, les solutions retournées par GAMS sont parfaites (erreur relative: 0%), ce qui n'est pas le cas pour le second, à cause de sa non-convexité (erreur relative: 30-50%). Dans ce dernier cas, il arrive qu'il n'obtienne aucune solution satisfaisante. En revanche, les solutions retournées, retournées par l'algorithme génétique, sont très proches de la solution réelle (erreur relative maximale: 0.048%) dans les 2 cas.

107

Même si les problèmes considérés dans cette étude ne sont pas réalistes et pas appliqués au contrôle des microgrids, ils n'en demeurent pas moins des problèmes de contrôle optimal. Et les résultats montrent bien que l'algorithme génétique et la programmation mathématique arrivent à résoudre ces problèmes, avec un avantage pour le premier lorsque le problème n'est pas convexe. Toutefois, lorsque le problème est sous une forme appropriée, linéaire-quadratique dans ce cas, la programmation mathématique atteint l'optimum, et est plus performante que l'algorithme génétique. À noter que les auteurs précisent qu'au moment de la publication de leur étude, ils n'avaient aucune connaissance de l'application de l'algorithme génétique à la résolution des problèmes de contrôle optimal. Cela est conforme à l'historique que nous avons dressée dans l'introduction.

3

Dans [Suchetha 2018], C. Suchetha et J. Ramprabhakar font une revue des méthodes et critères d'optimisation des microgrids. Ils affirment, dans l'abstract, qu'une étude approfondie de la littérature montre que les métaheuristiques, algorithme génétique compris, sont plus performantes que les méthodes dites classiques, telles que la programmation mathématique. Toutefois, ils ne fournissent aucune référence pour soutenir cette assertion.

108

Dans [Nemati 2018], M. Nemati *et al* résolvent les problèmes d'Unit Commitment (UC) et Economic Dispatch (ED) avec l'algorithme génétique et la programmation mathématique, spécifiquement la programmation linéaire en nombres entiers (MILP). Les problèmes d'optimisation sont des minimisations de coût. Il ressort de leurs simulations que, dans le cas de référence, le programme mathématique obtient des coûts relativement inférieurs à ceux de l'algorithme génétique (différence de 0.3%), que le premier est 2 fois plus rapide que le second. Dans le cas où le microgrid est isolé et dans le cas d'un fonctionnement écologique, le MILP présente des coûts relativement inférieurs et nécessite 84% moins de temps que l'algorithme. Cependant, dans les cas très contraints, où on prend en compte le vieillissement des

109

batteries et la gestion de la qualité de la tension et de la congestion, l'algorithme génétique présente de meilleurs résultats.

110 Dans [Gelleschus 2018], R. Gelleschus *et al* comparent divers solveurs d'optimisation sur le problème de contrôle prédictif d'un microgrid composé d'un champ PV, de batteries et d'une pompe à chaleur. Un modèle linéaire en nombres entiers du système est développé. Comme conclusion de cette étude, il est dit que l'approche MILP, basée sur l'algorithme Branch & Cut, est plus performante que toutes les autres, en particulier l'algorithme génétique. Concernant cette dernière approche, il est dit qu'elle échoue à trouver des solutions réalisables à cause du nombre important de contraintes.

111 Dans [Bourbon 2019], R. Bourbon *et al* comparent une méthode heuristique — qui peut être assimilée à un système de règles d'expert — et un MILP, dans le cadre de la gestion optimale d'une centrale éolienne. Il en ressort que le MILP a de meilleures performances que l'heuristique, en tout point de vue.

112 Les références susmentionnées font état de la supériorité de la programmation mathématique sur l'algorithme génétique et les règles d'expert. Il est toutefois important de préciser que, dans tous ces cas, l'algorithme génétique est basé sur un modèle analytique du microgrid, et que la littérature ne foisonne pas de nombreux cas de comparaison de ces 3 méthodes, deux à deux, et qu'à notre connaissance, il n'y a aucun cas de comparaison simultanée de ces 3 approches. C'est ce que nous nous proposons de faire, avec la différence que l'algorithme génétique est couplé à un simulateur numérique, càd un modèle boîte noire.

3.2.2 Garantie d'optimalité

113 Une garantie ou certificat d'optimalité est un ensemble de conditions qui permet d'attester que la solution obtenue est optimale. Par exemple, on montre qu'une solution réalisable \mathbf{x} du problème linéaire $\min\{\mathbf{c}^T \mathbf{x} : \mathbf{Ax} = \mathbf{b}, \mathbf{x} \geq \mathbf{0}\}$ est optimale s'il existe \mathbf{y} tel que $\mathbf{A}^T \mathbf{x} \leq \mathbf{c}$ et $\mathbf{c}^T \mathbf{x} = \mathbf{y}^T \mathbf{b}$. En d'autres termes, il faut que le problème dual ait une solution y de même valeur d'objectif que celle de x dans le problème primal. En général, les problèmes d'optimisation pouvant être résolus à l'optimum par des méthodes de programmation mathématique, fournissent un certificat d'optimalité. Numériquement, les solveurs utilisent des indicateurs quantitatifs pour indiquer à quel point la solution actuelle est proche de la meilleure solution possible. Un de ces indicateurs est le *gap de dualité* qui est de deux types : le *gap absolu* et le *gap relatif*. Le premier mesure la différence (en valeur d'objectif) entre la meilleure solution actuelle et la meilleure solution possible (la meilleure borne). Le second est le premier divisé par la meilleure borne. Ces indicateurs sont plus faciles à exploiter pour un utilisateur final que les conditions mathématiques.

114 Comme nous l'avons déjà mentionné à maintes reprises, les métahéuristiques ne fournissent pas de certificat d'optimalité à cause de leur manière de rechercher la solution au problème. Aussi, même si elles sont capables de trouver l'optimum global, l'optimalité de leurs solutions ne peut être évaluée qu'en résolvant le même problème par des méthodes conventionnelles, capables de fournir cette garantie.

115 De la discussion précédente, il ressort que les algorithmes d'optimisation peuvent ne pas converger vers la solution du problème, même si, en théorie, la solution optimale existe. Et, même s'il y a des solveurs puissants pour résoudre certains types

de problème, comme la plupart des problèmes convexes, leur capacité à trouver la solution optimale dépend de la complexité du problème. À chaque étape de la résolution du problème, on peut au mieux avoir une solution avec un certain gap d'optimalité. Si le problème est relativement simple à résoudre, le solveur retournera la solution optimale avec un gap presque nul.

D'un point de vue théorique, il est donc important d'associer à chaque solution, son gap d'optimalité. Cette grandeur, plus le temps mis pour obtenir la solution, permettent d'évaluer la performance du solveur et la complexité du problème. D'un point de vue pratique, cela permet de savoir que la solution obtenue peut encore être améliorée, si on laisse suffisamment de temps au solveur, et évaluer le gain de cette approche.

Pour toutes ces raisons, l'observation de la garantie d'optimalité est un aspect important dans toute application de l'optimisation, et a donc été un aspect très important de notre étude. Nous notons cependant qu'à l'exception de quelques études, telles que [Viana 2013, Das 2018, Madani 2015], la plupart des études sur le contrôle optimal des microgrids ne font pas cas de la garantie d'optimalité. En effet, dans [Viana 2013], il est proposé une nouvelle approche, de résolution des problèmes d'Unit Commitment, basée sur la programmation linéaire en nombres entiers. Il s'agit d'un algorithme linéaire itératif. On y montre que cet algorithme résout le problème à l'optimalité, en comparant ses solutions à celles obtenues par un solveur quadratique qui garantit l'optimalité. On y montre aussi que le temps de résolution de ce nouvel algorithme est moindre. Dans [Das 2018], on propose un algorithme de programmation dynamique approximative, pour la résolution des problèmes de contrôle optimal des batteries de stockage dans les microgrids off-grid. Ces résultats sont comparés avec ceux obtenus en utilisant la programmation linéaire et la programmation dynamique, et montrent que l'approche atteint l'optimum dans 100% des cas déterministes, avec un taux presqu'équivalent dans les cas stochastiques, et un temps de résolution moindre dans ces derniers. Dans [Madani 2015], des algorithmes sont proposés pour résoudre les problèmes d'enchérissement sur les marchés day-ahead européens. Les résultats d'application de ces algorithmes sont comparés à ceux obtenus par les solveurs standards, en terme de gap relatif.

Un point commun entre ces trois études est qu'elles proposent un nouvel algorithme. Il va donc sans dire que la performance de ces algorithmes doit être montrée. Toutefois, la plupart des études, faisant juste usage des solveurs existants, n'évaluent pas l'optimalité de leurs solutions.

3.3 Applicabilité des commandes optimales

L'environnement de simulation, défini à la section 3.1, sert de cadre de validation de la commande avant qu'elle soit envoyée à Plant. Elle teste donc l'applicabilité de cette commande en environnement réel. Lorsque dans cet environnement, le simulateur n'existe pas — cet environnement n'existe plus en quelque sorte —, la commande est directement envoyée à Plant. En fonction de la criticité de l'application, cette action peut dégrader la performance globale du système de contrôle.

L'environnement de simulation ne résout pas complètement le problème d'applicabilité de la commande, mais permet de la prévoir, et de prendre des mesures

correctives et préventives, telles que l'amélioration du modèle du Simulateur ou du modèle de Plant, éventuellement embarqué dans le Contrôleur. En effet, même si, lorsqu'on se trouve dans l'environnement de simulation, on suppose que le Simulateur est parfait, il ne l'est que relativement à cet environnement. Il peut en réalité s'écarte de Plant. De même, dans l'environnement de simulation, la représentation de Plant dans le Contrôleur peut s'écarte du Simulateur. L'environnement de simulation permet donc d'améliorer ces deux modèles, et donc d'améliorer la performance globale du système de contrôle.

119 La discussion précédente justifie notre choix de vérifier l'applicabilité des commandes retournées par le contrôleur, que nous avons développé. Dans la littérature, cet aspect est le plus souvent négligé, soit parce qu'on ne voit pas suffisamment le risque, soit parce qu'on le fait mais qu'on ne le reporte pas, soit parce qu'on est conscient de la capacité d'un système de contrôle en boucle fermée de compenser les erreurs de modélisation (ou les incertitudes sur les données) [Palma-Behnke 2013, Malysz 2013, Silvente 2018]. Mais, même dans ce dernier cas, il est nécessaire d'évaluer à quel point la configuration du système le permet effectivement. Cependant, dans [Sechilariu 2014], il est explicitement mentionné que les commandes ont été appliquées à un microgrid (Simulateur), implémenté sous MATLAB/Simulink, pour tester leur faisabilité.

120 Lorsqu'une couche de contrôle temps réel existe entre le Contrôleur et Plant [Sechilariu 2014, El-Hendawi 2018], l'environnement de simulation peut ne pas être nécessaire, si cette couche veille à la réparation de la non applicabilité des commandes. Cette approche est courante, mais ajoute une couche de complexité au système de contrôle, et le contrôleur temps réel doit également être optimal pour s'assurer que les commandes, qu'il retourne, sont optimales. Il est donc nécessaire d'avoir une représentation du contrôleur temps réel en environnement de simulation, afin qu'il soit pris en compte dans la validation des commandes retournées par le Contrôleur.

3.4 Contexte AOCRE et calcul d'engagement

121 L'AOCREZNI est un marché d'énergie (voir §26 et §1.3.3), composé d'un marché day-ahead, d'un marché intraday et de marchés d'équilibre. Dans cette étude, nous n'avons considéré que les 2 premiers marchés. L'AOCREZNI diffère, en bien de points, des marchés d'énergie classiques. La différence la plus notable est le concept d'*engagement* qui est, à notre connaissance, spécifique à l'AOCREZNI. En effet, l'engagement est le profil de production totale journalière, avec un temps de résolution d'une minute, que le producteur annonce au gestionnaire de réseau, la veille de la production effective : c'est le marché day-ahead. En marché intraday, le producteur veille à respecter son engagement, dans un environnement de production solaire incertaine. Il est donc confronté au problème de détermination d'un profil d'engagement optimal, et à celui respecter cet engagement, en intraday. Ces 2 problèmes d'optimisation sont étroitement liés.

122 Dans les marchés d'énergie classiques, il n'y a pas d'engagement. En day-ahead, chaque producteur fait son enchère (production, prix de vente), et le gestionnaire de réseau détermine un prix d'équilibre et la quantité d'énergie, que doit produire chaque producteur participant. Cette quantité devient donc une demande à satis-

faire, en intraday. Mais, elle peut ne pas être égale à celle contenue dans l'enchère du producteur. Dans ce cas, son problème d'enchérissement optimal est déconnecté de son problème de contrôle optimal, et dans la littérature, c'est ce dernier problème qui est le plus étudié [Mohammadi 2012, Palma-Behnke 2013, Haessig 2014, Chen 2018, Meena 2019, Aboli 2019, Bahmani 2020]. Le marché day-ahead de l'AOCREZNI est donc fondamentalement différent de celui des marchés classiques.

Pierre Haessig, dans sa thèse [Haessig 2014], mentionne explicitement l'AOCREZNI¹²³. Mais, il a travaillé sur le problème de contrôle optimal uniquement, dans lequel l'engagement est une donnée. À notre connaissance, c'est l'article de Peter Pflaum *et al* [Pflaum 2017] qui traite du problème d'engagement optimal de l'AOCREZNI. La différence, entre nos travaux et les leur, réside dans la méthode d'optimisation utilisée — donc dans la modélisation du problème —, et dans le fait qu'un de leurs objectifs est de déterminer la taille optimale de la batterie. Ils utilisent des algorithmes probabilistes ou randomisés, alors que nous utilisons la programmation mathématique.

3.5 Incertitudes des données de prévision solaire

Dans la section 3.4, nous avons indiqué l'originalité du problème d'engagement dans le contexte des marchés d'énergie, et combien ce problème n'est pas considéré dans la littérature.¹²⁴

Le producteur détermine donc l'engagement, et veille à le satisfaire en intraday. Pour les 2 problèmes qu'il cherche à résoudre, il fait usage de données de prévision solaire, plus ou moins bonnes. Aussi, puisque l'ensoleillement est fortement variable, il peut arriver que son engagement soit trop optimiste, au cas où la production solaire réelle est fortement inférieure à celle prévue la veille. Le producteur doit donc déterminer son engagement qui soit robuste aux incertitudes liées à la production solaire.

Dans [Pflaum 2017], Peter Pflaum *et al* traitent directement le problème d'engagement optimal sous incertitudes. Dans notre étude, nous traitons d'abord le cas déterministe, ensuite le cas sous incertitudes. Cela nous permet d'évaluer la nécessité de la prise en compte des incertitudes. Car, en effet, il est possible que le gain apporté par la gestion des incertitudes soit négligeable.¹²⁵

4

Contrôle optimal des microgrids off-grid

Sommaire

- 4.1 Modélisation mathématique du problème
- 4.2 Résolution, résultats et discussion
- 4.3 Conclusion

Nous commençons notre conception de l'EMS par la couche de contrôle. Deux applications sont considérées: le cas d'un microgrid isolé — qui fait l'objet de ce chapitre — et le cas d'un microgrid connecté réseau — que nous traiterons au chapitre suivant. 126

Nous qualifions les microgrids off-grid de microgrids hybrides car ils sont composés de ressources renouvelables (photovoltaïque, éolien, etc.) et de ressources fossiles (principalement les générateurs diesel). 127

Un microgrid est dit isolé lorsqu'il n'est pas connecté au réseau principal, c'est-à-dire qu'il ne dépend que de lui-même pour sa production, et sa consommation d'énergie. En d'autres termes, il est autonome. Il est donc clair qu'il n'a pas la même flexibilité qu'un microgrid connecté réseau. Il reste toutefois le type de microgrid adapté aux zones non connectées au réseau principal, que l'on rencontre principalement dans les pays en voie de développement. D'où l'intérêt de contrôler ces systèmes, et de les contrôler efficacement afin de maximiser leur utilité. 128

Dans la littérature, il y a une foule d'études portant sur la résolution du problème de contrôle optimal des microgrids off-grid [Barley 1995, Seeling-Hochmuth 1998, Muselli 1999, Woon 2008, Gupta 2011, Anayochukwu 2013, Viana 2013, Kusakana 2015, Tazvinga 2015, Sichilalu 2015, Bordin 2017, Das 2018]. A. Mahesh et K. S. Sandhu en font une revue critique dans [Mahesh 2015]. Cependant, il est rare dans ces études, notamment dans les applications de programmation mathématique, que la qualité des solutions soit évaluée au travers d'un simulateur, par exemple, afin d'attester de leur applicabilité. C'est précisément ce que nous proposons de faire. 129

4.1 Modélisation mathématique du problème

Nous présentons dans cette section un modèle mathématique en puissance du contrôle de microgrid sur un horizon de temps discrétré en $t = 1, \dots, T$ pas de temps de durée δ_t . On suppose le système en régime stationnaire sur chaque pas de temps: les flux et puissances sont constants sur chaque pas de temps.

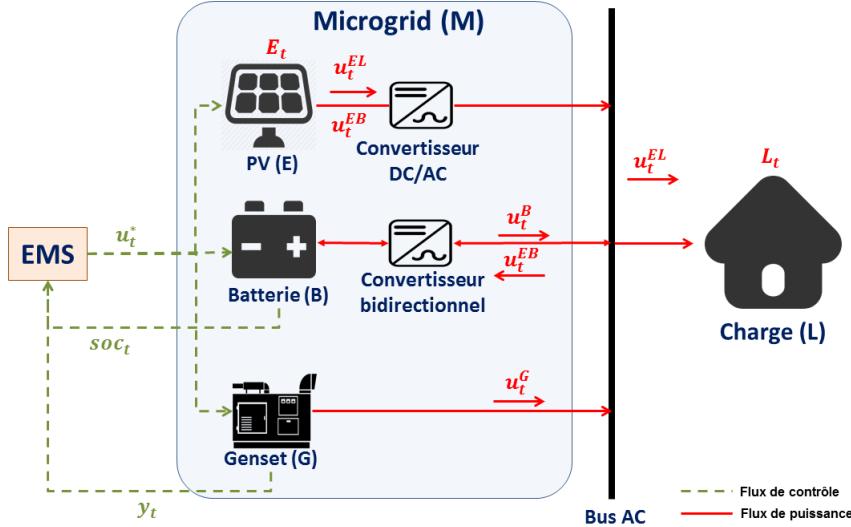


FIGURE 4.1: Microgrid off-grid fournissant de l'énergie à une charge quelconque

4.1.1 Les contraintes

Le microgrid considéré dans cette étude peut être représenté comme sur la figure 4.1. Il est composé d'un champ PV, d'une batterie et d'un générateur diesel et d'une charge. Le système doit fournir une puissance égale à la demande de la charge à chaque instant. Cette contrainte d'équilibre sur le réseau s'exprime par :

$$\eta_{PV}^{inv} u_t^{EL} + u_t^B + u_t^G = L_t \quad \forall t = 1, \dots, T \quad (4.1)$$

où L_t désigne la demande en puissance sur le pas de temps t et les variables u_t^{EL} , u_t^B et u_t^G sont les puissances fournies par le champ PV, la batterie et le gенset à la charge, respectivement. La constante η_{PV}^{inv} est le rendement du convertisseur DC/AC en sortie du champ PV.

La contrainte d'égalité stricte (4.1) pourrait conduire à l'irréalisabilité du problème, si la demande ne peut être satisfaite à un instant donné, généralement à cause des plages restreintes de fonctionnement du gенset. Nous relâchons donc cette égalité, et pénalisons la déviation entre la production et la demande, dans la fonction objectif (voir équation (4.17)). La contrainte (4.1) devient :

$$\eta_{PV}^{inv} u_t^{EL} + u_t^B + u_t^G = u_t^L \quad \forall t = 1, \dots, T \quad (4.2)$$

où la variable u_t^L représente la quantité d'énergie fournie à la charge. La déviation u_t^{dev} est exprimée par l'équation :

$$u_t^{dev} = u_t^L - L_t \quad \forall t = 1, \dots, T \quad (4.3)$$

Cette déviation est toujours positive, car on ne permet pas que le microgrid soit en sous-production.

Le champ PV a une production instantanée E_t . Il fournit la part u_t^{EL} nécessaire à la charge et/ou à la batterie et l'excédent est écrété. La contrainte d'écrêtage de l'excédent de puissance PV, s'exprime par :

$$u_t^{EL} + u_t^{EB} \leq E_t \quad \forall t = 1, \dots, T \quad (4.4)$$

où la variable u_t^{EB} est la part du productible PV, E_t , fournie à la batterie pour sa charge.

L'état de charge soc_t de la batterie exprime sa capacité à fournir/recevoir de l'énergie au début du pas de temps t . La dynamique de cette variable est exprimée par l'équation aux différences

$$soc_t = soc_{t-1} + \left(\eta_c \eta_{PV}^{inv} u_t^{EB} - \frac{u_t^B}{\eta_d} \right) \frac{\delta_t}{B^{nom}} \quad \forall t = 1, \dots, T \quad (4.5)$$

où les paramètres η_c , η_d et B^{nom} relatifs à la batterie désignent, respectivement, les rendements de charge et de décharge et la capacité nominale de la batterie. L'état de charge initial soc_0 de la batterie est connue, ainsi que les bornes minimale soc^{min} et maximale soc^{max} , de l'état de charge de la batterie à chaque instant :

$$soc^{min} \leq soc_t \leq soc^{max} \quad \forall t = 1, \dots, T. \quad (4.6)$$

La charge et la décharge de la batterie ne peuvent pas s'effectuer au même instant. On assure cette contrainte par les équations :

$$0 \leq u_t^B \leq B_d^{max} y_t^B \quad \forall t = 1, \dots, T \quad (4.7)$$

$$0 \leq u_t^{XB} \leq B_c^{max} (1 - y_t^B) \quad \forall t = 1, \dots, T \quad (4.8)$$

où les paramètres B_d^{max} et B_c^{max} sont les puissances maximales que peuvent fournir ou recevoir la batterie à chaque instant, et y_t^B est une variable binaire égale à 1 si la batterie est en décharge, et 0 si elle est en charge. Le produit $u_t^B \times u_t^{XB}$ est garanti être ainsi toujours nul.

On suppose que quand le gensem est en marche (resp. à l'arrêt) (mode « on », resp. « off »), il doit rester dans cet état pendant au moins t_{on}^{min} (resp. t_{off}^{min}) pas de temps consécutifs. L'état de marche ou d'arrêt du gensem sur le pas de temps t est représenté par la variable binaire y_t^G . Elle est égale à 1 (resp. 0) si le gensem est en marche (resp. à l'arrêt). Étant donné l'état, y_0^G , dans lequel le gensem se trouvait à la fin de l'horizon précédent et le nombre d'instants, t_0^G , pendant lesquels il s'est trouvé dans cet état, la durée minimale de marche (resp. d'arrêt) du gensem peut être exprimée par [Viana 2013] :

$$y_t^G = y_0^G, \quad \forall t = 1, \dots, \tau_0 \quad (4.9)$$

avec $\tau_0 = \max(1, t_{off}^{min} - t_0^G)$ si $y_0^G = 0$ et $\tau_0 = \max(1, t_{on}^{min} - t_0^G)$ si $y_0^G = 1$.

Les contraintes (4.9) permettent de fixer l'état du gensem en début d'horizon. Pour le reste de l'horizon, on doit représenter la mise en marche ou à l'arrêt du gensem au moyen de variables binaires additionnelles x_t^{on} et x_t^{off} : si le gensem est mis en marche (resp. à l'arrêt) au pas de temps t , alors il était à l'arrêt (resp. en marche) au temps précédent $t - 1$ et $x_t^{on} = 1$ (resp. $x_t^{off} = 1$). Les variables x_t^{on} et x_t^{off} sont liées aux variables y_t^G par les équations :

$$y_t^G \geq \sum_{i=\tau_t^{on}}^t x_i^{on} \quad \forall t = 1, \dots, T \quad (4.10)$$

$$1 - y_t^G \geq \sum_{i=\tau_t^{off}}^t x_i^{off} \quad \forall t = 1, \dots, T \quad (4.11)$$

$$x_t^{on} \geq y_t^G - y_{t-1}^G \quad \forall t = 1, \dots, T \quad (4.12)$$

$$x_t^{off} = x_t^{on} + y_{t-1}^G - y_t^G \quad \forall t = 1, \dots, T \quad (4.13)$$

avec $\tau_t^{on} = \max(1, t - t_{on}^{min} + 1)$ et $\tau_t^{off} = \max(1, t - t_{off}^{min} + 1)$.

Les bornes de la puissance fournie par le genset sont définies par :

$$y_t^G G^{min} \leq u_t^G \leq y_t^G G^{nom} \quad \forall t = 1, \dots, T \quad (4.14)$$

où G^{min} et G^{nom} représentent les puissances minimale et nominale du genset, respectivement.

4.1.2 La fonction objectif

Dans ce cas d'étude, étant donnés des profils de demande $(L_t)_{t=1}^T$ et de production solaire $(E_t)_{t=1}^T$, l'objectif du contrôle optimal du microgrid off-grid est de trouver la commande $\mathcal{U} = \{u_t^{EL}, u_t^{EB}, u_t^G, u_t^B\}_{t=1}^T$ qui minimise le coût de son exploitation

$$J = J_{gen}^{fuel} + J_{load}^{tracking} + J_{gen}^{on} \quad (4.15)$$

Ce coût a 3 composantes : le coût J_{gen}^{fuel} de consommation de carburant par le genset, $J_{load}^{tracking}$ les pénalités de sur-production, et J_{gen}^{on} les pénalités de démarrage du genset. Le coût lié à la consommation s'exprime [Barley 1995] :

$$J_{gen}^{fuel} = \delta \pi_F \sum_{t=1}^T \left(C_F^{idle} + \frac{u_t^G}{G^{nom}} (C_F^{nom} - C_F^{idle}) \right) \quad (4.16)$$

avec π_F le coût unitaire de carburant, et C_F^{nom} et C_F^{idle} les valeurs de consommation de carburant nominale et lorsque le genset est en inactivité.

Les pénalités de sur-production sont proportionnelles à la déviation de la production par rapport à la demande :

$$J_{load}^{tracking} = \lambda_1 \sum_{t=1}^T u_t^{dev} \quad (4.17)$$

avec λ_1 le coefficient de pénalisation.

Les pénalités de démarrage du genset sont proportionnelles au nombre d'allumage du genset :

$$J_{gen}^{on} = \lambda_2 \sum_{t=1}^T x_t^{on} \quad (4.18)$$

avec λ_2 le coefficient de pénalisation.

La dégradation de l'état de santé de la batterie peut également être considérée explicitement dans la fonction objective comme une quatrième composante de coût. Ce coût étant négligeable à l'échelle d'une journée, nous ne le considérons pas dans notre modèle de contrôle.

4.1.3 Le modèle complet

Le modèle de contrôle que nous considérons pour un microgrid off-grid correspond au programme linéaire en nombres entiers (P_{hybrid}) suivant:

$$\begin{aligned}
P_{hybrid} : \quad & \max_{\mathcal{U}} \sum_{t=1}^T \left(\delta \pi_F (C_F^{idle} + \frac{u_t^G}{C_{nom}^G} (C_F^{nom} - C_F^{idle})) + \lambda_1 u_t^{dev} + \lambda_2 x_t^{on} \right) \\
\text{s.t.} \quad & \eta_{PV}^{inv} u_t^E + u_t^B + u_t^G = u_t^L, \quad t = 1, \dots, T \\
& u_t^{dev} = u_t^L - L_t, \quad t = 1, \dots, T \\
& soc_t - soc_{t-1} = \frac{\delta}{B_{nom}} (\eta_c u_t^{EB} - \frac{u_t^B}{\eta_d}), \quad t = 1, \dots, T \\
& \sum_{i=\tau_t^{on}}^t x_i^{on} \leq y_t^G, \quad t = 1, \dots, T \\
& \sum_{i=\tau_t^{off}}^t x_i^{off} \leq 1 - y_t^G, \quad t = 1, \dots, T \\
& y_t^G - y_{t-1}^G \leq x_t^{on}, \quad t = 1, \dots, T \\
& x_t^{on} + y_{t-1}^G - y_t^G = x_t^{off}, \quad t = 1, \dots, T \\
& y_t^G = y_0^G \quad t = 1, \dots, \tau_0 \\
& u_t^{EL} + u_t^{EB} \leq E_t, \quad t = 1, \dots, T \\
& 0 \leq u_t^B \leq y_t^B B_d^{max}, \quad t = 1, \dots, T \\
& 0 \leq u_t^{EB} \leq (1 - y_t^B) B_c^{max}, \quad t = 1, \dots, T \\
& soc^{min} \leq soc_t \leq soc^{max}, \quad t = 1, \dots, T \\
& y_t^G G^{min} \leq u_t^G \leq y_t^G G^{nom}, \quad t = 1, \dots, T \\
& u_t^L \geq 0, u_t^{EL} \geq 0, \quad t = 1, \dots, T \\
& y_t^G, y_t^B \in \{0, 1\}, \quad t = 1, \dots, T.
\end{aligned}$$

4.2 Résolution, résultats et discussion

4

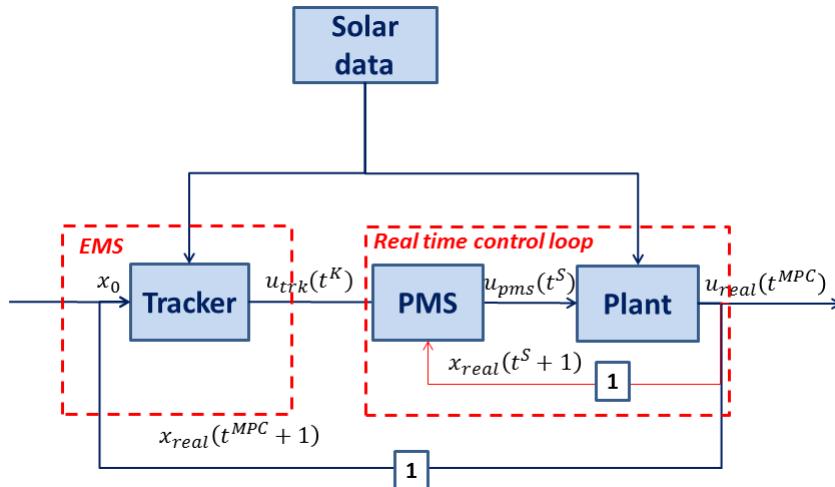


FIGURE 4.2: Système EMS avec le Tracker comme seul composant de l'EMS.

Dans cette partie nous allons présenter les résultats de résolution du modèle (P_{hybrid})

130

À ce stade, notre système EMS a la structure de la figure 4.2. Le système est composé de l'EMS couplé à une boucle de contrôle temps réel. Cette dernière est composée d'un système de gestion de puissance (Power Management System ou PMS, en anglais), dont le rôle est d'appliquer la commande optimale au microgrid désigné par Plant. L'EMS possède un seul composant, appelé Tracker ou *contrôleur*: il est chargé de résoudre le modèle (P_{hybrid}) et d'envoyer la commande optimale au PMS. Il prend en entrée : l'état réel du microgrid, comme état initial, et les profils de demande et de prévision solaire sur un horizon donné.

4.2.1 Cadre de simulation

- 131** Pour les besoins de reproductibilité des simulations, nous n'avons pas testé l'EMS directement en production, sur le microgrid réel, mais sur une simulation numérique de celui-ci. Plant désigne donc, dans ces simulations, un modèle numérique du microgrid réel (ou simulateur), développé sous MATLAB/Simulink®.
- 132** Les différents composants de la boucle de contrôle agissent sur des échelles de temps différentes. Il est de plus nécessaire de distinguer plusieurs dimensions de temps : l'instant où le composant est exécuté, l'horizon de planification sur lequel il calcule une décision, et l'horizon de contrôle définissant le temps de validité de la commande qu'il émet.

Ainsi, concernant le Tracker, sa fréquence d'exécution coïncide généralement avec la régénération des données de prévision solaire, mais il y a un avantage à exécuter le Tracker plus fréquemment pour mieux tenir compte de l'état réel du système et gommer les erreurs du modèle. C'est le principe même de l'approche MPC, que nous discuterons plus en détail au chapitre 5. Nous appliquons dans le présent cas d'étude, une fréquence d'exécution du Tracker de 15 minutes, soit 96 exécutions pour une journée débutant à minuit. L'horizon de planification débute à la date d'exécution (ou à la minute d'après) jusqu'à la fin de la journée à minuit. Le dernier instant de l'horizon étant fixe, l'horizon raccourcit à chaque nouvelle exécution du Tracker. Une alternative serait d'implémenter un horizon *glissant* d'une durée constante de 24h. Ce qui veut dire qu'à midi d'un jour J , on optimise jusqu'à midi du jour $J+1$. Nous n'implémentons pas cette stratégie, car elle nécessite de disposer de données de prévision sur ce même horizon glissant ; ce qui n'est pas le cas du microgrid étudié. Le pas de discrétisation δ est fixé à 1 minute, et donc T varie de 1440 à 15 entre la première et dernière exécution de la journée. L'horizon de contrôle est lui égal à 15 minutes : seules les 15 premières valeurs $u_t \forall t = 1, \dots, 15$ de la commande optimale sont transmises, l'une après l'autre, à la boucle de contrôle temps quasi-réel PMS+Plant.

Cette boucle de contrôle est ainsi appelée toutes les minutes en prenant en entrée la commande optimale du Tracker pour la minute suivante. Elle est donc exécutée 1440 fois en une journée. À l'intérieur de la boucle de contrôle, PMS et Plant sont exécutés chaque seconde, soit 60 fois, et produisent/réalisent une décision de commande pour la seconde. Le choix des fréquences d'exécution relève du producteur et, en pratique, elles peuvent être plus rapides s'approchant ainsi vraiment du temps réel.

- 133** Nous considérons un microgrid fictif, de puissance crête de 2500 kW, installé dans le sud de la France ; la capacité nominale de la batterie est de 4500 kWh, la

puissance nominale du gенset est de 1750 kW et sa puissance minimale est de 525 kW. La courbe de charge est donnée.

Les simulations ont été réalisées sur un ordinateur Intel Core i7-6700HQ Octa-Core cadencé à 2.6 GHz et ayant une RAM de 16 Go. 134

4.2.2 Résultats et discussion

Les simulations ont porté sur 24 jours de l'année 2013. Comme mentionné dans l'introduction à ce chapitre, notre objectif est de vérifier que le modèle P_{hybrid} résout bien le problème de contrôle optimal du microgrid isolé, et que la solution optimale obtenue est applicable. 135

À chaque exécution du Tracker, il reçoit la demande u^L est fournie au , qui détermine le plan de production, pour le reste de l'horizon. La première valeur de ce plan, correspondant à la consigne de production à l'instant présent, est envoyée au PMS, qui se charge de l'appliquer à Plant. À cause de la stratégie de rétroaction, le plan de production déterminé par le Tracker, à sa présente exécution, peut différer de celui de sa précédente exécution. On entend par « plan global de production » u_{trk} , le profil formé par la suite des commandes envoyées par le Tracker au PMS, en vue de l'application à Plant. 136

À chaque application d'une commande de production à Plant, celui-ci retourne la production observée (ou réelle) u_{real} . En fin d'horizon, nous avons donc un profil de production réelle.

La figure 4.3 présente les profils de la demande u^L , du plan global de production u_{trk} , et de la production réelle u_{real} , pour 2 instances. Comme on peut le voir, sur les profils de 2 instances, le Tracker produit un plan de production u_{trk} , qui satisfait bien la demande u^L , sur tout l'horizon. On remarque qu'en début d'horizon, le Tracker prévoit une suproduction. En effet, puisqu'au début de l'horizon, l'état de charge de la batterie est quasiment nul, on engage le gенset ; ce dernier fournit au moins sa puissance nominale, et celle-ci s'avère supérieure à la demande. Nous observons pratiquement le même schéma pour toutes les instances. On observe cependant que la production réelle u_{real} s'écarte du plan de production (donc de la demande), à diverses périodes de la journée, plus généralement en début d'horizon. Pire, c'est une sous-production, c'est-à-dire que la demande n'est pas satisfaite. En effet, le modèle de la puissance à fournir par le gенset, à un instant donné, implémenté dans le simulateur, est totalement en opposition avec le modèle implanté dans le Tracker. Une différence importante est que, même si le simulateur conçoit que la puissance instantanée du gенset est comprise entre une valeur minimale et une valeur maximale (qui est sa valeur nominale), il impose d'autres contraintes à cette puissance, que nous n'avons pas retrouvées dans la littérature sur le contrôle des gенsets par programmation mathématique. Une de ces contraintes consiste à délester littéralement la charge, en arrêtant le gенset lorsqu'une condition sur la commande et la puissance, à l'instant précédent, est vérifiée. C'est cette contrainte qui explique que le gенset n'est réellement pas engagé, alors que le Tracker avait prévu qu'il le soit. Aussi, étant donné que le gенset doit obligatoirement conserver son état pendant une durée fixée, chaque délestage dure au moins t_{min}^{off} . Si la batterie n'est pas à mesure de fournir la charge, le microgrid se trouve en sous-production.

La figure 4.4 présente les profils du plan global de production u_{trk} , et de la 138

contribution de chaque composant du microgrid, pour 2 instances. On observe que le gенset (en rouge) n'est engagé qu'en début d'horizon, à cause de l'indisponibilité de la batterie (en bleu), et en période de pointe, entre 6:00 PM et 9:00 PM. Le nombre relativement faible de démarrage (4 en moyenne) du gенset est dû aux pénalités de démarrage du gенset. Le productible PV (en violet) est naturellement utilisé entre 7:00 AM et 6:00 PM pour charger la batterie et fournir la charge. La batterie, quant à elle, est majoritairement sollicitée en fin d'horizon.

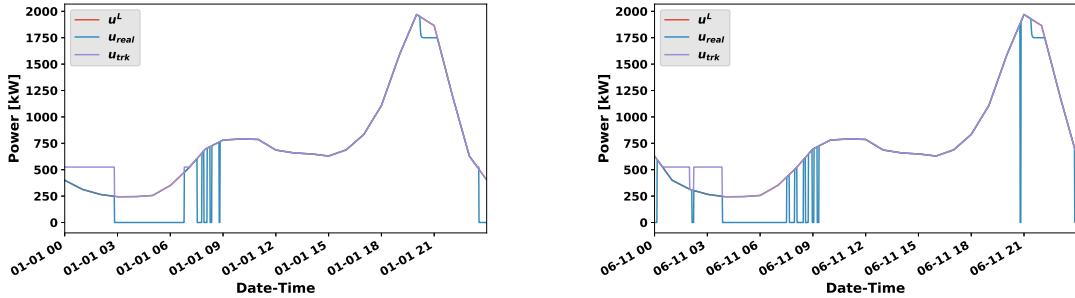


FIGURE 4.3: Profils de la demande u^L , du plan global de production u_{trk} et de la production réelle u_{real} , pour 2 instances.

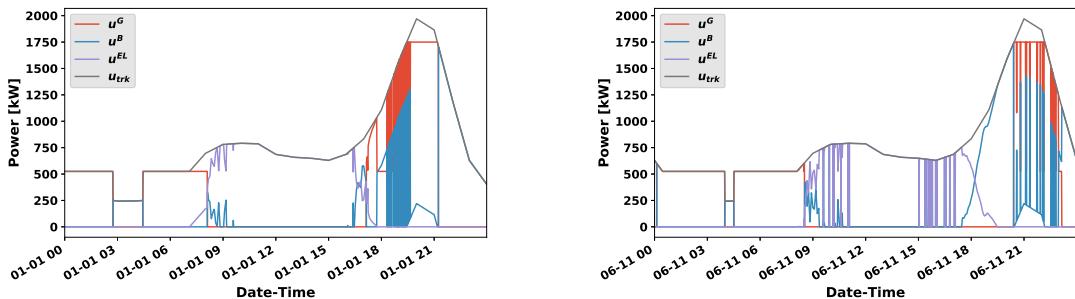


FIGURE 4.4: Profils du plan global de production u_{trk} , et de la contribution de chaque composant, pour 2 instances.

139

Nous avons relevé les valeurs du temps de résolution du Tracker, quand il est exécuté avec un horizon de 24 h, pour les 24 instances de test. En moyenne, le Tracker met environ 17.87 s (avec un écart-type de 10.28 s) pour résoudre le problème à l'optimum. Ses temps de résolution minimal et maximal sont de 4.2 s et 38.38 s, respectivement. Puisque pour cette application, nous n'avons pas de contrainte de temps, ces temps de résolution sont acceptables. Il est toutefois important de noter qu'en raison de la présence d'un grand nombre de variables binaires, si le problème devient large, par exemple avec plusieurs générateurs, la complexité algorithmique serait exponentielle et le solveur pourrait ne jamais résoudre le problème. Si ces variables binaires sont ignorées (ce qui n'est pas réel), le problème se réduirait à un problème de flot de complexité polynomiale, donc résoluble en temps raisonnable.

4.3 Conclusion

Nous concluons que la programmation mathématique permet de résoudre, à l'optimum, le problème de contrôle optimal des microgrids off-grid. Cette conclusion est conforme à la littérature sur cette application. Nous avons observé des temps de résolution en moyenne autour de la demi-minute. Étant donné que ce n'est pas du contrôle temps réel (rôle du PMS), ces temps observés sont faibles, donc acceptables. 140

Cependant, nous avons observé de fréquentes déviations entre le plan global de production, déterminé par le Tracker, et la production observée après application de ce plan à Plant. Et ce, malgré la stratégie de rétroaction, qui réduit les erreurs de modélisation inhérentes au Tracker. Ces déviations sont dues à l'inadéquation entre l'ensemble {PMS, simulateur} et le modèle physique du Tracker. Dans cette application, les conséquences de cette inadéquation sont difficilement compensables par la rétroaction, à cause des contraintes fortes, telles que les contraintes de durée minimale de marche/arrêt du genset. Nous verrons au chapitre suivant, que ce problème ne se pose pas dans le cas d'un microgrid connecté réseau. 141

Le Tracker développé dans ce chapitre ne peut donc pas être directement déployé en production avec le PMS utilisé. Ce dernier doit être adapté au Tracker, en supprimant les contraintes, qui ne sont pas justifiées par la pratique. 142

5

Contrôle optimal des microgrids connectés réseau

Sommaire

- 5.1 Contexte
- 5.2 Modélisation mathématique du problème
- 5.3 Résolution, résultats et discussion
- 5.4 Conclusion

5.1 Contexte

Nous traitons maintenant le cas du contrôle optimal d'un microgrid connecté réseau. **143**
C'est le type de microgrid qu'on rencontre le plus souvent dans zones ayant accès au réseau principal. Ces microgrids ont l'avantage de pouvoir soutirer de l'électricité sur le réseau, en cas de défaut et ne nécessitent donc pas de générateur diesel comme secours.

Depuis plusieurs années, la Commission française de régulation de l'énergie (CRE¹) **144** a lancé un appel d'offres portant sur la réalisation et l'exploitation d'installation de microgrids d'une puissance supérieure à 100 kWc et situés dans les zones non interconnectées (ZNI), principalement les îles françaises. L'appel publié en 2015 contient un chapitre innovation dans le domaine du solaire, où les producteurs sont invités à proposer des solutions innovantes qui donneraient plus de valeur à leurs soumissions. La conception d'EMS fait partie des types d'innovation recherchés.

Dans ce paradigme, que nous notons AOCREZNI15 par la suite, chaque producteur a l'obligation de vendre toute l'électricité produite par son microgrid, après déduction de son autoconsommation qu'il devra justifier. Il y a donc un acheteur obligé, c'est le gestionnaire de réseau. Le tarif de l'électricité est fixé et constant sur tout l'horizon sauf pendant la période de pointe du soir où le tarif est majoré.

Le producteur a la possibilité d'acheter de l'électricité auprès du gestionnaire de réseau à tout moment à hauteur de 10% de la puissance installée de son microgrid. Les tarifs d'achat et de vente sont les mêmes.

Ce qui fait la particularité de ce paradigme, et qui le rend général, est qu'au lieu de fournir une courbe de demande au producteur, on exige de ce dernier de prendre, la veille, un *engagement* de production sur l'horizon de la journée du lendemain, i.e. en *day-ahead*. L'objectif du contrôle dans ce contexte est donc de satisfaire, au lieu d'un profil de demande, l'engagement de production pris la veille. Une marge de déviation de la production par rapport à l'engagement est tolérée, au-delà de laquelle le producteur encourt des pénalités financières.

Dans ce chapitre, nous supposerons que l'engagement a été déterminé par un **145**

¹<https://www.cre.fr>

processus en amont. C'est donc une donnée du problème de contrôle considéré ici. Le problème de détermination de l'engagement sera considéré au chapitre 6.

146 Le problème de contrôle diffère donc du cas off-grid considéré au chapitre 4, principalement par l'absence des contraintes opérationnelles associées au genset et par la fonction de coût qui intègre un modèle de pénalités plus sophistiqué. Ainsi, comme pour le cas off-grid, nous abordons le problème de contrôle par une approche de programmation mathématique. La section 5.2 décrit le modèle de programmation mathématique — quadratique convexe dans ce cas — intégré dans le composant Tracker de notre EMS. Comme dans le chapitre précédent, nous proposons ensuite, dans la section 5.2, d'évaluer précisément l'efficacité de l'approche — notamment sa capacité à fournir, rapidement, des solutions implémentables de coût minimal —, en simulant un cadre d'exécution réel, c'est à dire: appliqué à un microgrid existant (implanté dans les Antilles françaises) et des données historiques d'ensoleillement observées, intégré à la boucle de contrôle du microgrid en association avec le PMS et une simulation numérique fiable du microgrid. De plus, nous proposons de comparer ce contrôle optimal de type boîte blanche à une approche de contrôle standard, de type boîte noire, couplant simulation et algorithme génétique.

5.2 Modélisation mathématique du problème

5.2.1 Les contraintes

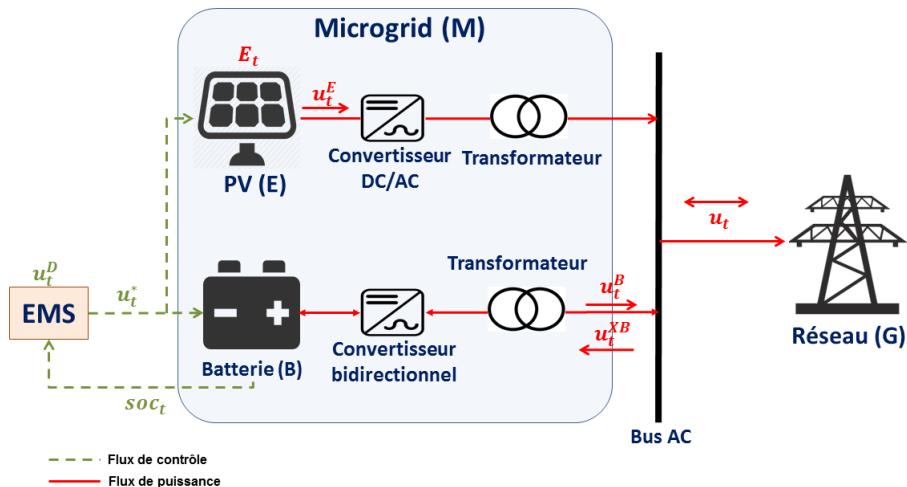


FIGURE 5.1: Microgrid échangeant de l'énergie avec le réseau.

Le microgrid considéré peut être représenté comme sur la figure 5.1. Il est composé d'un champ PV, d'une batterie et de composants électroniques. Comme dans la figure 4.1 du microgrid off-grid étudié au chapitre précédent, on retrouve u_t^E , u_t^B , u_t^{XB} désignant, respectivement, les flux de puissance fournie par le champ PV, fournie par la batterie et reçue par la batterie, et supposés constants sur chaque pas de temps $t = 1, \dots, T$.

Le microgrid peut à tout moment, soit *injecter* (i.e. fournir) de la puissance au réseau, soit lui en *soutirer*. La puissance échangée sur un pas de temps $t = 1, \dots, T$ est symbolisée dans notre modèle par la variable u_t . On convient que u_t

est négative en cas de soutirage et positive en cas d'injection et qu'elle a des bornes fixées proportionnelles à la puissance crête installée P du microgrid:

$$-0.1P \leq u_t \leq 0.75P \quad \forall t = 1, \dots, T \quad (5.1)$$

L'équilibre du réseau est ainsi défini par l'équation :

$$\eta_{PV}^{inv} \eta_{PV}^{trs} u_t^E + \eta_{Bat}^{trs} (u_t^B - u_t^{XB}) - u_t^{MX} = u_t \quad \forall t = 1, \dots, T \quad (5.2)$$

où les paramètres η_{PV}^{inv} , η_{PV}^{trs} et η_{Bat}^{trs} sont les rendements (valeurs comprises entre 0 et 1) du convertisseur du champ PV, du transformateur à la sortie du champ PV et du transformateur à la sortie de la batterie, respectivement. Ce modèle considère également des pertes en puissance dues au refroidissement des composants (convertisseurs, transformateurs, etc.), agrégées en une variable u_t^{MX} et qui s'expriment par la relation :

$$u_t^{MX} \geq \frac{(1 - \eta_{Bat}^{trs} \eta_{PV}^{inv}) u_t^E + (1 - \eta_{Bat}^{trs}) (u_t^B + u_t^{XB})}{cop} \quad \forall t = 1, \dots, T \quad (5.3)$$

où cop est le coefficient de performance de refroidissement.

Les autres contraintes du modèle s'expriment comme dans le cas off-grid : la contrainte d'écrêtage :

$$u_t^E \leq E_t \quad \forall t = 1, \dots, T \quad (4.4)$$

avec E_t la puissance instantanée du PV ; l'équation aux différences :

$$soc_t = soc_{t-1} + (\eta_c u_t^{XB} - \frac{u_t^B}{\eta_d}) \frac{\delta_t}{B^{nom}} \quad \forall t = 1, \dots, T \quad (4.5)$$

avec soc_0 l'état de charge initial de la batterie, et soc_t son état de charge à chaque instant t , dont les bornes sont fixées :

$$soc^{\min} \leq soc_t \leq soc^{\max} \quad \forall t = 1, \dots, T \quad (4.6)$$

La charge et la décharge de la batterie ne peuvent pas s'effectuer au même instant. On peut assurer cette contrainte par les équations (4.7) et (4.8) définies au chapitre 4.

5

5.2.2 La fonction objectif

L'objectif du contrôle est de maximiser l'utilité du producteur, telle que définie par l'AOCREZNI15, c'est-à-dire son profit journalier J égal à la différence entre les revenus de la vente d'électricité injectée, et la somme du coût d'achat d'électricité soutirée et des pénalités d'écart à l'engagement.

147

Le tarif de l'électricité échangée entre le réseau et le microgrid est le même en injection et en soutirage à un instant donné. Ce tarif π_t , constant en journée mais majoré sur la période de pic du soir de 19h à 21h, s'établit en €/kWh :

$$\pi_t = \begin{cases} 0.38 & \text{si } 1140 \leq t \leq 1259 \\ 0.18 & \text{sinon.} \end{cases}$$

Par conséquent, le profit hors pénalités est une fonction linéaire de la puissance injectée/soutirée :

$$\sum_{t=1}^T \delta\pi_t u_t \quad (5.4)$$

où δ désigne la durée d'un pas de temps en heure.

L'AOCREZNI15 définit les pénalités d'écart entre la puissance fournie et la puissance engagée à un instant t par $\delta\pi_t C(u_t, u_t^D)$ avec

$$C(u_t, u_t^D) = \begin{cases} 0 & \text{si } d_t^- \leq u_t \leq d_t^+ \quad (\text{Engagement respecté}) \\ u_t & \text{si } d_t^+ < u_t \leq 0.75P \quad (\text{Surproduction}) \\ \frac{(u_t - d_t^+)^2 - (d_t^- - d_t^+)^2}{P} & \text{si } -0.1P \leq u_t < d_t^- \quad (\text{Sousproduction}) \end{cases} \quad (5.5)$$

où $d_t^- = u_t^D - 0.05P$ et $d_t^+ = u_t^D + 0.05P$ définissent la marge de tolérance de déviation autour de la valeur u_t^D de l'engagement, avec $-0.05P \leq u_t \leq 0.7P$.

148 L'utilité du producteur s'exprime donc par :

$$J = \sum_{t=1}^T \delta\pi_t (u_t - C(u_t, u_t^D)) \quad (5.6)$$

Sachant que $\delta\pi_t > 0$ pour tout t , analysons les fonctions $\phi(u_t, u_t^D) = u_t - C(u_t, u_t^D)$ et $\phi_t(u_t) = \phi(u_t, u_t^D)$ sur leurs ensembles de définition respectifs, définis par $u_t \in [-0.1P, 0.75P]$ et $u_t^D \in [-0.05P, 0.7P]$. Ces fonctions sont représentées sur la figure 5.2, et s'écrivent analytiquement :

$$\begin{cases} (u_t - \frac{(u_t - d_t^+)^2 - (d_t^- - d_t^+)^2}{P}) & \text{si } -0.1P \leq u_t < d_t^- \quad (\text{Sousproduction}) \\ u_t & \text{si } d_t^- \leq u_t \leq d_t^+ \quad (\text{Engagement respecté}) \\ 0 & \text{si } d_t^+ < u_t \leq 0.75P \quad (\text{Surproduction}) \end{cases} \quad (5.7)$$

La figure 5.2 illustre, à gauche, la fonction ϕ lorsque u_t et u_t^D varient sur leurs ensembles de définition respectifs, sans restriction, et, à droite, la fonction ϕ_t définie par morceaux en fonction de u_t pour u_t^D fixé (à 500W), en rouge, et en bleu son approximation (par excès) par le prolongement de sa composante quadratique.

Proposition 1 La fonction $\phi_t(u_t)$ est concave et strictement croissante sur $[-0.1P, d_t^+]$ et continue sur l'intervalle ouvert $] -0.1P, d_t^- [$

Démonstration: ϕ_t est évidemment concave, continue et strictement croissante sur l'intervalle ouvert $]d_t^-, d_t^+[$ puisqu'elle y est linéaire $\phi(u) = u$. Sur l'intervalle $] -0.1P, d_t^- [$, ϕ_t est dérivable, donc continue, et on a :

$$\phi'_t(u) = 1 - \frac{2}{P}(u_t - d_t^+) > 0 \iff u < \frac{P}{2} + d_t^+ \quad (5.8)$$

La dérivée est donc toujours strictement positive et la fonction strictement croissante pour $u \leq d_t^-$. Par ailleurs, la dérivée seconde $\phi''_t(u) = -2/P$ est négative donc la

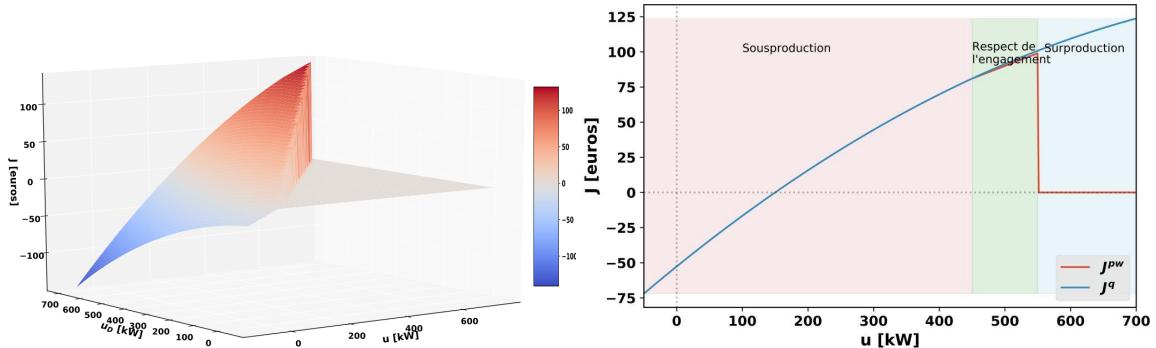


FIGURE 5.2: Graphes des composantes $\phi(u_t, u_t^D)$ (à gauche) et $\phi_t(u_t)\phi(u_t, 500)$ (en rouge à droite) de la fonction objectif et de l'approximation quadratique $\phi_t^0(u_t)$ (en bleu à droite).

fonction est concave sur ce même intervalle. Par ailleurs, la fonction est continue au point $u = d_t^-$ car:

$$\lim_{u \nearrow d_t^-} \phi_t(u) = d_t^- - \frac{(d_t^- - d_t^+)^2 - (d_t^- - d_t^+)^2}{P} = d_t^- = \phi(d_t^-). \quad (5.9)$$

Ce qui conclue la preuve. ■

La proposition suivante montre que l'on peut restreindre l'espace de faisabilité du problème en ignorant l'état de suproduction, nécessairement sous-optimal, grâce à l'écrêtage.

Proposition 2 Étant donné un profil d'engagement $u_t^D \in \mathbb{R}^T$, il existe une solution au système de contraintes (4.4)-(4.8) et (5.2) qui maximise la fonction objectif (5.6) et telle que $u_t \leq d_t^+$ pour tout $t = 1, \dots, T$.

Démonstration: Ce problème d'optimisation est toujours réalisable : il possède notamment la solution $u = u^E = u^B = u^{XB} = u^{MX} = 0$ avec $soc_t = soc_1$ pour tout $t = 1, \dots, N$. Il est aussi naturellement borné et possède donc au moins une solution optimale $S^* = (u^*, soc^*)$. Supposons qu'il existe $t \leq T$ le dernier instant tel que $u_t^* > d_t^+$. Il s'agit nécessairement d'une période avec un excédent d'injection, puisque $u_t^* > d_t^+ = u_t^D + 0.05P \geq -0.05P + 0.05P = 0$. Si $u_t^{E*} \geq \frac{u_t^* - d_t^+}{\eta_{PV}^{inv}\eta_{PV}^{trs}}$ alors l'intégralité de cet excédent peut être écrêtée. Autrement dit, la solution S' obtenue de S^* en remplaçant u_t^* par d_t^+ , et u_t^{E*} par $u_t^{E*} - \frac{u_t^* - d_t^+}{\eta_{PV}^{inv}\eta_{PV}^{trs}}$, est une solution réalisable et de même coût que S^* , donc optimale. Sinon une partie de l'excédent provient nécessairement de la batterie. On comprend facilement qu'il est possible de conserver cette charge dans la batterie sur l'ensemble des pas de temps ultérieurs à t , quitte à écrêter davantage ou à soutirer moins, pour ne pas dépasser la borne soc^{max} . La solution S' , ainsi obtenue, sera ainsi de même coût minimal que S^* avec $u'_t = d_t^+ < u_t^*$. ■

La proposition 2 indique que l'on peut donc restreindre la borne supérieure des variables u^t :

$$-0.1P \leq u_t \leq d_t^+ \quad \forall t = 1, \dots, T \quad (5.10)$$

Sur ce nouveau domaine, la fonction à maximiser est donc concave, mais elle est constituée de composantes quadratiques $\phi_t^0(u_t) = u_t - \frac{(u_t - d_t^+)^2 - (d_t^- - d_t^+)^2}{P}$ sur $u_t \in$

$[-0.1P, d_t^-]$ (sous-production), et linéaire $\phi_t^1(u_t) = u_t$ sur $u_t \in [d_t^-, d_t^+]$ (satisfaction de l'engagement). Modéliser une fonction objectif définie par morceaux dans un programme mathématique nécessite généralement l'introduction de variables binaires indicatrices du «morceau à considérer», à moins que la fonction objectif à maximiser (resp. à minimiser) ne s'exprime comme le minimum (resp. le maximum) de fonctions polynomiales. En effet, dans ce cas, on peut exploiter l'identité suivante :

$$\max_{u \in U} \min(\phi^0(u), \phi^1(u)) = \max_{u \in U, z \in \mathbb{R}} \{z \mid z \leq \phi^0(u), z \leq \phi^1(u)\}.$$

C'est le cas ici comme le montre la proposition suivante :

Proposition 3 $\phi_t = \min(\phi_t^0, \phi_t^1)$ sur l'intervalle $[-0.1P, d_t^+]$.

Démonstration: En effet, pour tout $u_t \in [-0.1P, d_t^+]$, $\phi_t^0(u_t) - \phi_t^1(u_t) = \frac{(d_t^+ - d_t^-)^2 - (d_t^+ - u_t)^2}{P}$ et on a $0 \leq d_t^+ - u_t \leq d_t^+ - d_t^-$ si $u_t \in [d_t^-, d_t^+]$ et $0 \leq d_t^+ - d_t^- \leq d_t^+ - u_t$ si $u_t \leq d_t^-$, d'où $\phi_t^0(u_t) \geq \phi_t^1(u_t)$ si $u_t \in [d_t^-, d_t^+]$ et $\phi_t^0(u_t) \leq \phi_t^1(u_t)$ si $u_t \in [-0.1P, d_t^+]$. ■

Le modèle P_{ongrid} ci-dessous exploite ainsi cette technique de modélisation.

La figure 5.2 montre, qu'en fait, la fonction objectif peut être approximée par au-dessus (le gain est donc sur-estimé), par une fonction quadratique concave sur tout l'intervalle de définition (en bleu sur la figure), obtenue en prolongeant la définition de la fonction ϕ_t^0 sur l'intervalle $u_t \in [-0.1P, d_t^-]$ à l'intervalle $u_t \in [-0.1P, d_t^+]$, pour tout t . L'erreur maximale obtenue sur un pas de temps t est donc atteinte en $u_t = d_t^+$, et vaut :

$$\delta\pi_t(d_t^+ + -\frac{(d_t^- - d_t^+)^2}{P} - d_t^+) = \frac{\delta\pi_t(u_t^D - 0.05P - (u_t^D + 0.05P))^2}{P} = 0.01P\delta\pi_t.$$

avec, dans notre cas d'étude, $P = 1000$ kW et $\pi_t \leq 0.38$ euros/kW.

5.2.3 Modèles complets

Le modèle de programmation mathématique P_{ongrid} pour le problème de contrôle du microgrid on-grid s'écrit ainsi :

$$\begin{aligned} P_{ongrid} : \quad & \max_{U, z} \sum_{t=1}^T \delta\pi_t z_t \\ \text{s.t.} \quad & z_t \leq u_t - \frac{(u_t - d_t^+)^2 - (d_t^- - d_t^+)^2}{P}, \quad t = 1, \dots, T \\ & \sum_{t=1}^T \delta\pi_t \left[u_t - \frac{(u_t - d_t^+)^2 - (d_t^- - d_t^+)^2}{P} \right] \end{aligned}$$

Comme ils sont souvent négligés dans la littérature, nous ne considérons pas dans ce modèle les rendements des convertisseurs et transformateurs, en posant :

$$\eta_{PV}^{inv} = \eta_{PV}^{trs} = \eta_{Bat}^{trs} = 1.$$

Dans ces conditions, les variables u_t^{MX} sont nulles, et peuvent être supprimées du modèle.

On dérive donc le modèle de programmation quadratique en variables continues P'_{ongrid} suivant :

$$\begin{aligned}
 P'_{ongrid} : \quad & \max_{\mathcal{U}} \sum_{t=1}^T \delta \pi_t \left(u_t - \frac{(u_t - d_t^+)^2 - (d_t^- - d_t^+)^2}{P} \right) \\
 \text{s.t.} \quad & u_t = u_t^E - u_t^{BG} - u_t^{XB}, \quad t = 1, \dots, T \\
 & soc_t = soc_{t-1} - \frac{\delta}{B_{nom}} (\eta_c u_t^{XB} - \frac{u_t^B}{\eta_d}), \quad t = 1, \dots, T \\
 & 0 \leq u_t^E \leq E_t, \quad t = 1, \dots, T \\
 & 0 \leq u_t^B \leq B_d^{max}, \quad t = 1, \dots, T \\
 & 0 \leq u_t^{XB} \leq B_c^{max}, \quad t = 1, \dots, T \\
 & -0.1P \leq u_t \leq u_t^D + 0.05P, \quad t = 1, \dots, T \\
 & soc^{min} \leq soc_t \leq soc^{max}, \quad t = 1, \dots, T.
 \end{aligned}$$

5.3 Résolution, résultats et discussion

Dans cette partie, nous allons présenter des résultats d’simulation de notre EMS, décrit au chapitre 4, équipé d’un module Tracker chargé de la résolution du programme mathématique P_{ongrid} ou de son approximation P'_{ongrid} . Le premier objectif de ces simulations est d’évaluer l’intérêt de l’optimisation avancée du contrôle. Pour se faire, nous comparons un Tracker basé sur l’approche par programmation mathématique (MP) avec un autre basé sur un algorithme génétique couplé à un simulateur (GA).

Par ailleurs, nous proposons d’évaluer l’effet des approximations liées à la modélisation de la dynamique du contrôle par des équations linéaires et quadratiques, en comparant les solutions conceptuelles du programme mathématique avec les solutions réalistes obtenues par application de cette commande via le PMS, et le simulateur numérique Plant.

Afin d’annuler l’impact des erreurs de prévision, nous nous plaçons dans un contexte purement déterministe : nous supposons que le Tracker et le simulateur Plant utilisent les mêmes données solaires, que celles utilisés pour le calcul du profil d’engagement.

Des 365 jours de données solaires sur l’année 2015, dont nous disposons, nous avons extrait un échantillon de 24 instances, à raison de deux instances par mois. Chaque instance est une série temporelle, sur une journée, ayant un pas d’échantillonnage de 6 minutes. Les colonnes de cette série sont : l’irradiation globale horizontale (GHI), l’irradiation directe normale au plan du module PV (DNI), l’irradiation directe horizontale (DHI) et la température ambiante (Ta). L’outil PV-LIB [Holmgren 2018] calcule la puissance PV productible (E_t) $_{t \in [1, T]}$, en veillant au rééchantillonnage à 1 minute. L’horizon T est donc égal à 1440.

5.3.1 Évaluation des erreurs de modélisation du programme mathématique

Pour cette simulation, nous n’évaluons que le modèle du Tracker. Le profil d’en-

149

5

150

151

152

gagement $(u_t^D)_{t \in [1, T]}$ est donc donné (calculé ici au moyen de l'algorithme génétique présenté au chapitre suivant). Le but de cette simulation est d'évaluer l'exactitude des modèles mathématiques par rapport au modèle de référence (le simulateur). Pour cela, on compare la solution optimale conceptuelle $(u, soc, J)_{trk}$ du programme mathématique retournée par le Tracker et la solution réelle (dans ce contexte) $(u, soc, J)_{real}$ retournée par le simulateur après application de la commande du Tracker via le PMS.

153 Nous avons testé 3 réglages pour l'exécution de la boucle de contrôle :

PP : le Tracker est exécuté une seule fois, à minuit et la commande est appliquée sur toute la journée.

P15 : la fréquence d'exécution du Tracker est de 15 minutes, à partir de minuit.

À chaque nouvelle exécution du Tracker, il prend en entrée le nouvel état du microgrid et transmet au PMS la commande pour les 15 prochaines minutes.

N15 : Pareil que **P15**, à la différence que les pertes sont négligées, c'est-à-dire que la variable u^{MX} ainsi que la contrainte (5.3) sont retirées du modèle et les rendements des convertisseurs et des transformateurs sont fixés à 1.

154 Nous proposons d'évaluer la déviation entre la solution du Tracker et la solution réellement observée à travers 3 indicateurs: la différence absolue des profits journaliers, et la déviation moyenne absolue (Mean Absolute Error ou MAE) des profils d'état de charge soc et de commande d'injection/soutirage u :

La différence absolue des profils journaliers (colonnes 1 et 2):

$$\Delta J = |J_{trk} - J_{real}| \quad (5.11)$$

La déviation moyenne absolue des variables soc (colonnes 3 et 4) et des variables u (colonnes 5 et 6):

$$MAE(soc_{trk}, soc_{real}) = \frac{1}{T} \sum_{t=1}^T |soc_{trk} - soc_{real}| \quad (5.12)$$

$$MAE(u_{trk}, u_{real}) = \frac{1}{T} \sum_{t=1}^T |u_{trk} - u_{real}| \quad (5.13)$$

Le tableau 5.1 reporte, pour chacun des 3 réglages, ces 3 indicateurs calculés en moyenne (avg) sur les 24 instances et dans le pire cas (max). Les deux dernières colonnes (J_{real}) du tableau montrent le profit journalier final généré par chaque réglage en moyenne (avg) et son écart-type (stddev).

Nous observons d'abord que les déviations sur l'état de charge de la batterie, la décision de production, sont faibles, même dans le pire-cas **PP**. Les approximations du modèle mathématique MP sont donc raisonnablement exactes, dans ce contexte. Les déviations sont négligeables lorsque MP est résolu chaque 15 min, dans une boucle de rétroaction, (P15 et N15) car, à chaque exécution, le plan de production est réajusté conformément à l'état réel de la centrale Plant, au début de la période.

TABLE 5.1: Déviation entre la solution optimale du Tracker MP et le résultat de production réel, et les profits générés, pour 4 réglages différents.

	ΔJ (€)		Δsoc (%)		Δu (kW)		J (€)	
	avg	max	avg	max	avg	max	avg	stddev
PP	0.3	1.4	3.33	3.92	0.08	0.13	968.6	150.1
P15	0.8	5.9	0.11	0.147	0.06	0.14	996.3	158.2
N15	0.0	0.2	0.09	0.11	0.06	0.09	1000.9	158.3

Ceci montre combien l'exécution fréquente du Tracker rend la gestion globale robuste aux erreurs liées au modèle physique du Tracker. Par ailleurs, il s'avère que les plus faibles déviations sont réalisées par **N15**, lorsque les pertes de la centrale sont négligées, et les rendements des transformateurs sont mis à 1, quoique **P15** semble plus réaliste. Même si cette observation est contre-intuitive, d'un point de vue pratique, elle est valable, car **N15** et **P15** étant des approximations, l'une n'est pas théoriquement meilleure que l'autre. En observant les profits journaliers générés J , on voit que **P15** et **N15** réalisent les profits les plus élevés. Cela n'est pas surprenant, puisque les solutions MP sont toujours optimales (pour le modèle conceptuel), et étant donné qu'elles sont quasiment réalisables pour **P15** et **N15**, elles sont probablement proches des solutions optimales réelles.

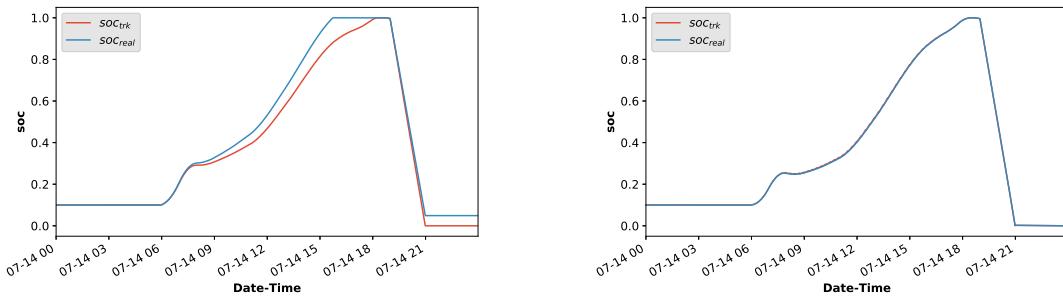


FIGURE 5.3: Profils de l'état de charge pour les réglages **PP** (à gauche) et **N15** (à droite).

La figure 5.3 montre l'impact de l'approximation du modèle du réglage **PP** (figure de gauche), le jour où la plus grande déviation est observée, et comment l'exécution fréquente du Tracker, dans le réglage **N15** annihile quasiment cette déviation (figure de droite). soc^{trk} représente le profil optimal de l'état de charge de la batterie, prévu par le Tracker MP, et soc^{real} représente le profil réel, observé en sortie de Plant. On observe que l'état de charge est sous-estimée dans le réglage **PP**, et que la batterie atteint son état de charge maximal, un peu plus d'une heure plus tôt que prévu. Cette déviation est en moyenne de 3.33%, et au maximum de 3.92%. Elle est considérablement réduite dans le réglage **N15**, à 0.09% en moyenne, et à 0.11% au maximum.

Nous avons fixé à 0 la valeur minimale de l'état de charge de la batterie, c'est pourquoi nous observons que soc_{trk} décroît jusqu'à 0 en fin d'horizon. Cette valeur

pourrait être non nulle (comme c'est généralement le cas dans la pratique) puisque c'est un paramètre du problème.

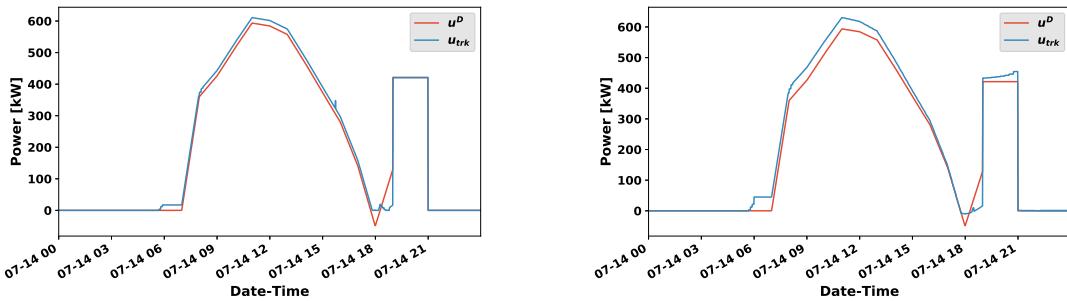


FIGURE 5.4: Profils du plan global de production et de la production réelle, pour les réglages **PP** (à gauche) et **N15** (à droite).

157 Une analyse similaire est faite en observant les profils de la figure 5.4. On voit bien que dans le réglage **PP** (figure de gauche), le profil du plan global de production est supérieur ou égal à celui de la production réelle, hors période de pointe, entre 00:00 et 6:30 PM et 9:00 PM et 11:59 PM, et lui est inférieur entre 6:30 PM et 9:00 PM. Toutefois, cette différence reste dans la plage de tolérance. Dans le réglage **N15** (figure de droite), le profil du plan global de production est toujours supérieur ou égal à celui de la production réelle. Et on voit clairement qu'il fait une meilleure pointe du soir que le réglage **N15**. Cela veut dire que le réglage **N15** est plus profitable que le réglage **PP**.

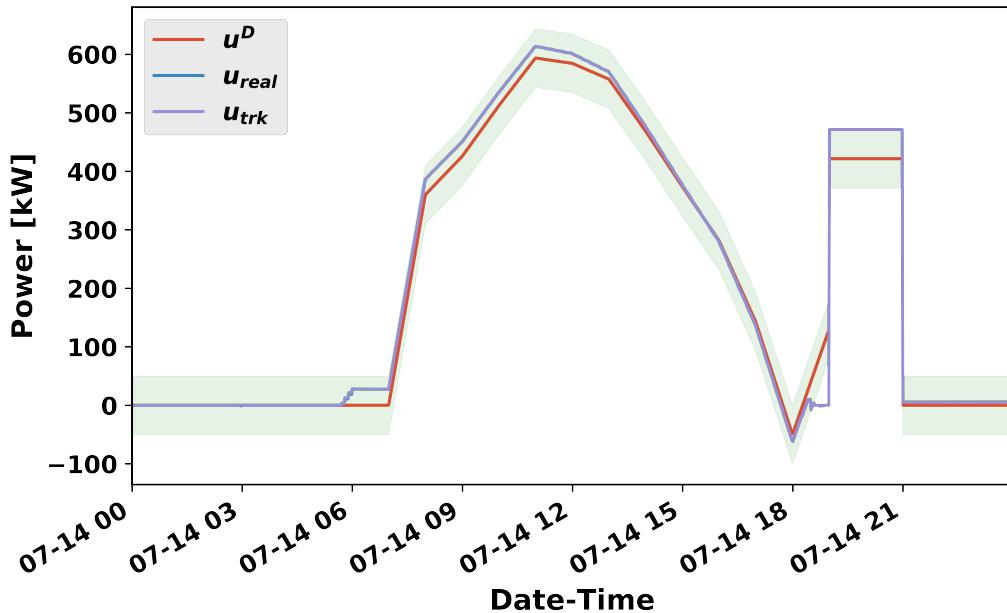


FIGURE 5.5: Exemple de profils d'engagement u^D , plan de production u_{trk} , et production réelle u_{real} .

158 La figure 5.5 montre un exemple de profils d'engagement u^D , plan de produc-

tion u_{trk} , et production réelle u_{real} . Comme on peut le voir, l'erreur absolue, entre l'engagement (courbe rouge) et la production réelle (courbe bleue), oscille entre 0 et 1 kW, est clairement dans la plage de tolérance $[-50 \text{ kW}, 50 \text{ kW}]$. Les profils du plan de production (courbe violette) et de la production réelle sont pratiquement confondus.

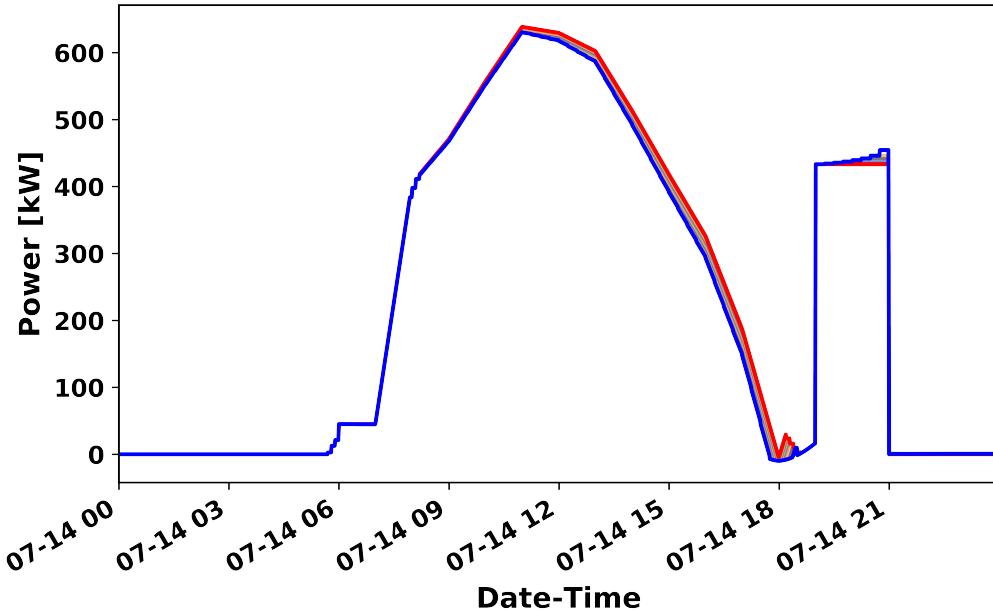


FIGURE 5.6: Profils des plans de production successifs, déterminés par le Tracker au cours d'une journée, pour une instance donnée.

Finalement, la figure 5.6 présente les profils des plans de production successifs, déterminés par le Tracker au cours d'une journée, pour une instance donnée. La courbe en rouge gras représente le plan de production déterminé en début d'horizon, et la courbe en bleu gras représente le plan global de production. Comme on peut le voir, la différence entre ces plans de production s'observe en période où il y a de l'ensoleillement, soit entre 7:00 AM et 6:30 PM (l'instance choisie est un jour très ensoleillé), et en période de pointe du soir. On remarque surtout qu'au fil des replanifications, le Tracker réduit sa production en période d'ensoleillement pour faire une meilleure pointe du soir. À noter qu'étant donné que nous sommes dans un contexte déterministe, la différence entre ces plans de production n'est pas très grande.

Nous avons également testé une plus grande fréquence d'exécution du Tracker, de 15 à 5 minutes, mais nous n'avons pas observé une amélioration significative des résultats.

Pour évaluer l'impact de l'approximation de la fonction d'utilité, nous avons comparé la version de P_{ongrid} (fonction objectif définie par morceaux) sans les pertes et avec les rendements mis à 1, et P'_{ongrid} (fonction objectif quadratique). Les 4 réglages suivants (dans lesquels les rendements sont mis à 1 et les pertes sont négligées) ont été utilisés.

159

5

160

161

TABLE 5.2: Différence moyenne entre la valeur obtenue en évaluant le contrôle optimal par la fonction non approximée (notons-la \hat{J}) et la valeur optimale non approximée J (respectivement la valeur optimale approximée J')

	\hat{J}	$J (J')$	$\hat{J} - J$ ou $\hat{J} - J'$	J_{real}
PW	1025.6	1025.6	0.0	968.6
QQ	1063.5	1025.6	37.9	968.5

TABLE 5.3: Profit journalier réel de chaque réglage, moyenné sur les 24 instances de simulation

	J_{real} (€)	
	avg	stddev
PW	968.6	150.1
PW15	1001.0	158.3
QQ	968.5	150.1
Q15	1000.9	158.2

PW : le Tracker basé sur P_{ongrid} est exécuté une seule fois, à minuit et la commande est appliquée sur toute la journée.

W15 : Pareil que **PW**, à la différence que la fréquence d'exécution du Tracker est de 15 minutes, à partir de minuit.

QQ : le Tracker basé sur P'_{ongrid} est exécuté une seule fois, à minuit et la commande est appliquée sur toute la journée.

Q15 : Pareil que **QQ**, à la différence que la fréquence d'exécution du Tracker est de 15 minutes, à partir de minuit.

Les résultats moyennés sur les 24 instances, sont consignés dans les tableaux 5.2 et 5.3. Le premier tableau présente, pour les réglages **PW** et **QQ**, la différence moyenne entre la valeur obtenue en évaluant le contrôle optimal par la fonction non approximée (notons-la \hat{J}) et la valeur optimale non approximée J (respectivement la valeur optimale approximée J'), obtenue par la résolution des problèmes P_{ongrid} (respectivement P'_{ongrid}). En effet, dans la configuration **PW**, $\hat{J} = J'$.

Comme on peut le voir sur le tableau 5.2, dans le cas du réglage **QQ**, la différence moyenne entre la valeur optimale du problème, et la valeur de la fonction non approximée, est de 37.9€. Cela justifie la proposition 3. Dans le cas du réglage **PW**, la différence est évidemment nulle, puisque le problème utilise la fonction définie par l'AOCREZNI15, à la seule différence que le domaine de définition de la fonction est restreint à l'intervalle 5.10. La dernière colonne du tableau 5.2 montre que malgré la surestimation observée pour le réglage **QQ**, les résultats réels journaliers des deux réglages sont pratiquement les mêmes.

Le tableau 5.3 montre que les réglages **PW** et **QQ** sont équivalents en profit réel journalier. Il en est de même pour les réglages **PW15** et **Q15**. Ces derniers ayant

TABLE 5.4: Temps de calcul des Tracker MP et GA (en secondes)

	avg	min	max	std
MP	0.718	0.593	0.796	0.158
GA	250.47	224.70	289.18	15.167

un profit moyen d'environ 32€ de plus que les premiers. Cette observation justifie encore le gain apporté par la boucle de rétroaction, exécutée chaque 15 min.

On conclut donc des tableaux 5.2 et 5.3, que l'approximation de la fonction d'utilité, par une fonction quadratique, est une approximation raisonnable, de même performance que le modèle non approximé, mais plus simple.

5.3.2 Comparaison des techniques d'optimisation

Nous proposons ici de comparer les Trackers MP et GA, suivant le profit journalier (figure 5.7) et la temps de calcul (table 5.4). De nouveau, le profil d'engagement est une donnée. Il est déterminé par un algorithme génétique couplé à un simulateur, comme le Tracker GA. En effet, en début d'horizon, le Tracker GA utilise directement l'engagement comme plan de production. Nous supposons, en plus, que ce Tracker embarque la même représentation du simulateur, donc si on néglige le caractère stochastique de l'algorithme génétique, on estime qu'il n'y a aucune nécessité de relancer le Tracker plus d'une fois. Son plan de production est donc directement appliqué à Plant, tout au long de l'horizon, et on obtient ainsi la production réelle en fin d'horizon. Cependant, le Tracker PM est exécuté chaque 15 min, puisque nous avons montré que cela permet de réduire ses erreurs de modélisation : c'est la configuration Q15. Nous rappelons que l'effet des incertitudes de la prévision solaire est annulé, puisque l'on considère le même profil de production solaire que celui utilisé par l'engagement.

La configuration utilisée pour le solveur d'algorithme génétique est : 10 générations et 400 individus. Cette configuration est employée en production.

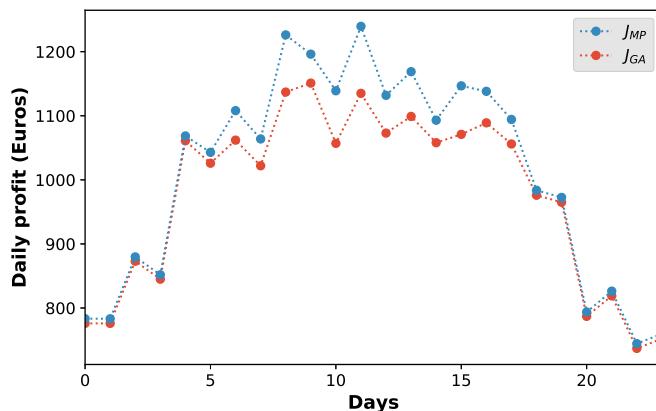


FIGURE 5.7: Profits réels générés par les Trackers MP et GA sur 24 jours.

Comparant les profits générés sur les 24 instances, nous voyons que le Tracker MP (J_{MP} en bleu) est toujours plus profitable que le Tracker GA (J_{GA} en rouge) (jusqu'à 9.7% plus grand, soit environ 110€). Les profits journaliers moyens sont, respectivement, 1001 and 975€, avec un écart-type de 150 et 136€. La différence est significative en pratique, et confirme notre première analyse qu'un modèle très précis de la dynamique du système n'est pas une exigence. Cela met également en évidence l'avantage de résoudre le problème à l'optimum, comparativement à la stratégie sous-optimale de l'algorithme génétique.

En ce qui concerne le temps de calcul, avec une moyenne d'environ 0.718 s (et un écart-type de 0.158 s), le Tracker MP est environ 348 fois plus rapide que le Tracker GA², qui a un temps de calcul moyen de 250.47 s (avec un écart-type de 15.167 s). Toutefois, les deux Tracker sont utilisables en production, puisque le temps alloué pour un calcul est de 15 minutes.

5.4 Conclusion

- 162** Nous avons montré que la programmation mathématique permet de résoudre, à l'optimum, le problème de contrôle optimal des microgrids connectés réseau. Et contrairement au cas off-grid, nous avons observé l'avantage de la rétroaction lorsque le PMS est compatible au Tracker. En effet, nous avons montré que l'exécution fréquente du Tracker, avec le nouvel état de Plant, permet de compenser les erreurs de modélisation du microgrid, que nous réalisons dans le Tracker. Un résultat très important est qu'il n'est pas nécessaire que le Tracker embarque un modèle très précis du microgrid réel, notamment la prise en compte des pertes et de certains rendements.
- 163** Par ailleurs, nous avons observé que le Tracker basé sur un programme mathématique présente de meilleures performances (en profit journalier généré et en temps de résolution) que le Tracker basé sur un algorithme génétique couplé à un simulateur.
- 164** Une des approximations, que nous avons faites dans le programme mathématique, est le passage de la fonction objectif non différentiable, définie dans l'AO-CREZNI15, à une fonction quadratique concave, différentiable en tout point de son ensemble de définition. Cette dernière fonction, bien qu'elle surestime la première, ne dégrade pas les performances du Tracker. Au contraire, elle conduit à un Tracker légèrement plus rapide et à un modèle plus simple, qui facilite le développement de la version robuste du programme mathématique (Chapitre 7).

²Il s'agit ici du temps de calcul du Tracker GA, lorsqu'on lui permet d'effectuer un calcul, un peu après l'instant initial. A priori, il devrait mettre moins de temps que s'il était lancé au début de l'horizon, mais nous négligeons cette différence.

6

Modèle d'engagement

Sommaire

- 6.1 Contexte
- 6.2 Le modèle
- 6.3 Résolution, résultats et discussion
- 6.4 Conclusion

6.1 Contexte

Dans ce chapitre, nous développons un modèle d'engagement optimal basé sur la programmation mathématique dans le cadre de l'AOCREZNI15 et nous le comparons avec les modèles d'engagement basés sur l'algorithme génétique et sur un système expert basique. 165

L'engagement, soumis à des contraintes définies dans l'AOCREZNI15, est déclaré (ou notifié), la veille (*déclaration*), au gestionnaire de réseau. Le lendemain, il est permis au producteur de mettre à jour son engagement trois fois (*redéclarations*). Cela lui permet de rattraper ses erreurs de prévision, dues principalement aux erreurs de prévisions solaires. Comme nous l'avons vu au chapitre 5, pour le Tracker, l'engagement est une « référence » (ou une demande), à laquelle il tente de se rapprocher de façon optimale. 166

D'après ce qui vient d'être dit, le problème du producteur, relatif à la conception d'un EMS, est à deux niveaux : la détermination de l'engagement et le pilotage. Il y a donc deux problèmes d'optimisation à résoudre. Lorsque l'engagement est une donnée, on retombe sur le contrôle optimal classique, que nous résolu au chapitre précédent. 167

À notre connaissance, il y a deux thèses de doctorat et un article liées à ce paradigme. La première thèse — celle qui nous a inspiré tout au long de notre étude — est celle de Pierre Haessig [Haessig 2014]. Il s'agit du dimensionnement et gestion optimale d'un microgrid (à énergie éolienne plutôt que solaire), principalement du stockage. À part qu'il s'est occupé du dimensionnement et nous non, la différence majeure entre nos études est qu'il ne détermine pas d'engagement. Il s'engage sur toute la production éolienne prédictive, choix qui n'est pas nécessairement optimal. La seconde thèse est celle de Laurent Bridier [Bridier 2015], qui résout principalement un problème de dimensionnement optimal du stockage; il n'y a pas non plus de détermination d'engagement. L'article de Pflaum *et al* [Pflaum 2017] est celui qui se rapproche le plus de cette partie. Toutefois, le problème est résolu dans un contexte stochastique et l'objectif est de trouver la dimension optimale de la batterie. 168

6.2 Le modèle

Le modèle d'engagement diffère très peu de celui de contrôle, défini en 5.2.3. Les principales différences sont les suivantes :

- L'engagement u^D est une variable de contrôle (plutôt qu'une donnée). L'optimisation est de déterminer cette quantité.
- L'introduction des contraintes (6.4–6.9) de l'AOCREZNI15 portant sur l'engagement.
- La suppression de la variable et de la contrainte liée aux pertes et le réglage des rendements des convertisseurs à 1. On a vu au chapitre précédent que cette approximation est meilleure.

Le modèle mathématique P_{aocre} pour le problème de gestion optimale du microgrid on-grid, dans le cadre de l'AOCREZNI15 s'écrit ainsi :

$$P_{aocre} : \max_{\mathcal{U}, z} \sum_{t=1}^T \frac{\delta}{60} \pi_t \left(u_t - \frac{(u_t - d_t^+)^2 - (d_t^- - d_t^+)^2}{P} \right) \quad (6.1)$$

$$\text{s.t. } u_t = \eta_{PV}^{inv} u_t^E + u_t^B - u_t^{XB}, \quad t = 1, \dots, T \quad (6.2)$$

$$soc_t = soc_{t-1} + \frac{\delta_t}{B_{nom}} (\eta_c u_t^{XB} - \frac{u_t^B}{\eta_d}), \quad t = 1, \dots, T \quad (6.3)$$

$$-0.05P \leq u_t^D \leq 0.7P, \quad t = 1, \dots, T \quad (6.4)$$

$$-0.003P \leq u_{t+1}^D - u_t^D, \leq 0.006P \quad t \in [0, 599] \quad (6.5)$$

$$-0.003P \leq u_{t+1}^D - u_t^D, \leq 0.003P \quad t \in [600, 638] \quad (6.6)$$

$$-0.006P \leq u_{t+1}^D - u_t^D, \leq 0.003P \quad t \in [839, 1138] \quad (6.7)$$

$$\cup [1260, 1438] \quad (6.8)$$

$$u_t^D \geq 0.2P, \quad t \in [1140, 1259] \quad (6.9)$$

$$0 \leq u_t^E \leq E_t, \quad t = 1, \dots, T \quad (6.10)$$

$$0 \leq u_t^B \leq B_d^{max}, \quad t = 1, \dots, T \quad (6.11)$$

$$0 \leq u_t^{XB} \leq B_c^{max}, \quad t = 1, \dots, T \quad (6.12)$$

$$-0.1P \leq u_t \leq u_t^D + 0.05P, \quad t = 1, \dots, T \quad (6.13)$$

$$soc^{min} \leq soc_t \leq soc^{max}, \quad t = 1, \dots, T \quad (6.14)$$

6.3 Résolution, résultats et discussion

- 169** Dans cette partie, nous présentons les résultats de la résolution du problème P_{aocre} . L'objectif principal est de montrer qu'il est possible de résoudre le problème intégré d'engagement optimal et de contrôle optimal. Ensuite, montrer l'intérêt de l'emploi de techniques d'optimisation avancées, pour résoudre ce problème. Pour ce faire, nous comparons la programmation mathématique et l'algorithme génétique (couplé à un simulateur), à un système basé sur des règles d'expert (RB), que nous appellerons « système expert ». Finalement, montrer que de ces 2 techniques d'optimisation avancées, la programmation mathématique présente les meilleures performances.

6.3.1 Cadre de simulation

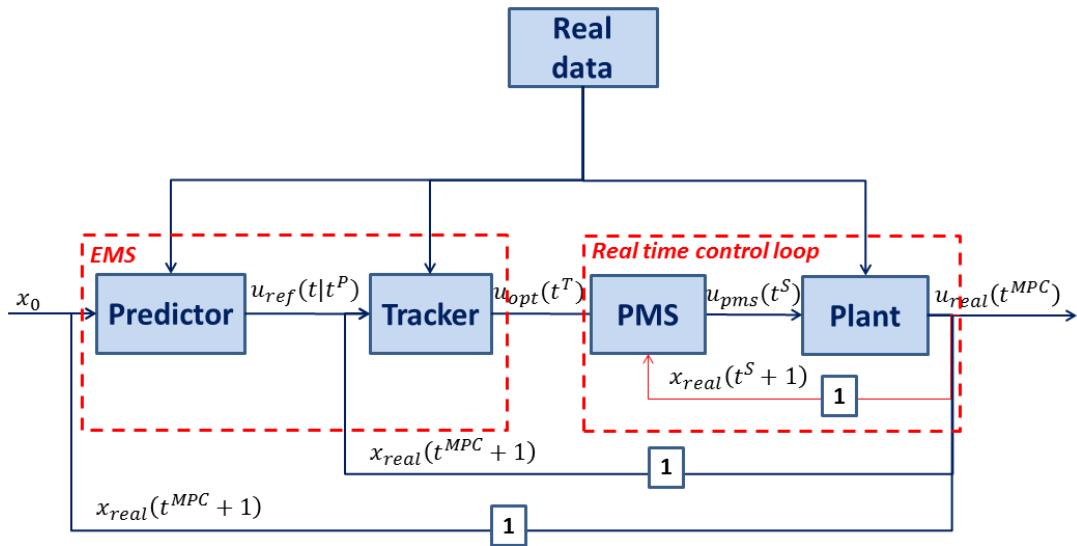


FIGURE 6.1: Système EMS avec le Predictor et Tracker comme composants de l’EMS.

Nous considérons un microgrid réel installé sur une île française, qui peut être 170 représenté par le système sur la figure 5.1. Nous sommes dans le cadre de l’AO-CREZNI15 sauf que les redéclarations ne sont pas considérées. Notez toutefois que notre EMS a été implémenté de sorte à supporter les redéclarations. Elles ne sont juste pas nécessaires pour ces simulations.

La figure 6.1 présente l’architecture du système EMS. La différence entre cette 171 figure et la figure 4.2 est que l’EMS comporte un nouveau composant : le Predictor. C’est ce composant qui est chargé de déterminer l’engagement optimal. Dans le chapitre précédent, nous avons exclusivement utilisé un Predictor basé sur un algorithme génétique couplé à un simulateur (ou Predictor GA). Ici, nous considérons également des Predictors MP et RB. Et plutôt que de comparer séparément les Predictors et les Trackers, nous comparons les EMSs (ensemble Predictor+Tracker). On dira donc EMS MP, GA et RB.

En plus des 2 types d’horizon de temps définis au chapitre 4, on distingue un troisième : *l’horizon de prédiction* [Silvente 2018]. C’est la durée sur laquelle on estime connaître toutes les informations (notamment les prévisions solaires) nécessaires à la prise de décision. C’est l’horizon du Predictor. Dans ce cas d’étude, nous supposons avoir les données de prévision sur toute la journée.

6.3.2 Comparaison programmation mathématique vs algorithme génétique vs système expert

Avant de passer aux résultats des simulations, il convient de présenter maintenant le système expert.

Système expert

Dans la pratique, les producteurs ne se servent pas toujours d’EMS car cela a un coût 173

important. Ils se servent plutôt de connaissances expertes, déduites de l'expérience qu'ils ont acquis dans l'exploitation des microgrids. Ces règles sont généralement myopes, car elles permettent de prendre des décisions sans prise en compte (ou prise en compte partielle) du futur.

174 Nous avons développé un système expert assez simple, dont la stratégie principale est de charger entièrement la batterie quand il y a du soleil (typiquement entre 6:00 AM et 6:00 PM) pour satisfaire les contraintes de pente et de pointe et tirer le meilleur profit de la pointe du soir (entre 7:00 PM et 9:00 PM). Lorsque la batterie est pleine, la production solaire, aux instants suivants, est directement injectée sur le réseau.

En utilisant cette stratégie, et la connaissance de la pente de puissance maximale et des temps de début (10:00 AM) et fin (2:00 PM) de la phase de plateau, de simples calculs algébriques sont utilisés pour déterminer les valeurs des pentes du trapèze et la la valeur de la puissance de pointe, et donc pour déterminer entièrement le profil de l'engagement u^D pour la journée.

La figure 6.2 montre un exemple de profil d'engagement conforme à l'AOCREZNI15. Comme on peut le voir, il a une partie trapézoïdale, composée d'une phase de pente ascendante, d'une phase de plateau et d'une phase de pente descendante, et une partie rectangulaire qui est la période de pointe du soir.

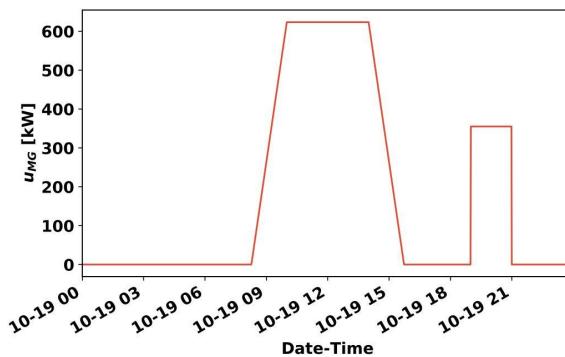


FIGURE 6.2: Un profil d'engagement conforme à l'AOCREZNI15.

175 Avec cette stratégie, le contrôle optimal u_{trk} retourné par le Tracker RB est défini par :

$$u_t = \begin{cases} u^D + 0.05P & \text{si } 1140 \leq t \leq 1259 \\ u^D & \text{sinon.} \end{cases} \quad (6.15)$$

Résultats et discussion

Comme au chapitre 5, la comparaison porte sur les profits réels générés (figure 6.3) et les temps de calcul (tables 6.1 et 6.2) par les 3 EMSs.

Comparant les profits générés sur les 24 instances, nous voyons que l'EMS MP (J_{MP} en bleu) est toujours plus profitable que le l'EMS GA (J_{GA} en rouge). Ce dernier étant toujours plus profitable que l'EMS RB (J_{RB} en violet), sauf pour l'instance 11. Pour quelques instances, notamment 4, 7, 8, 11, 13, 15, 19, 20, 22 et 24, soit pour 42% des instances, J_{MP} , J_{GA} et J_{RB} sont très proches. Cependant, alors que la différence maximale entre J_{MP} et J_{GA} est d'environ 110€, celle entre J_{MP} et J_{RB} est d'environ 400€. Celle différence est très grande, et montre bien l'intérêt des

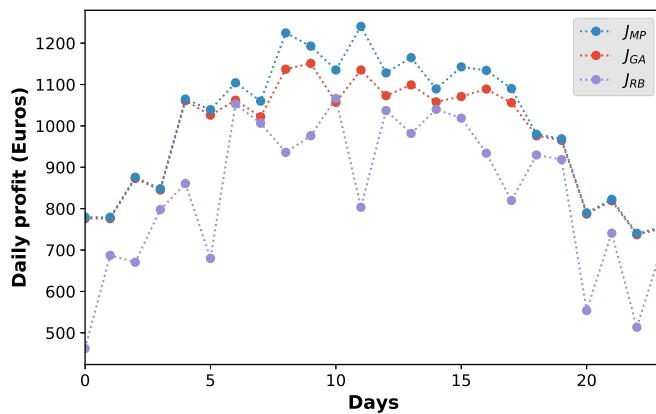
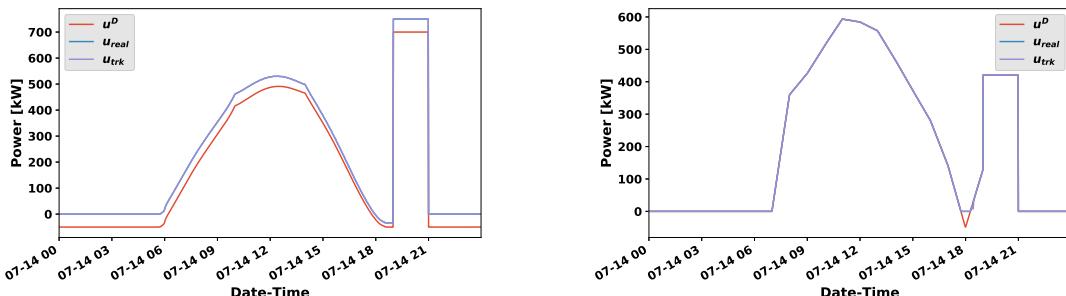


FIGURE 6.3: Profits réels générés par les EMSs MP, GA et RB sur 24 jours.

techniques d'optimisation avancées, telles que la programmation mathématique et l'algorithme génétique. De plus, pour ce cas d'étude, la programmation mathématique est nettement supérieure à l'algorithme génétique (couplé à un simulateur).

Pour une meilleure compréhension de ces valeurs, nous présentons les profils d'engagement u^D , de plan de production u_{trk} , et de production réelle u_{real} , déterminés par les EMSs MP, GA (figure 6.4) et RB (figure 6.5), pour une instance.

FIGURE 6.4: Profils d'engagement u^D , de plan de production global u_{trk} , et de production réelle u_{real} , des EMSs MP (à gauche) et GA (à droite).

L'instance choisie est un jour très ensoleillé. On peut voir sur la figure 6.4 que l'EMS MP exploite mieux la pointe du soir — où le prix de l'électricité est plus important —, que l'EMS GA. Ce dernier exploite plutôt la période où il y a de l'ensoleillement, soit entre 7:00 AM et 5:00 PM. Cela donne l'impression que l'EMS GA est myope. La figure 6.5 (gauche) montre que l'EMS RB fait de même que l'EMS GA ; ce qui corrobore d'ailleurs notre intuition. La figure 6.5 (droite) illustre juste que la décision du Tracker RB est exactement celle du Predictor RB, hors pointe, et majorée de la tolérance de 50 kW, en période de pointe. C'est ce qui est exprimé par l'équation 6.15. La figure 6.6 présente une superposition des profils de production réelle du microgrid, recevant les commandes des EMSs MP, GA et RB. Cette figure illustre clairement la différence entre les performances financières de ces EMS.

Les tableaux 6.1 et 6.2 présentent les temps de calcul des Predictor et Tracker MP, GA et RB, respectivement. Le tableau 6.2 est une réplique du tableau 5.4 du

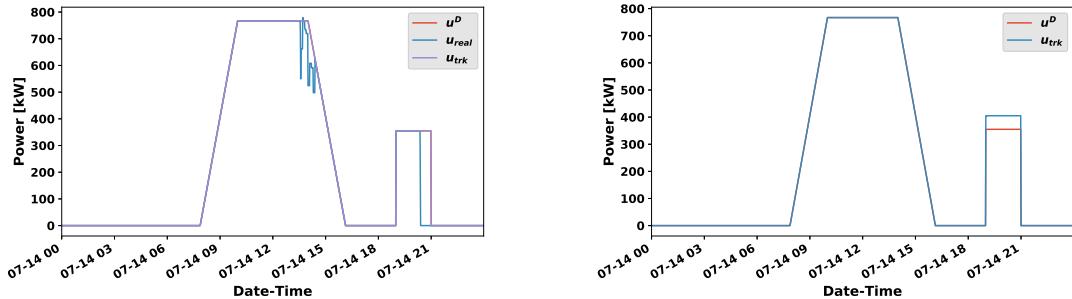


FIGURE 6.5: Profils d'engagement u^D , de plan de production global u_{trk} , et de production réelle u_{real} , de l'EMS RB (à gauche). Profils d'engagement u^D et de plan de production u_{trk} , de l'EMS RB en début d'horizon (à droite).

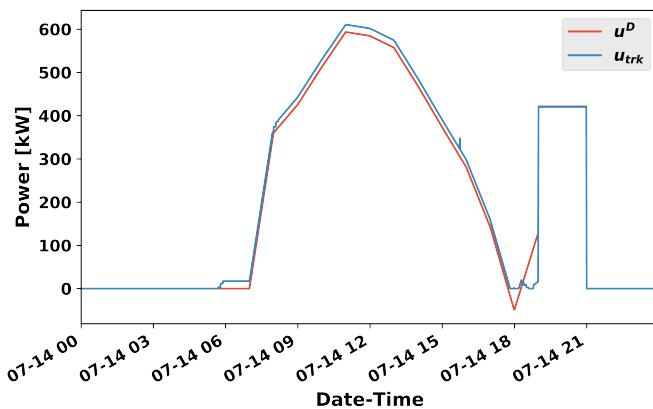


FIGURE 6.6: Profils de production réelle du microgrid des EMSs MP, GA et RB.

TABLE 6.1: Temps de calcul des Predictor MP, GA et RB (en secondes)

	avg	min	max	std
MP	0.810	0.631	0.952	0.165
GA	255.55	225.84	290.21	15.332
RB	0.18	0.15	0.32	0.042

TABLE 6.2: Temps de calcul des Tracker MP, GA et RB (en secondes)

	avg	min	max	std
MP	0.718	0.593	0.796	0.158
GA	250.47	224.70	289.18	15.167
RB	0.16	0.09	0.28	0.039

chapitre précédent, avec une ligne pour le Predictor RB. On observe que même si les Predictors ont un temps de résolution légèrement supérieur à celui des Trackers, cette différence est relativement faible : en moyenne environ 0.1 s pour le cas MP, 5.08 s pour le GA, et 0.02 s pour le RB.

6.4 Conclusion

Dans ce chapitre, le double-problème de contrôle optimal et d’engagement optimal a été résolu en utilisant 3 différentes approches d’optimisation : la programmation mathématique, un algorithme génétique couplé à un simulateur, et un système expert. Les résultats montrent que les 2 premières approches, qui sont des techniques d’optimisation plus avancées que la dernière, présentent de meilleures performances financières ; mais que le système expert est nettement plus rapide puisqu’il n’implémente que quelques règles. Puisque toutes ces techniques résolvent le problème dans le temps alloué (15 min), le choix de l’une d’entre elles doit principalement se faire sur la base du profit journalier généré. Dans ce cas d’étude, la programmation mathématique est le meilleur choix. Par ailleurs, le point important est qu’il y a un gain manifeste à employer des techniques d’optimisation avancées plutôt que des règles d’expert.

Au prochain chapitre, ce même problème est résolu en présence d’incertitudes sur les données de production solaire.

7

Gestion des incertitudes

Sommaire

- 7.1 Le modèle stochastique
- 7.2 Le modèle robuste
- 7.3 Résolution du problème d'optimisation robuste
- 7.4 Résolution, résultats et discussion
- 7.5 Conclusion

C E CHAPITRE s'inscrit dans la suite logique du problème de gestion optimale d'un microgrid. En effet, jusqu'ici nous avons supposé que les données de prévisions solaires sont parfaites. Grâce à cette hypothèse, nous avons conçu un EMS (Predictor+Tracker) déterministe. Cet EMS fonctionne plutôt bien lorsque la production solaire réelle est très proche de celle qui a été prévue. Mais il va sans dire que si la production réelle s'écarte de la production prévue jusqu'à un certain point, la performance de l'EMS se dégraderait. Il faut donc trouver une technique qui permettrait à l'EMS de s'adapter à ce genre de situations. Nous avons vu au chapitre 2 que deux manières d'y arriver sont la programmation stochastique et la programmation robuste. Nous avons donc écrit un modèle pour chacune et les avons comparer.

Dans cette étude, nous ne considérons que les incertitudes liées aux prévisions de la production solaire et leur impact sur l'engagement déterminé par le Predictor. Ce choix se justifie par le fait que le gain du tracking dépend de l'engagement. Il faut donc investir plus de ressources pour améliorer la performance du Predictor plutôt que celle du Tracker. Une autre raison de la non considération du Tracker est que la stratégie MPC compense les erreurs de prévisions au niveau du Tracker.

Nous utilisons le terme générique EMS robuste pour désigner l'EMS avec un Predictor stochastique ou robuste, indifféremment. l'EMS robuste est une extension de l'EMS développé au chapitre 6.

7.1 Le modèle stochastique

Le problème de détermination de l'engagement peut être vu comme un problème à deux étages : calcul de l'engagement et pilotage. Lors du calcul de l'engagement, on dispose de prévisions solaires (sous forme de scénarios) : c'est le premier étage. L'engagement, ainsi déterminé, sert de référence au pilotage en situation où l'ensoleillement est connu (il se réalise) : c'est le second étage. On peut donc scinder les variables de décision du problème 6.1 en variables *here-and-now* $\{u^D\}$ et *wait-and-see* $\{u, u^E, u^B, u^{XB}, soc\}$.

L'équivalent déterministe du programme stochastique à deux étages peut être formulé comme suit 2.4.1:

$$\max_u \frac{1}{N_S} \frac{\delta}{60} \sum_{s=1}^{N_s} \sum_{t=1}^T \pi_t \left[u_{s,t} - \frac{(u_{s,t} - d_t^+)^2 - (d_t^- - d_t^+)^2}{P} \right] \quad (7.1)$$

$$\text{s.t.} \quad u_{s,t} - u_{s,t}^E - u_{s,t}^B + u_{s,t}^{XB} = 0, \quad s \in [1..N_s] \quad (7.2)$$

$$soc_{t+1} - soc_t - \frac{\delta}{60B_{nom}} \left(\eta_c u_{s,t}^{XB} - \frac{u_{s,t}^B}{\eta_d} \right) = 0, \quad s \in [1..N_s] \quad (7.3)$$

$$-0.05P \leq u_t^D \leq 0.7P \quad (7.4)$$

$$0.003P \leq u_{t+1}^D - u_t^D \leq 0.006P, \quad t \in [0, 599] \quad (7.5)$$

$$P_{sto} := -0.003P \leq u_{t+1}^D - u_t^D \leq 0.003P, \quad t \in [600, 638] \quad (7.6)$$

$$-0.006P \leq u_{t+1}^D - u_t^D \leq 0.003P, \quad t \in [839, 1138] \quad (7.7)$$

$$\cup [1260, 1438] \quad (7.8)$$

$$u_t^D \geq 0.2P, \quad t \in [1140, 1259] \quad (7.9)$$

$$0 \leq u_{s,t}^E \leq E_{s,t}, \quad s \in [1..N_s] \quad (7.10)$$

$$0 \leq u_{s,t}^B \leq B_d^{max}, \quad s \in [1..N_s] \quad (7.11)$$

$$0 \leq u_{s,t}^{XB} \leq B_c^{max}, \quad s \in [1..N_s] \quad (7.12)$$

$$-0.1P \leq u_{s,t} \leq u_t^D + 0.05P, \quad s \in [1..N_s] \quad (7.13)$$

$$0 \leq soc_{s,t} \leq soc^{max}, \quad s \in [1..N_s] \quad (7.14)$$

$$\max_u \frac{1}{N_S} \frac{\delta}{60} \sum_{s=1}^{N_s} \sum_{t=1}^T \pi_t \left[u_{s,t} - \frac{(u_{s,t} - d_t^+)^2 - (d_t^- - d_t^+)^2}{P} \right] \quad (7.15)$$

$$\text{s.t.} \quad u_{s,t} - u_{s,t}^E - u_{s,t}^B + u_{s,t}^{XB} = 0, \quad s \in [1..N_s] \quad (7.16)$$

$$soc_{t+1} - soc_t - \frac{\delta}{60B_{nom}} \left(\eta_c u_{s,t}^{XB} - \frac{u_{s,t}^B}{\eta_d} \right) = 0, \quad s \in [1..N_s] \quad (7.17)$$

$$\text{Contraintes AOCRE ZNI 15} \quad (7.18)$$

$$0 \leq u_{s,t}^E \leq E_{s,t}, \quad s \in [1..N_s] \quad (7.19)$$

$$0 \leq u_{s,t}^B \leq B_d^{max}, \quad s \in [1..N_s] \quad (7.20)$$

$$0 \leq u_{s,t}^{XB} \leq B_c^{max}, \quad s \in [1..N_s] \quad (7.21)$$

$$-0.1P \leq u_{s,t} \leq u_t^D + 0.05P, \quad s \in [1..N_s] \quad (7.22)$$

$$0 \leq soc_{s,t} \leq soc^{max}, \quad s \in [1..N_s] \quad (7.23)$$

Où l'indice s représente un scenario, N_s est le nombre de scenario.

Comme on peut le voir, la donnée de production solaire $E_{s,t}$ (dans la contrainte 7.19) est dépendante du scenario. C'est le seul paramètre incertain du problème. Par ailleurs, on suppose que chaque scenario a la même probabilité de se réaliser, donc la probabilté de chaque scenario est de $\frac{1}{N_s}$.

L'unique variable *here-and-now*, u_t^D , ne dépend pas du scénario s . Toutefois, pour calculer la Valeur Moyenne de l'Information Parfaite (EVPI) (voir §2.4.3), on

écrit la version *wait-and-see* du programme 7.15 dans lequel u_t^D devient une variable *wait-and-see*, donc dépendante du scénario et notée $u_{s,t}^D$.

7.2 Le modèle robuste

7.2.1 Présentation du problème

Comme indiqué dans l'introduction à ce chapitre, l'objectif est de trouver l'engagement optimal robuste aux incertitudes sur les prévisions solaires. Le problème peut être défini comme suit :

$$\begin{aligned}
 & \min_{E \in \mathcal{E}} \max_{\mathcal{U}, u^D \in \mathcal{D}} \sum_{t=1}^T \delta \pi_t J_t(u_t, u_t^D) && (7.24) \\
 & \text{s.t.} \quad u_t - u_t^E - u_t^B + u_t^{XB} = 0 && (7.25) \\
 & \quad soc_t - soc_{t-1} - \frac{\delta}{60B_{nom}} \left(\eta_c u_t^{XB} - \frac{u_t^B}{\eta_d} \right) = 0 && (7.26) \\
 & \quad -0.05P \leq u_t^D \leq 0.7P && (7.27) \\
 & \quad 0.003P \leq u_{t+1}^D - u_t^D \leq 0.006P, \quad t \in [0, 599] && (7.28) \\
 & \quad -0.003P \leq u_{t+1}^D - u_t^D \leq 0.003P, \quad t \in [600, 638] && (7.29) \\
 P_{robust} := & \quad -0.006P \leq u_{t+1}^D - u_t^D \leq 0.003P, \quad t \in [839, 1138] && (7.30) \\
 & \quad \cup [1260, 1438] && (7.31) \\
 & \quad u_t^D \geq 0.2P, \quad t \in [1140, 1259] && (7.32) \\
 & \quad 0 \leq u_t^E \leq E_t && (7.33) \\
 & \quad 0 \leq u_t^E \leq 0.75P && (7.34) \\
 & \quad 0 \leq u_t^B \leq B_d^{max} && (7.35) \\
 & \quad 0 \leq u_t^{XB} \leq B_c^{max} && (7.36) \\
 & \quad -0.1P \leq u_t \leq u_t^D + 0.05P && (7.37) \\
 & \quad soc^{min} \leq soc_t \leq soc^{max} && (7.38)
 \end{aligned}$$

Où $\mathcal{U} = \{u, u^D, u^E, u^B, u^{XB}, soc\}$.

Le problème 7.24 ne diffère du problème 6.1 que par la fonction objectif et la contrainte 7.34 sur u^E . En effet, il est défini comme un problème d'optimisation robuste. L'objectif est de trouver l'engagement qui produit le maximum de profit (problème **max** interne) dans un scénario de pire cas de réalisation des incertitudes (problème **min** externe).

Pour résoudre ce problème, nous le transformons en un problème à *deux étages* dans lequel le premier étage — *problème maître*, noté M — a pour but de trouver un potentiel engagement optimal, qui serait satisfait au second étage — *problème esclave*, noté $S(u^D)$ — soumis aux incertitudes sur la variable $E_t \in \mathcal{E}$, apparaissant dans la contrainte 7.33. Les contraintes de l'AOCREZNI15, càd celles portant sur u^D sont relatives au premier étage et les autres contraintes (de contrôle) relatives au second étage.

Il est important de remarquer que le choix de reformuler le problème 7.24, comme

179

7

180

181

182

un problème d'optimisation robuste à deux étages, n'est ni systématique ni arbitraire : ça répond au besoin de « relâcher » le problème en deux sous-problèmes relativement simple à résoudre.

7.2.2 La décomposition de Benders

En pratique, la décomposition de Benders a été utilisée pour déduire le problème à deux étages. La procédure est similaire à celle de [POIRION 2013].

7.3 Résolution du problème d'optimisation robuste

Le problème à deux étages, formulé dans la section 7.2, a été résolu en utilisant l'algorithme dual de Benders (*Benders-dual Cutting Plane Algorithm*, en anglais) [Zeng 2013]. L'algorithme 2 est une application pour résoudre le problème 7.24.

Algorithm 2 Algorithme dual de Benders

Require: N // Nombre maximal d'itérations

Require: ε // Tolérance sur la valeur optimale

Require: $LB = -\infty$, $UB = +\infty$, $k = 0$

Require: $z_0 = 0$

for $k \leftarrow 0, N$ **do**

Résoudre le **problème maître** M , $\forall l \leq k$

Obtenir une solution optimale pour M : $(u_{k+1}^{D*}, z_{k+1}^*)$

Mettre à jour $UB = z_{k+1}^*$

Résoudre le **problème esclave** $DS(u_{k+1}^{D*})$

Obtenir une solution optimale pour $DS(u_{k+1}^{D*})$:

$$(\lambda_{k+1}^*, \nu_{k+1}^*, \mu_{k+1}^{E*}, \mu_{k+1}^{B*}, \mu_{k+1}^{XB*}, \mu_{k+1}^{MG*}, \mu_{k+1}^{GM*}, \mu_{k+1}^{soc-*}, \mu_{k+1}^{soc+*}, \gamma_{k+1}^{E*}, \beta_{k+1}^*, \nu_{0,k+1}^*)$$

Mettre à jour $LB = \max\{LB, DS(u_{k+1}^{D*})\}$

if $UB - LB \leq \varepsilon$ **then**

return u_{k+1}^{D*}

else

Ajouter la contrainte suivante au problème F :

$$\begin{aligned} z \leq & x\nu_{0,k+1}^* + \sum_{t=1}^T \{\bar{E}_t \mu_{t,k+1}^{E*} - \Delta E_t^{max} \gamma_{t,k+1}^{E*} + B_d^{max} \mu_{t,k+1}^{B*} + B_c^{max} \mu_{t,k+1}^{XB*} \\ & + (u_t^D + 0.05P) \mu_{t,k+1}^{MG*} + 0.1P \mu_{t,k+1}^{GM*} + \delta \pi_t B_t\} \\ & + \sum_{t=1}^{T+1} (soc^{max} \mu_t^{soc+*} - soc^{min} \mu_t^{soc-*}) \end{aligned}$$

end if

end for



7.4 Résolution, résultats et discussion

Cette section est consacrée à la comparaison des approches déterministe, stochastique et robuste sur un jeu de 20 données de prévision solaire. Chaque instance correspond à un jour choisi aléatoirement. Nous avons effectué les trois simulations suivantes : 183

Calcul du profit réel: dans cette simulation, pour chaque jour de simulation, le Predictor est exécuté une fois en début d'horizon¹ en utilisant les données de prévision solaire disponible à cet instant. Le profil d'engagement obtenu est envoyé au Tracker qui est exécuté une fois en début d'horizon. Le contrôle optimale déterminé par ce dernier est transmis au PMS qui l'applique à Plant. Dans cette simulation, le Tracker utilise la valeur médiane des données de prévision et le PMS utilise des données réelles, c'ds les données d'ensoleillement observées sur site. Dans le cas stochastique, pour chaque instance des données de prévision, un nombre N_s de scénarios sont générées aléatoirement (voir § 7.4.1).

Calcul de la VSS: Comme expliqué à la section 2.4.3, on remplace, dans le modèle stochastique à deux étages, la variable de premier étage (qui devient une donnée) par la solution déterministe et robuste, successivement. Chaque « scénario » (car les variables du second sont dépendants du scénario) de solutions de second étage, pour chaque cas, est envoyé au Tracker qui, lui, envoie son résultat au PMS. Puisqu'il faut nécessairement passer par le PMS, le workflow précédent est quelque peu différent de celui énoncé à la section 2.4.3 et la solution (de premier étage) stochastique subit le même workflow, même si *a priori* ses solutions pourraient être directement envoyées au PMS (sans passer par le Tracker).

Ainsi, pour une instance donnée, pour chaque stratégie (déterministe, stochastique et robuste), il y aura N_s valeurs pour chaque variable de second étage. Il y aura donc N_s profits journaliers correspondant à chaque scénario. L'espérance mathématique de ces N_s profits journaliers est calculé. Ce qui fait au total $20 \times 3 = 60$ valeurs de profit espéré. La VSS robuste et la VSS déterministe sont calculés à partir de ces valeurs.

Dans cette simulation, le Predictor n'est pas exécuté ; on se sert des engagements déterminés à l'simulation précédente. Le Tracker utilise la valeur médiane des prévisions solaires et le PMS utilise les données réelles.

Calcul de l'EVPI: Comme expliqué à la section 2.4.3, on change le modèle stochastique à deux étages en un modèle *wait-and-see* où toutes les variables de décisions sont dépendantes du scénario. Cette simulation ne concerne que la stratégie stochastique ; elle permet d'évaluer le gain d'avoir des données de prévision parfaites.

Pour une instance donnée, il y aura N_s valeurs pour chaque variable de décision, notamment l'engagement. Il y aura donc N_s profits journaliers correspon-

¹L'instant précis auquel le Predictor est lancé importe peu tant qu'il est lancé avant le début de l'horizon. Ce que nous voulons dire, c'est que l'instant initial de son horizon d'optimisation coïncide avec le premier instant de la journée, qui est le début de l'horizon journalier.

Symbol	Description	Valeur
T	Horizon	1440 min
N_s	Nombre de scénarios	50
t	Instant	$[1 \dots T]$
δ	Durée d'un pas de temps	1 min
P	Puissance totale installée sur le microgrid	1000 kW
η_c, η_d	Rendement de charge/décharge de la batterie	0.87, 0.87
B^{nom}	Capacité nominale de la batterie	1000 kWh
B_c^{max}, B_d^{max}	Puissance maximale de charge/décharge de la batterie	1000 kW, 1000 kW
η_{PV}^{inv}	Rendement du convertisseur DC/AC en sortie du champ PV	1
π_t	Prix de l'électricité	$0.38 \text{ €/kWh si } 1140 \leq t \leq 1259, 0.2 \text{ €/kWh sinon}$
soc^{min}, soc^{max}	État de charge minimal/maximal de la batterie	0.1, 1

TABLE 7.1: Données d'simulation des modèles déterministe, stochastique et robuste.

Symbol	Description	Valeur
p	Facteur de déviation	0.6
$depth$	Profondeur de déviation	1
N_c	Nombre de clusters	4

TABLE 7.2: Paramètres du programme robuste.

dant à chaque scénario. L'espérance mathématique de ces N_s profits journaliers est calculé. Ce qui fait au total 20 valeurs de profit espéré. L'EVPI est calculée à partir de ces valeurs.

Dans cette simulation, le Predictor utilise la valeur médiane des prévisions solaires (cas déterministe), les N_s scénarios (cas stochastique) et les déciles (cas robuste), le Tracker utilise la valeur médiane des prévisions solaires et le PMS utilise les données réelles.

Pour toutes ces simulations, les mêmes valeurs des paramètres sont utilisées. Le tableau 7.1 présente ces paramètres et leurs valeurs correspondantes.

7.4.1 Génération des scénarios et calcul des paramètres du programme robuste

La génération des scénarios

Les données de prévision solaire utilisées dans les simulations sont des séries temporelles de déciles de l'ensoleillement global sur un plan horizontal (GHI). En statistiques, une quantile est un nombre qui divise une suite ordonnée de valeurs en parties d'égale étendue. Par exemple, la *médiane* (ou quantile de proportion 1/2) d'une suite ordonnée de valeurs est la valeur qui partage cette suite en *deux* sous-suites de même cardinalité ; les *déciles* (ou quantiles de proportion 1/10, 2/10, ..., 9/10) sont les valeurs qui partagent cette suite en *dix* sous-suites de même cardinalité, etc. En probabilités discrètes, une quantile q , de proportion p , peut être définie comme la valeur pour laquelle la probabilité de réalisation d'une observation inférieure ou égale (à q) est égale à p . En d'autres termes :

$$\text{Prob}(X \leq q) = p \quad (7.39)$$

Où Prob désigne la probabilité et X est une variable aléatoire.

Les données de prévision ont donc la forme d'une matrice dont les colonnes sont des déciles et les lignes sont les valeurs de ces déciles, à chaque instant de l'horizon. Leur résolution temporelle est de 15 min, que nous rééchantillonnons à 1 min lors du calcul de la production solaire. En plus des déciles conventionnelles, il y a deux autres colonnes qu'on pourrait nommer décile de proportion 0/10 et décile de proportion 10/10. Ces valeurs désignent donc les valeurs minimales et maximales de GHI.

Le principe que nous avons utilisé pour générer les scénarios est le suivant. On estime que chaque observation est « uniformément » d'une part ou de l'autre d'une décile (On l'appelle *côté* dans la suite). On suppose donc que la répartition des déciles est uniforme. Aussi, on commence par tirer une décile ; lorsqu'elle est choisie, on connaît immédiatement la probabilité que l'observation soit inférieure ou supérieure à la valeur de cette décile. Cela nous permet de choisir aléatoirement le côté dans lequel l'observation se réalisera. Dès que ce choix est fait, les bornes de ce côté sont définies, l'une d'elles étant la décile choisie précédemment, l'autre borne étant la décile 0/10 ou la décile 10/10. La répartition de l'observation dans ce côté est uniforme. Il ne reste plus qu'à la tirer aléatoirement. On réalise cette procédure pour chaque instant de l'horizon et on obtient un scénario journalier. L'algorithme 3 présente cette procédure.

La détermination de l'intervalle et du budget d'incertitude

Comme nous l'avons dit à la section 7.2.2, le pire cas de réalisation de la production solaire est sa valeur minimale ou sa déviation maximale de sa valeur médiane. On a montré que l'intervalle d'incertitude se réduit à cette valeur, qui dépend du temps. On a également dit que si à chaque instant, on prenait le pire cas, on finirait avec un programme trop pessimiste, alors on introduit le budget d'incertitude, qui est une valeur qui nous permet de contraindre le nombre de déviations sur l'horizon. Dans cette section, nous montrons la procédure que nous avons implémentée pour déterminer ces deux quantités.

Diverses méthodes sont utilisées pour déterminer la déviation (maximale). Cer-

Algorithm 3 Génération de scénarios de GHI

```

1: function GENERATE-SCENARIO(data,  $T$ ,  $N_s$ )
2:   // data,  $T$ ,  $N_s$ : time serie des déciles, horizon, nombre de scénarios
3:   function CHOOSE-SIDE(decile)
4:     // On utilise un codage binaire pour représenter la répartition des valeurs
      de l'observation à gauche et à droite de la décile. L'ensemble des valeurs est une
      liste de 10 binaires où les 0 représentent le côté gauche et les 1 représentent le
      côté droit. Le nombre d'occurrence de chaque bit correspond à la probabilité de
      l'observation d'être inférieure ou supérieure à la décile.
5:     bin  $\leftarrow$  List(10)
6:     k  $\leftarrow$  10
7:     for i  $\leftarrow$  0, 9 do
8:       if k  $\leq$  decile then
9:         bin[k]  $\leftarrow$  0
10:      else
11:        bin[k]  $\leftarrow$  1
12:      end if
13:      k  $\leftarrow$  k + 10
14:    end for
15:    return random.choice(bin) // Cette fonction choisit un élément dans un
      ensemble discret reparti uniformément
16:  end function
17:  function FIND-BOUNDS(side, decile)
18:    if side == 0 then
19:      lb  $\leftarrow$  "00"
20:      ub  $\leftarrow$  TO-STRING(decile)
21:    else
22:      lb  $\leftarrow$  TO-STRING(decile)
23:      ub  $\leftarrow$  "100"
24:    end if
25:    return lb, ub
26:  end function
27:  choices  $\leftarrow$  RANGE([10, 100], multiple=10)
28:  // Générer une matrice  $N_s \times T$  de déciles
29:  deciles  $\leftarrow$  RANDOM.CHOICE(choices, [ $N_s$ ,  $T$ ])
30:  // Allouer la matrice de scénarios de taille  $N_{scen} \times T$ 
31:  scen  $\leftarrow$  array[ $N_s$ ][ $T$ ]
32:  // Générer les scénarios
33:  for i  $\leftarrow$  0,  $N_s - 1$  do
34:    for j  $\leftarrow$  0,  $T - 1$  do
35:      decile  $\leftarrow$  deciles[i][j]
36:      side  $\leftarrow$  CHOOSE-SIDE(decile)
37:      lb, ub  $\leftarrow$  FIND-BOUNDS(side, decile)
38:      scen[i][j]  $\leftarrow$  RANDOM.UNIFORM(data[j][lb], data[j][ub]))
39:    end for
40:  end for
41:  return scen
42: end function

```

tains auteurs la supposent constante sur l'horizon [Lin 2018], d'autres la considèrent dépendante du temps et la détermine comme écart-type moyen des différences entre les prévisions et les mesures historiques [Wang 2015]. Le budget d'incertitudes est généralement choisi en fonction de la connaissance plus ou moins précise des instants où il peut avoir déviation. Cette décision peut également être basée sur des données historiques. Certains auteurs testent plusieurs valeurs de budget afin d'en choisir une (ou plusieurs selon les jours) qui est appropriée [Liu 2015].

Nous proposons de déterminer la déviation maximale et le budget algorithmiquement en se servant des déciles disponibles au moment du calcul de l'engagement, plutôt qu'en utilisant des données historiques. Notre approche est la suivante. Pour chaque instant, nous disposons des déciles 0/10 à 10/10, la décile 5/10 étant la médiane. Une déviation de la production réelle correspond à une valeur réelle inférieure à la valeur médiane. On décide de ne travailler qu'avec les déciles strictement inférieures à la médiane². Ce sont donc les déciles 0/10 à 4/10. On les sépare ensuite en un nombre défini de clusters (ou voisinages), soit N_c ce nombre, en utilisant l'algorithme MiniBatchKMeans de la bibliothèque Python de Machine Learning, appelé Scikit-learn. Chaque cluster a un centre et un nombre d'éléments. On les range par ordre croissant suivant leurs centres et on choisit la profondeur de la déviation : c'est une valeur entière inférieure au nombre de clusters. Une valeur de 0 signifie qu'il faut prendre le cluster le plus proche de la valeur médiane et une valeur $N_c - 1$ signifie qu'il faut prendre le cluster le plus éloigné de la valeur médiane. N_c est donc un paramètre important de notre algorithme. Ces clusters sont utilisés pour déterminer la déviation maximale et la valeur du budget, via la règle basique suivante. Pour le cluster choisi, on calcule la distance (par défaut la norme 2) entre chaque élément et la valeur médiane. La valeur maximale est la déviation recherchée. On calcule ensuite le nombre d'éléments du cluster qui sont supérieurs ou égaux à un p ($p < 1$) fois la distance maximale et donc le nombre d'éléments inférieurs. Si le premier est supérieur ou égal au dernier, le budget instantané est mis à 1 (déviation), sinon il est mis à 0 (pas de déviation). La somme des valeurs instantanées du budget sur l'horizon donne la valeur du budget recherchée.

Même si cet algorithme est relativement simple, son utilité est moindre dans le cas des déciles car elles sont peu nombreuses. Il devient intéressant lorsqu'on fait de l'optimisation robuste basée sur des scénarios, car le nombre de scénarios peut être très grand. Toutefois, nous l'avons bien utilisé dans le cas des déciles. Le pseudo-code 4 présente les grandes lignes de l'algorithme.

7.4.2 Calcul du profit réel

Les résultats obtenus sont consignés dans le tableau 7.3. Comme on peut le voir, l'optimisation sous incertitudes présente, en moyenne, un meilleur profit que la stratégie déterministe. Les stratégies robuste et stochastique sont supérieures à la stratégie déterministe de 27.1 unités et de 17.9 unités, respectivement. La stratégie robuste est supérieure à la stratégie stochastique de 9.2 unités.

Pour mieux comprendre ces valeurs économiques, nous présentons des graphes

²On pourrait alternativement choisir aléatoirement s'il faut considérer les déciles inférieures ou les déciles supérieures

Algorithm 4 Calcul de la déviation maximale de la production solaire et du budget d'incertitude

```

1: function COMPUTE-CLUSTERS(data,  $T$ ,  $N_c$ , depth)
2:   // data,  $N_c$ , depth: time serie des déciles, horizon, nombre de clusters, pro-
   fondeur de déviation
3:   cluster_set  $\leftarrow$  array[ $T$ ]
4:   mean_val  $\leftarrow$  data[:, "pv50"] // Extraire la valeur médiane
5:   for  $t \leftarrow 0, T - 1$  do
6:     data_t  $\leftarrow$  data[t][:] // Extraire les décile de l'instant  $t$ 
7:     data_t  $\leftarrow$  data_t[data_t < mean_val[t]] // Extraire les déciles inférieures à
   la médiane
8:     kmeans  $\leftarrow$  MINIBATCHKMEANS(n_clusters= $N_c$ ).FIT(data_t) // Déter-
   miner les clusters
9:     centers  $\leftarrow$  kmeans.cluster_centers_
10:    sorted_clusters  $\leftarrow$  SORT-CLUSTERS(kmeans, key=centers, ascending=False)
11:    cluster  $\leftarrow$  CHOOSE-CLUSTER(sorted_clusters, depth) // Choisir le cluster
12:    cluster_set[t]  $\leftarrow$  cluster // Sauvegarder le cluster
13:  end for
14:  return cluster_set, mean_val
15: end function
16: function COMPUTE-BUDGET(cluster_set, mean_val)
17:   budget  $\leftarrow$  array[ $T$ ]
18:   max_dev  $\leftarrow$  array[ $T$ ]
19:    $p \leftarrow 0.6$ 
20:   for  $t \leftarrow 0, T - 1$  do
21:     cluster  $\leftarrow$  cluster_set[t]
22:      $L \leftarrow$  LENGTH(cluster)
23:     dist  $\leftarrow$  CDIST(cluster, mean_val[t])
24:     max_dist  $\leftarrow$  MAX(dist)
25:     max_dev[t]  $\leftarrow$  max_dist
26:     n_up  $\leftarrow$   $\sum_{d \in \{d \in \text{dist}: d \geq p \times \text{max\_dist}\}} d$ 
27:     n_down  $\leftarrow$   $L - n_{\text{up}}$ 
28:     if  $n_{\text{up}} \geq n_{\text{down}}$  then
29:       budget[t]  $\leftarrow 1$ 
30:     else
31:       budget[t]  $\leftarrow 0$ 
32:     end if
33:   end for
34:   return budget, max_dev
35: end function

```

Date	V^s	V^r	V^d
2017-03-04	547.8	558.4	498.2
2017-03-15	759.4	807.9	697.3
2017-03-25	991.2	906.1	994.0
2017-03-30	627.2	671.9	606.7
2017-04-06	897.1	824.9	936.3
2017-04-15	516.5	555.8	462.8
2017-04-20	562.8	650.6	542.5
2017-04-28	472.7	524.1	438.9
2017-05-05	630.4	776.8	688.2
2017-05-15	835.2	776.3	874.9
2017-05-25	882.7	854.4	921.3
2017-05-31	346.4	388.5	339.7
2017-06-05	906.4	926.1	978.7
2017-06-15	901.0	914.8	908.1
2017-06-20	882.7	842.7	812.2
2017-06-30	380.9	389.9	384.6
2017-07-01	914.9	864.1	816.6
2017-07-15	868.0	843.6	722.1
2017-07-20	267.8	318.7	269.3
2017-07-29	704.4	683.4	646.4
Avg	694.8	704.0	676.9

TABLE 7.3: Profits réels journaliers. d pour déterministe, s pour stochastique et r pour robuste.

de la production solaire médiane E_{mean} , de la production solaire réelle E_{real} , de l'engagement u_{pred} (ou u^D), du contrôle optimal retourné par le Tracker u_{trk} (ou u) et trajectoires de SOC prévue par le Tracker soc_{trk} et réellement observée soc_{real} . Nous présentons ces graphes pour chaque stratégie pour un jour spécifique : 2017-05-05.

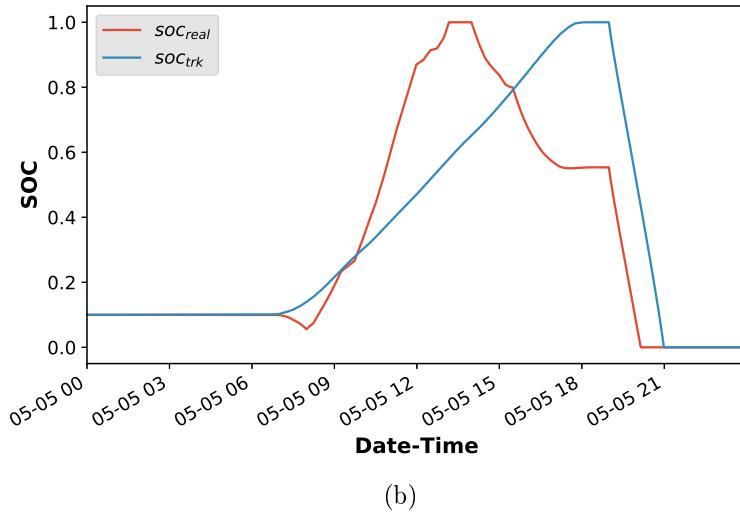
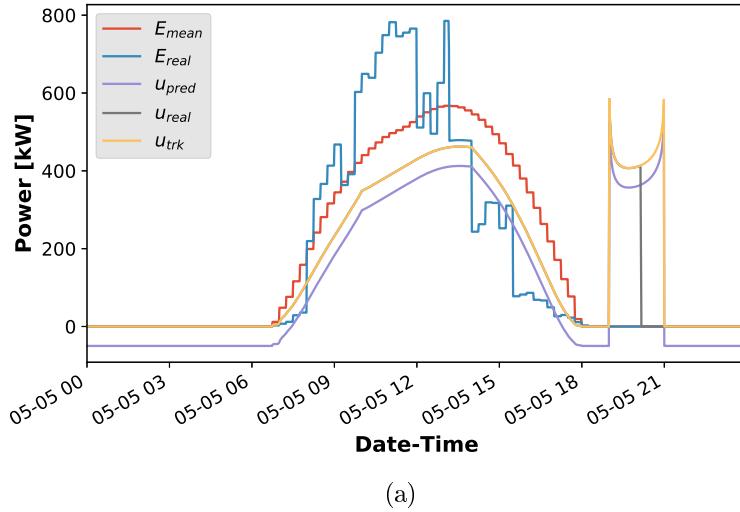


FIGURE 7.1: Graphes de la production solaire (prévue et réelle), de l'engagement, du contrôle optimal et de la production totale réelle (a). Trajectoires de l'état de charge prévu par le Tracker et de l'état de charge observé (b). *Stratégie déterministe*

Pour les 3 stratégies, on a les mêmes courbes de E_{mean} et E_{real} (voir figures 7.1 (a), 7.2 (a) et 7.3 (a)). Comme on peut le voir la production solaire est sous-estimée entre 8:00 et 13:00 et surestimée entre 13:00 et 18:00 environ. La stratégie déterministe, déterminant l'engagement en utilisant la valeur E_{mean} , l'engagement u_{pred} a la même monotonie et est inférieure à E_{mean} , en période où il y a du soleil, notamment entre 7:00 et 18:00. L'objectif étant d'utiliser l'excès de production solaire pour charger la batterie et faire une pointe du soir profitable, comme le montre la courbe u_{trk} de la figure 7.1 (a) et la trajectoire de SOC sur la figure 7.1 (b) (la valeur de SOC monte

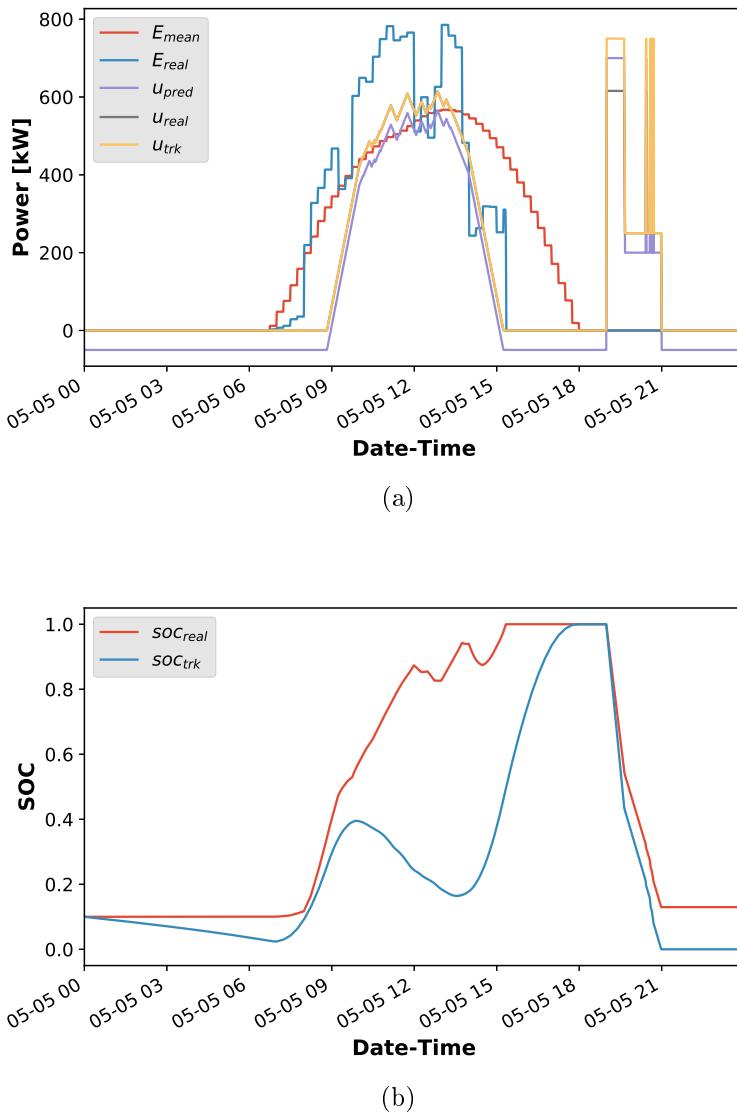


FIGURE 7.2: Graphes de la production solaire (prévue et réelle), de l'engagement, du contrôle optimal et de la production totale réelle **(a)**. Trajectoires de l'état de charge prévu par le Tracker et de l'état de charge observé **(b)**. *Stratégie robuste*

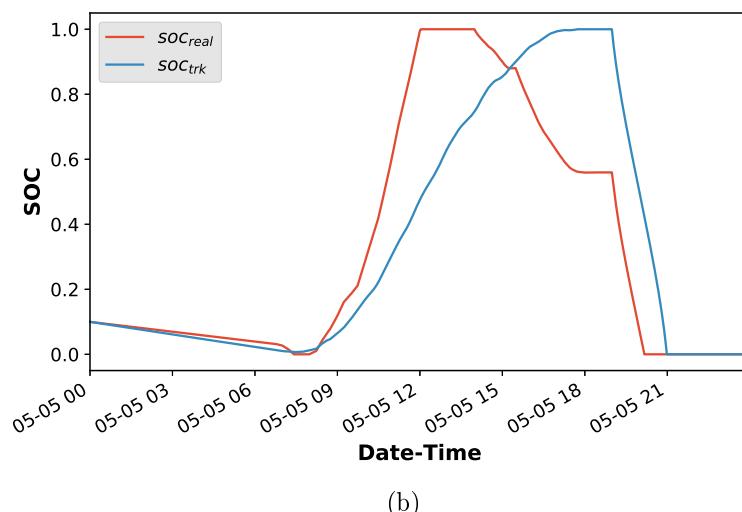
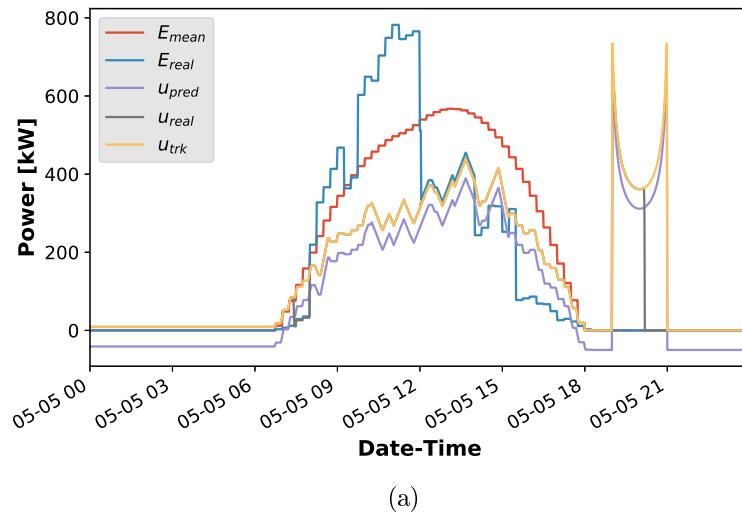


FIGURE 7.3: Graphes de la production solaire (prévue et réelle), de l'engagement, du contrôle optimal et de la production totale réelle **(a)**. Trajectoires de l'état de charge prévu par le Tracker et de l'état de charge observé **(b)**. *Stratégie stochastique*

jusqu'à 1). Mais ce plan n'a pu se réaliser principalement à cause de la surestimation de la production solaire entre 13:00 et 18:00. La pointe du soir n'est réalisée qu'à la moitié de ce qui était prévu. En effet, la sous-estimation entre 8:00 et 13:00 aurait dû compenser la surestimation ; cela a été le cas dans une certaine mesure, c'est pourquoi on voit que la trajectoire de u_{real} a une pente ascendante plus élevée que celle de u_{trk} . Mais cela ne suffit pas puisqu'il faut satisfaire l'engagement entre 13:00 et 18:00, avec une faible production solaire, et la pointe du soir. En effet, on voit que la valeur de SOC n'a pas pu atteindre son maximum avant la pointe, comme cela était prévu par le Tracker. En particulier, la non satisfaction de cette pointe, pendant 1 heure environ, a grandement pénalisé la stratégie déterministe.

Comme on peut le voir sur la figure 7.2 (a), la stratégie robuste a retourné un engagement qui est pratiquement en dessous des courbes E_{mean} et E_{real} — donc sous-estimation de la trajectoire de SOC (voir figure 7.2 (b)) — mais assez proche de E_{mean} entre 10:00 et 13:00. Cela veut dire qu'il a réussi à envisager le pire cas. De ce fait, il satisfait globalement son engagement sur tout l'horizon. Il faut cependant remarquer qu'il aurait mieux fait s'il n'avait pas été trop pessimiste entre 8:00 et 9:00.

La stratégie stochastique (figures 7.2 (a) et (b)) se comporte pratiquement comme la stratégie déterministe mais moins bien que cette dernière entre 9:00 et 15:00, d'où le profit journalier inférieur obtenu.

7.4.3 Calcul de la VSS

Comme on peut le voir sur le tableau 7.4, en moyenne VSS^r est négative, ce qui veut dire que la stratégie robuste est meilleure que la stratégie stochastique. Cette dernière étant meilleure que la stratégie déterministe car, en moyenne, $VSS^r > 0$. Ces valeurs absolues de VSS étant importantes, on peut conclure qu'il est préférable d'implémenter la stratégie robuste par rapport aux deux autres stratégies, ou la stratégie stochastique par rapport à la stratégie déterministe. En d'autres termes, d'un point de vue profit financier, il est préférable d'implémenter une stratégie sous incertitudes plutôt qu'une stratégie déterministe.

7.4.4 Calcul de l'EVPI

Comme on peut le voir sur le tableau 7.5, en moyenne, la valeur de l'EVPI est inférieure à 0. Cela indique que la stratégie stochastique produirait un meilleur profit si les prévisions étaient parfaites, avec un gain moyen d'environ 61.2 unités. Cette valeur pourrait justifier des efforts pour améliorer les méthodes de prévision de la production, si ces derniers n'ont évidemment pas un coût plus élevé.

7.4.5 Performance des stratégies sous incertitudes

Nous avons montré, aux sections 7.4.2–7.4.4, que les stratégies sous incertitudes (robuste et stochastique) sont meilleures que la stratégie déterministe, en ce qui concerne le profit journalier. Nous allons voir dans cette section d'autres indicateurs de performance tels que le temps de calcul et la qualité des solutions. Il s'agit des performances des Predictor déterministe, robuste et stochastique.

Date	V^d	V^r	V^s	VSS^d	VSS^r
2017-03-04	577.3	712.8	635.3	58.0	-77.5
2017-03-15	653.8	773.7	713.2	59.4	-60.4
2017-03-25	705.5	795.2	708.9	3.4	-86.3
2017-03-30	541.8	595.8	548.1	6.3	-47.7
2017-04-06	606.0	717.4	643.4	37.4	-74.0
2017-04-15	525.9	607.7	543.1	17.2	-64.6
2017-04-20	609.8	700.4	617.1	7.3	-83.3
2017-04-28	532.8	620.6	549.5	16.8	-71.1
2017-05-05	546.2	674.8	609.2	63.0	-65.6
2017-05-15	560.9	661.8	596.5	35.6	-65.3
2017-05-25	618.6	663.5	629.2	10.6	-34.3
2017-05-31	602.6	665.4	659.6	57.0	-5.9
2017-06-05	640.3	702.3	686.0	45.7	-16.3
2017-06-15	630.2	685.4	687.4	57.2	2.0
2017-06-20	683.2	735.2	717.1	33.9	-18.0
2017-06-30	583.9	676.2	651.7	67.8	-24.5
2017-07-01	624.0	706.6	702.9	78.9	-3.7
2017-07-15	618.4	715.0	705.2	86.8	-9.8
2017-07-20	518.9	596.3	586.8	68.0	-9.5
2017-07-29	575.4	666.7	628.4	53.0	-38.3
Avg	597.8	683.6	640.9	43.2	-42.7

TABLE 7.4: VSS déterministe et VSS robuste pour chaque instance.

Date	V^s	V^{ws}	EVPI
2017-03-04	547.8	711.8	-164.0
2017-03-15	759.4	857.7	-98.3
2017-03-25	991.2	915.8	75.4
2017-03-30	627.2	684.7	-57.5
2017-04-06	897.1	846.9	50.2
2017-04-15	516.5	661.7	-145.2
2017-04-20	562.8	706.7	-143.9
2017-04-28	472.7	657.5	-184.8
2017-05-05	630.4	715.1	-84.7
2017-05-15	835.2	790.1	45.1
2017-05-25	882.7	826.6	56.1
2017-05-31	346.4	566.6	-220.2
2017-06-05	906.4	853.9	52.6
2017-06-15	901.0	846.6	54.4
2017-06-20	882.7	876.3	6.3
2017-06-30	380.9	620.5	-239.6
2017-07-01	914.9	850.4	64.4
2017-07-15	868.0	855.2	12.8
2017-07-20	267.8	516.2	-248.4
2017-07-29	704.4	759.8	-55.4
Avg	694.8	756.0	-61.2

TABLE 7.5: EVPI pour chaque instance. s pour stochastique et ws pour *wait-and-see*

TABLE 7.6: Performance des Predictor déterministe, robuste et stochastique sur les 20 instances.

Predictor	Runtime (s)		Gap	
	avg	std	avg	std
Déterministe	1.79	0.46	0	0
Robuste	186.86	48.48	0.027	0.028
Stochastique	68.65	7.63	0	0

191 Le tableau 7.6 présente ces performances. Comme on peut le voir, d'un point de vue temps de résolution, le Predictor déterministe est plus rapide que les deux autres, au moins 50 fois. Le Predictor stochastique est 3 fois plus rapide que le Predictor robuste. Il faut noter que dans ces deux derniers cas, le temps de résolution dépend grandement de leurs paramètres. En effet, plus il y a de scénarios, plus de temps prendra le Predictor stochastique et plus on augmente le nombre d'itérations du Predictor robuste, plus de temps il pourrait prendre pour trouver la solution optimale. D'un point de vue qualité des solutions, les valeurs 0 dans les cas déterministe et stochastique indiquent que le solveur résout le problème à l'optimum : aucune limite n'est fixée dans sa résolution. Cependant, dans le cas robuste, nous avons fixé un nombre maximal d'itérations (200) et un écart absolu minimal entre la borne supérieure et la borne inférieure (0.005). Dès que l'une de ces conditions est satisfaite, le programme s'arrête. L'écart moyen observé est de 0.027 avec un écart-type de 0.028, ce qui, pour la présente application, est raisonnable. Mais étant donné qu'en production, on dispose de plus de temps pour le calcul d'engagement, environ 15 minutes, on pourrait augmenter le nombre d'itérations pour permettre au solveur d'aller jusqu'à l'optimum. Il faut également noter que la rapidité de convergence du Predictor robuste peut être également améliorée par des modifications appropriées du modèle.

7.5 Conclusion

192 Globalement, nous pouvons conclure que même si le Predictor robuste est moins rapide que le Predictor stochastique et le Predictor déterministe, son temps de résolution (de 3 min en moyenne) constitue un cinquième du temps alloué pour le calcul de l'engagement, et est donc raisonnable. Par ailleurs, le gain en profit journalier, qu'il apporte, fait de lui le meilleur choix.

193 Par ailleurs, il a été montré, en utilisant des indicateurs de la littérature sur la programmation stochastique, qu'une connaissance plus ou moins parfaite des incertitudes sur la production pourrait conduire à des profits journaliers significatifs. Cette observation incite le producteur à investir dans la recherche sur la prévision de la production solaire.

Conclusion

Dans cette thèse, nous avons étudié la gestion optimale d'une centrale PV avec stockage dans le cas connecté réseau et avec générateur diesel, dans le cas isolé. L'accent a été mis sur le premier cas pour lequel nous avons considéré le cas « déterministe »— dans lequel on suppose que les données de prévision de la production solaire sont parfaites — et le cas « sous incertitudes »— dans lequel on prend en compte les effets de la stochasticité de la production solaire. Dans les sections qui suivent, nous présentons nos contributions, les principales difficultés que nous avons rencontrées tout au long de cette étude, et les axes d'amélioration et perspectives.

Contributions

Contribution à la modélisation du microgrid. Nous avons montré expérimentalement que la mise en place d'un contrôle prédictif, avec une boucle de rétroaction, permet de minimiser l'effet des erreurs de modélisation du microgrid, notamment lors de l'emploi de la programmation mathématique pour résoudre le problème de contrôle. Ces erreurs sont principalement des approximations linéaires de fonctions fortement non linéaires et la suppression de certains coefficients, tels que des rendements de conversion, lorsque leur impact par rapport à celui des autres grandeurs est négligeable. Grâce à cette boucle de rétroaction, il est donc possible de simplifier raisonnablement le modèle du microgrid, et cela de façon intentionnelle. Il convient toutefois de préciser que la suppression d'une ou plusieurs contraintes physiques, généralement les contraintes liant plusieurs composants, telles que la contrainte d'équilibre de réseau, ne peut être une simplification acceptable car elle dénature complètement le problème. Ce sont les contraintes portant sur un seul composant, telles que les contraintes de rampe du générateur diesel et la dégradation de l'état de santé de la batterie, qui peuvent être négligées lorsqu'elles sont naturellement optionnelles ou que les variables qu'elles impliquent ont un faible impact sur la fonction objectif.

Contribution à la résolution du problème de contrôle optimal des microgrids.

Nous avons une fois pour toutes, nous l'espérons, montré qu'il est préférable d'adopter un contrôle prédictif, avec des méthodes d'optimisation avancées, plutôt qu'une stratégie statique qui consiste à utiliser des règles d'expert. En effet, même si cette dernière essaie d'utiliser au mieux la batterie sur tout l'horizon, elle demeure quasiment myope et sous-optimale car elle a forcément tendance à privilégier certaines périodes de l'horizon, telles que la pointe du soir, au détriment d'autres périodes qui lui semblent moins profitables. Un autre inconvénient de cette stratégie est que, contrairement, à la programmation mathématique, elle est difficilement extensible pour prendre en compte les incertitudes liées à la production solaire.

D'autre part, nous avons montré qu'en ce qui concerne les applications étudiées, la programmation mathématique est plus performante (en profit journalier et en temps de calcul) que l'algorithme génétique basé sur un simulateur. Et, nous avons surtout montré que les commandes obtenues par le programme mathématique sont optimales, et que, malgré les grosses approximations, ces commandes sont applicables au microgrid. L'applicabilité des commandes a grandement été rendue possible par la boucle de rétroaction.

Contribution à la résolution du problème d'engagement optimal des microgrids.

Nous avons étudié le problème d'engagement optimal dans le cadre d'un marché day-ahead et intraday dans les îles françaises. C'est un problème spécifique du problème général d'enchérissement sur les marchés d'énergie, mais il reste spécial à cause des contraintes et d'autres spécificités de ce marché. En ce sens, notre contribution est originale : nous avons résolu le problème d'engagement optimal dans les cas déterministe et sous incertitudes couplé au problème de contrôle optimal. Par ailleurs, à l'aide d'indicateurs précis, nous avons comparé, entre elles, deux stratégies de prise en compte des incertitudes, la stratégie robuste et la stratégie stochastique. Cela a révélé que la première est plus performante que la dernière. Nous avons également montré qu'il est important de prendre en compte des incertitudes, càd que la stratégie sous incertitudes (robuste ou stochastique) est meilleure que la stratégie déterministe. Nous avons également quantifié le gain obtenu grâce à des données de prévision parfaites. Il en ressort que le gain est significatif, et justifie amplement des efforts d'amélioration des modèles de prévision de la production solaire.

Contribution à la mise en place d'un système de contrôle prédictif. Nous avons présenté l'architecture et le fonctionnement du système de contrôle prédictif à deux couches que nous avons développé et implémenté. La première couche permet la détermination de l'engagement optimal — déclaration pour le marché day-ahead et redéclarations pour le marché intraday —, et la seconde permet la détermination du contrôle optimal. En environnement de simulation, ce système est couplé à un simulateur, et « en ligne », il envoie ses commandes directement au système réel. Ce système est extensible en ce sens qu'il peut supporter d'autres couches, et il est suffisamment générique pour supporter divers types de solveur d'optimisation.

Difficultés rencontrées

Disponibilité des modèles de composants physiques. L'une des plus grandes difficultés que nous avons rencontrées, est certainement le choix d'un modèle approprié pour chaque composant dans la panoplie de modèles existants. Il y a des cas où aucun modèle n'est satisfaisant : c'est le cas de l'évaluation de la dégradation de l'état de santé de la batterie. Plusieurs modèles existent, mais ils sont incompatibles avec l'approche de programmation mathématique que nous avons adoptée. Nous n'avons finalement pas pris en compte la dégradation des batteries car, après analyse du modèle le plus simple dont nous disposions, nous avons observé que la dynamique de cette quantité était trop négligeable

pour être prise en compte dans un problème de contrôle dont le plus grand horizon est la journée.

D'autre part, la difficulté du choix d'un modèle réside dans la satisfaction générale des praticiens. Pour ces derniers, certains modèles sont peu réalistes. Nous espérons avoir résolu ce problème, comme expliqué à la section précédente.

Approximation des fonctions. Avant d'arriver au modèle quadratique (convexe) du cas connecté réseau, tel qu'il est transcrit dans ce mémoire, nous avons commencé par un programme linéaire en nombre entiers et sommes passés par un programme linéaire quadratiquement contraint en nombre entiers. Nous pouvons estimer sans coup férir que le temps consacré à la modélisation linéaire en nombres entiers, a constitué un peu plus d'un tiers de la durée totale de nos travaux de thèse. Nous avons dû abandonner cette approche parce qu'elle impliquait beaucoup de variables entières qui la rendait peu efficace en temps de calcul, et souvent en temps de convergence.

Développement d'un cadre d'expérimentation et de comparaison équitable.

Pour chaque application que nous avons considérée, nous nous sommes attelés à comparer notre approche à plusieurs autres afin de la valider. Qui dit comparaison, dit critères de comparaison et, surtout, cadre de comparaison. Pour les critères de comparaison, nous avons utilisé les indicateurs classiques, tels que la différence moyenne absolue, la déviation absolue, le temps de calcul, etc. Les choses ont été plus difficiles au niveau du cadre d'expérimentation. Dans le cas déterministe, il fallait choisir le type de données solaires (prévisions ou mesures) à envoyer à chaque composant du système de contrôle, de sorte à éviter les effets des incertitudes. Dans tous les cas, il fallait s'assurer que les modèles d'optimisation comparés utilisent bien la même fonction objectif, et la question qui se pose c'est la validité de la comparaison si un des modèles utilise une fonction approchée. En outre, la mesure du temps de calcul est souvent biaisée par des opérations auxiliaires (affectations de variables, lecture/écriture de données depuis/vers le disque, ...) qui n'ont rien à voir avec le calcul du solveur. Dans le cas du programme mathématique, il nous a été plus simple d'isoler le calcul du solveur. Dans le cas de l'algorithme génétique, cette isolation est également réalisée, mais dans l'implémentation même de l'algorithme, ces opérations auxiliaires sont nécessaires. Nous avons donc considéré qu'elles font partie intégrante du calcul du solveur. Ce qui nous a permis de comparer les temps de calcul des solveurs considérés.

Perspectives

Diversification des applications et généricité. L'un des objectifs de cette thèse était d'aboutir à une solution générique en code et en applications. Pour ce qui est du code, nous avons veillé à ce qu'il soit générique et extensible. Nous avons commencé par une structure entièrement impérative avant de terminer par un code partiellement orienté objet. Une interface de programmation ou API (Application Programming Interface) a été mise en place pour permettre l'utilisation facile de notre système comme module dans un autre système.

Quant à la générnicité en applications, nous n'avons pas pu l'assurer. Nous n'avons, en plus du cas connecté réseau, étudier rapidement le cas off-grid. Ce dernier cas pourrait être amélioré, par l'ajout de nouvelles contraintes sur le générateur diesel et l'amélioration de la fonction ojectif, comme l'intégration de coûts d'arrêt/démarrage du générateur diesel. Dans les deux cas, surtout dans le cas connecté réseau, on pourrait envisager les services auxiliaires au réseau, tels que la *demand-side management*, la *demand response* et la participation au marché de réserve pour la régulation de la fréquence et de la tension. Ce dernier service constituant un service optionnel de l'AOCREZNI. Ces services valoriseraient encore plus la batterie. En outre, on pourrait envisager l'*auto-consommation*. En effet, l'énergie écrétée au niveau du champ photovoltaïque peut servir pour l'auto-consommation. Le modèle, tel qu'il est conçu, veille à l'écrêtage, donc à réserver une quantité d'énergie qui pourrait être consommée sur site, mais puisqu'il n'y a aucune contrainte que la quantité minimale d'auto-consommation, la quantité écrétée peut potentiellement être nulle. Il convient de faire remarquer que la prise en compte de tous ces services, devrait être facilitée par le langage de modélisation utilisée. Nous avons remarqué que celui du Gurobi assure cela jusqu'à un certain degré. La grande difficulté que nous avons constatée, c'est l'ajout de contrainte à la volée à un modèle existant, par exemple à travers un autre fichier. Nous n'avons pas profondément considéré le problème, mais si cela est possible, la question de la générnicité peut être totalement résolue, car le programme mathématique est naturellement générnicque, si le modèle est correctement écrit.

Par ailleurs, il est directement possible d'étendre le modèle agrégé en un modèle avec plusieurs occurrences de chaque composant du microgrid. En effet, le modèle que nous avons développé suppose qu'il y a un seul champ PV, une seule batterie et un seul générateur diesel. La réalité en est tout autre, et même dans le cas de l'AOCREZNI, les centrales comportent plusieurs occurrences de chacun de ces composants. Notre approche agrégée est valable si les occurrences de chaque composant sont physiquement identiques càd qu'elles ont le même modèle physique. Si ce n'est pas le cas, il faut construire un modèle désagrégé. Encore une fois, cela est rendu aisément par le langage Python. Ce qui est loin d'être le cas pour l'algorithme génétique basé sur un simulateur numérique, développé sous MATLAB/Simulink.

Amélioration du calcul des paramètres du programme robuste. Pour le calcul des paramètres du programme robuste, nous avons utilisé des méthodes de Machine Learning et une heuristique. Ces algorithmes pourraient être améliorés. Nous pensons qu'il est possible, sur la base d'une grande quantité de données de prévision significatives, d'utiliser la méthode de *clustering* pour trouver un budget fixe par saison d'une année, et par période d'une journée.

Prise en compte de la disponibilité des équipements dans le programme robuste.

La disponibilité des équipements (champ PV, batterie et générateur diesel) est un facteur stochastique que nous n'avons pas pris en compte dans nos modèles. Ces équipements peuvent ne pas être capables de fournir de l'énergie à un instant pour une raison ou pour une autre. Cette non disponibilité peut entraîner

des pénalités. Aussi, un modèle plus robuste devrait prendre en compte ce facteur.

Simplification possible de la contrainte de budget d'incertitude. Lors de l'analyse des résultats de la résolution du problème d'engagement robuste, nous avons constaté que, par moments-là, le budget était systématiquement mis à 0, malgré une valeur maximale supérieure à 0 imposée. Cela veut dire qu'à ces moments, la contrainte de budget est inutile. Une étude approfondie du programme robuste pourrait permettre de comprendre ce comportement et de simplifier conséquemment le programme.

Apprentissage de la prédiction du contrôle optimal. Ce point est assez ambitieux. Nous pensons que, plutôt que de résoudre chaque fois le problème de contrôle/engagement optimal en appelant le solveur, il est possible de prédire le résultat en utilisant un modèle d'apprentissage. En effet, il est possible, même si peu probable, qu'on se retrouve plusieurs fois à vouloir résoudre des problèmes identiques, càd dont les entrées sont identiques, ou analogues, càd dont les entrées diffèrent de façon structurée. Dans ces cas, il devrait être possible de retourner le résultat optimal sans avoir à appeler le solveur. Pour des entrées simples en petit nombre, il est possible d'utiliser la technique de programmation appelée *memoization*, en anglais. Mais les problèmes d'optimisation que nous traitons ici, quoiqu'ils ne soient pas des problèmes à grande échelle, leur nombre d'entrées est assez grand pour empêcher l'utilisation de la memoization. Dans ces cas-là, l'apprentissage pourrait être possible. Mais nous ignorons si les techniques actuelles de Machine Learning le permettent.

A

Exemple d'annexe

Sommaire

A.1 Exemple d'annexe

A.1 Exemple d'annexe

Bibliographie

- [Aardal 2005] K. Aardal, G.L. Nemhauser et R. Weismantel. *Discrete optimization*. Springer Science+Business Media, LLC, 2005. (Cité en page 16.)
- [Aboli 2019] Reza Aboli, Maryam Ramezani et Hamid Falaghi. *Joint optimization of day-ahead and uncertain near real-time operation of microgrids*. International Journal of Electrical Power & Energy Systems, vol. 107, pages 34–46, 2019. (Cité en page 41.)
- [Anayochukwu 2013] Ani Vincent Anayochukwu. *Simulation of Photovoltaic/Diesel Hybrid Power Generation System with Energy Storage and Supervisory Control*. International Journal of Renewable Energy Research (IJRER), vol. 3, no. 3, 2013. (Cité en page 43.)
- [Arora 2015] Rajesh Kumar Arora. *Optimization - algorithms and applications*. CRC Press, Taylor & Francis Group, 2015. (Cité en page 16.)
- [Bahmani 2020] Ramin Bahmani, Hamid Karimi et Shahram Javid. *Stochastic electricity market model in networked microgrids considering demand response programs and renewable energy sources*. International Journal of Electrical Power & Energy Systems, vol. 117, 2020. (Cité en page 41.)
- [Barley 1995] C.D. Barley, C.B. Winn, L. Flowers et H.J. Green. *Optimal Control of Remote Hybrid Power Systems. Part 1: Simplified Model*. Rapport technique, National Renewable Energy Laboratory, 1995. (Cité en pages 8, 43 et 46.)
- [Ben-Tal 2009] Aharon Ben-Tal, Laurent El Ghaoui et Arkadi Nemirovski. *Robust optimization*. Princeton University Press, 2009. (Cité en page 31.)
- [Bertsimas 1997] Dimitris Bertsimas et John N. Tsitsiklis. *Introduction to linear optimization*. John Wiley & Sons, Inc, 1997. (Cité en page 16.)
- [Bertsimas 2011] Dimitris Bertsimas, David B. Brown et Constantine Caramanis. *Theory and applications of Robust Optimization*. SIAM Rev, vol. 53, no. 3, pages 464–501, 2011. (Cité en page 31.)
- [Bidram 2014] A. Bidram, A. Davoudi, F. L. Lewis et S. S. Ge. *Distributed Adaptive Voltage Control of Inverter-Based Microgrids*. IEEE Transactions on Energy Conversion, vol. 39, no. 4, pages 862–872, 2014. (Cité en page 8.)
- [Birge 2011] John R. Birge et François Louveaux. *Introduction to stochastic programming*. Springer Science+Business Media, 2011. (Cité en pages 28 et 29.)
- [Bordin 2017] Chiara Bordin, Harold Oghenetejiri Anuta, Andrew Crossland, Isabel Lascurain Gutierrez, Chris J. Dent et Daniele Vigo. *A linear programming approach for battery degradation analysis and optimization in offgrid power*

- systems with solar energy integration.* Renewable Energy, vol. 101, pages 417–430, 2017. (Cité en page 43.)
- [Bourbon 2019] R. Bourbon, S.U. Ngueveu, X. Roboam, B. Sareni, C.Turpin et D. Hernandez-Torres. *Energy management optimization of a smart wind power plant comparing heuristic and linear programming methods.* Mathematics and Computers in Simulation, vol. 158, pages 418–431, 2019. (Cité en page 38.)
- [Boyd 2004] Stephen Boyd et Lieven Vandenberghe. Convex optimization. Cambridge University Press, 2004. (Cité en page 16.)
- [Bretthauer 1992] G. Bretthauer, E. Handschin et W. Hoffmann. *Expert Systems Application to Power Systems - State-of-the-Art and Future Trends.* IEEE Transactions on Power Delivery, vol. 25, no. 1, pages 463–468, 1992. (Cité en page xix.)
- [Bridier 2015] Laurent Bridier. *Modélisation et optimisation d'un système de stockage couplé à une production électrique renouvelable intermittente.* PhD thesis, Université de la Réunion, 2015. (Cité en page 67.)
- [Carbone 2011] Rosario Carbone. Energy storage in the emerging era of smart grids. InTech, 2011. (Cité en pages 2 et 3.)
- [Chen 2016] Haoyong Chen, Honwing Ngan et Yongjun Zhang. Power system optimization - large-scale complex systems approaches. John Wiley & Sons Singapore Pte. Ltd, 2016. (Cité en page 11.)
- [Chen 2018] Y. Chen et M. Trifkovic. *Optimal scheduling of a microgrid in a volatile electricity market environment: Portfolio optimization approach.* Applied Energy, vol. 226, pages 703–712, 2018. (Cité en page 41.)
- [Chong 2013] Edwin K. P. Chong et Stanislaw H. Zak. An introduction optimization. John Wiley & Sons, Inc., Hoboken, New Jersey, 2013. (Cité en pages 16, 23, 24 et 25.)
- [Commission 2019] Australian Energy Market Commission. *National Electricity Rules - Version 124.* Rapport technique, Australian Energy Market Commission, 2019. (Cité en page xviii.)
- [Dantzig 1997] George B. Dantzig et Mukund N. Thapa. Linear programming - 1. introduction. Springer-Verlag New York, LLC, 1997. (Cité en page 16.)
- [Dantzig 2003] George B. Dantzig et Mukund N. Thapa. Linear programming - 2. theory and extensions. Springer-Verlag New York, 2003. (Cité en page 16.)
- [Das 2018] Avijit Das et Zhen Ni. *A Computationally Efficient Optimization Approach for Battery Systems in Islanded Microgrid.* IEEE Transactions on Smart Grids, vol. 9, no. 6, pages 6489–6499, 2018. (Cité en pages 39 et 43.)

- [Dasgupta 1997] Dipankar Dasgupta et Zbigniew Michalewicz. Evolutionary algorithms in engineering applications. Springer-Verlag Berlin Heidelberg, 1997. (Cité en page 16.)
- [de Régulation de l'Energie (CRE France) 2015] Commission de Régulation de l'Energie (CRE France). *Appel d'offres portant sur la réalisation et l'exploitation d'installations de production d'électricité à partir de techniques de conversion du rayonnement solaire d'une puissance supérieure à 100 kWc et situées dans les zones non interconnectées*, 2015. [Online; accessed 22-December-2018]. (Cité en page 13.)
- [Delille 2012] Gauthier Delille, Bruno François et Gilles Malarange. *Dynamic Frequency Control Support by Energy Storage to Reduce the Impact of Wind and Solar Generation on Isolated Power System's Inertia*. IEEE Transactions on Sustainable Energy, vol. 3, no. 4, 2012. (Cité en page 3.)
- [DOE/EPRI 2013] DOE/EPRI et NRECA. *Electricity Storage Handbook*. Rapport technique, Sandia National Laboratories, 2013. (Cité en page 3.)
- [Dréo 2006] J. Dréo, A. Pétrowski, P. Siarry et E. Taillard. Metaheuristics for hard optimization - methods and case studies. Springer-Verlag Berlin Heidelberg, 2006. (Cité en pages 16 et 22.)
- [El-Hendawi 2018] Mohamed El-Hendawi, Hossam A. Gabbar, Gaber El-Saady et El-Nobi A. Ibrahim. *Control and EMS of a Grid-Connected Microgrid with Economical Analysis*. Energies, vol. 11, no. 1, pages 140–149, 2018. (Cité en page 40.)
- [Enns 1994] M. Enns, L. Budler, T.W. Cease, A. Elnewehi, E. Guro, M. Kezunovic, J. Linders, P. Leblanc, J. Postforoosh, R. Ramaswami, F. Soudi, R. Taylor, H. Ungrad, S.S. Venkata et J. Zipp. *Potential Applications of Expert Systems to Power System Protection*. IEEE Transactions on Power Delivery, vol. 9, no. 2, pages 720–728, 1994. (Cité en page xix.)
- [Fletcher 2000] R. Fletcher. Practical methods of optimization. John Wiley & Sons, Inc, 2000. (Cité en page 16.)
- [Floudas 1995] Christodoulos A. Floudas. Nonlinear and mixed-integer optimization - fundamentals and applications. Oxford University Press, 1995. (Cité en page 16.)
- [Gelleschus 2018] Ronny Gelleschus, Michael Böttiger, Peter Stange et Thilo Bocklischa. *Comparison of Optimization Solvers in the Model Predictive Control of a PV-Battery-Heat Pump System*. 12th International Renewable Energy Storage Conference, IRES 2018, Energy Procedia, vol. 155, pages 524–535, 2018. (Cité en pages 37 et 38.)
- [Gill 1981] Philip E. Gill, Walter Murray et Margaret H. Wright. Practical optimization. Academic Press, 1981. (Cité en page 16.)

- [Guo 2015] F. Guo, C. Wen, J. Mao et Y. Song. *Distributed Secondary Voltage and Frequency Restoration Control of Droop-Controlled Inverter-Based Microgrids*. IEEE Transactions on Industrial Electronics, vol. 62, no. 7, pages 4355–4364, 2015. (Cité en page 8.)
- [Gupta 2011] Ajai Gupta, R.P. Saini et M.P. Sharma. *Modelling of hybrid energy systemd - Part II: Combined dispatch strategies and solution algorithm*. Renewable Energy, vol. 36, pages 466–473, 2011. (Cité en page 43.)
- [Haessig 2014] Pierre Haessig. *Dimensionnement et gestion d'un stockage d'énergie pour l'atténuation des incertitudes de production éolienne*. PhD thesis, ENS Cachan, 2014. (Cité en pages 41 et 67.)
- [Handschin 1991] Edmund Handschin et Alexander Petroianu. Energy management systems: Operation and control of electric energy transmission systems. Springer-Verlag Berlin, Heidelberg, 1991. (Cité en pages xvii et xviii.)
- [Hazel 2000] Terence Hazel. *Cahier technique 196 - Génération électrique intégrée aux sites industriels et batiments commerciaux*. Rapport technique, Schneider Electric, 2000. (Cité en page 7.)
- [Holmgren 2018] William F. Holmgren, Clifford W. Hansen et Mark A. Mikofskoi. *pvlib python: a python package for modeling solar energy systems*. Journal of Open Source Software, vol. 3, no. 29, page 884, 2018. (Cité en page 59.)
- [Ibrahim 2002] Wael R. Anis Ibrahim et Medhat M. Morcos. *Artificial Intelligence and Advanced Mathematical Tools for Power Quality Applications: A Survey*. IEEE Transactions on Power Delivery, vol. 17, no. 2, pages 668–673, 2002. (Cité en page xix.)
- [IEA 2019] IEA. *Status of Power System Transformation 2019*. Rapport technique, International Energy Agency, Paris, 2019. (Cité en page xx.)
- [IRENA 2017] IRENA. *Electricity Storage and Renewables: Costs and Markets to 2030*. Rapport technique, International Renewable Energy Agency, Abu Dhabi, 2017. (Cité en page xix.)
- [Jong 1997] Kenneth De Jong, Lawrence Fogel et Hans-Paul Schwefel. Handbook of evolutionary computation. IOP Publishing Ltd, 1997. (Cité en page 16.)
- [Kanwar 2015] Aastha Kanwar, Diego I. Hidalgo Rodriguez, Jan von Appen et Martin Braun. *A Comparative Study of Optimization- and Rule-Based Control for Microgrid Operation*. In Power and Energy Student Summit (PESS) 2015, 2015. (Cité en page 7.)
- [Karthik 2018] N. Karthik, A. K. Parvathy et R. Arul. *Optimal Operation of Microgrids - A Survey*. International Journal of Applied Power Engineering (IJAPE), vol. 7, no. 2, pages 179–185, 2018. (Cité en page 35.)
- [Komor 2012] Paul Komor et John Glassmire. *Electricity Storage and Renewables for Island Power: A Guide for Decision Makers*. Rapport technique, International Renewable Energy Agency (IRENA), 2012. (Cité en page 7.)

- [Krewer 2018] Ulrike Krewer, Fridolin Röder, Eranda Harinath, Richard D. Braatz, Benjamin Bedürftig et Rolf Findeisen. *Review-Dynamic Models of Li-Ion Batteries for Diagnosis and Operation: A Review and Perspective*. Journal of The Electrochemical Society, vol. 165, no. 16, pages A3656–A3673, 2018. (Cité en page 5.)
- [Kueck 2004] John D. Kueck, Brendan J. Kirby, Philip N. Overholt et Lawrence C. Markel. *Measurement Practices For Reliability And Power Quality: A Toolkit Of Reliability Measurement Practices*. Rapport technique, Oak Ridge National Laboratory, 2004. (Cité en page xviii.)
- [Kusakana 2015] Kanzumba Kusakana. *Operation cost minimization of photovoltaic-diesel-battery hybrid systems*. Energy, vol. 85, pages 645–653, 2015. (Cité en pages 8 et 43.)
- [Lakkis 2015] M. El Lakkis, O. Sename, M.Corno et D. Bresch Pietri. *Combined battery SOC/SOH estimation using a nonlinear adaptive observer*. 2015 European Control Conference (ECC), 2015. (Cité en page 6.)
- [Lee 2012] Jon Lee et Sven Leyffer. Mixed integer nonlinear programming. Springer Science+Business Media, LLC, 2012. (Cité en page 16.)
- [Lin 2018] Da Zhen Lin, Li Huang, Xiangjin Wang, Zhihao Li et Leiqi Zhang. *Robust Economic Dispatch of Grid-connected AC/DC Hybrid Microgrids*. 2018 2nd IEEE Conference on Energy Internet and Energy System Integration (EI2), pages 1–5, 2018. (Cité en page 83.)
- [Liu 2010] Hongrui Liu, Zelda B. Zabinsky et Wolf Kohn. *Rule-based Control System Design for Smart Grids*. IEEE PES General Meeting, 2010. (Cité en page xix.)
- [Liu 2015] Yixin Liu, Li Guo et Chengshan Wang. *A robust operation-based scheduling optimization for smart distribution networks with multi-microgrids*. Applied Energy, vol. 228, pages 130–140, 2015. (Cité en page 83.)
- [Luenberger 2015] David G. Luenberger et Yinyu Ye. Linear and nonlinear programming. Springer International Publishing Switzerland, 2015. (Cité en page 16.)
- [Madani 2015] Mehdi Madani et Mathieu Van Vyve. *Computationally efficient MIP formulation and algorithms for European day-ahead electricity market auctions*. European Journal of Operational Research, vol. 242, pages 580–593, 2015. (Cité en page 39.)
- [Mahesh 2015] Aeidapu Mahesh et Kanwarjit Singh Sandhu. *Hybrid wind/photovoltaic energy system developments: Critical review and findings*. Renewable and Sustainable Energy Reviews, vol. 52, pages 1135–1147, 2015. (Cité en page 43.)

- [Malysz 2013] Paweł Malysz, Shahin Sorouspour et Ali Emadi. *MILP-based Rolling Horizon Control for Microgrids with Battery Storage*. IECON 2013 - 39th Annual Conference of the IEEE Industrial Electronics Society, pages 2099–2104, 2013. (Cité en page 40.)
- [Manwell 1993] James F. Manwell et Jon G. McGowan. *Lead Acid Battery Storage Model for Hybrid Energy Systems*. Solar Energy, vol. 50, no. 5, pages 399–405, 1993. (Cité en page 4.)
- [Martin 1999] Richard Kipp Martin. Large scale linear and integer optimization - unified approach. Springer Science+Business Media, LLC, 1999. (Cité en page 16.)
- [Medjoudj 2017] Rabah Medjoudj, Hassiba Bediaf et Djamil Aissani. *Power System Reliability: Mathematical Models and Applications*. In Constantin Volosencu, éditeur, System Reliability, chapitre 15. IntechOpen, Rijeka, 2017. (Cité en page xviii.)
- [Meena 2019] Nand K. Meena, Jin Yang et Evan Zacharis. *Optimisation framework for the design and operation of open-market urban and remote community microgrids*. Applied Energy, vol. 252, 2019. (Cité en page 41.)
- [Michalewicz 1990] Z. Michalewicz, J.B. Krawczyk, M. Kazemi et C.Z. Janikow. *Genetic Algorithms and Optimal Control Problems*. 29th IEEE Conference on Decision and Control, 1990. (Cité en page 37.)
- [Michalewicz 1994] Zbigniew Michalewicz. Genetic algorithms + data structures evolution programs. Springer-Verlag Berlin Heidelberg GmbH, 1994. (Cité en pages 16, 24 et 25.)
- [Minchala-Avilaa 2015] Luis I. Minchala-Avilaa, Luis E. Garza-Castanón, Adriana Vargas-Martínez et Youmin Zhang. *A review of optimal control techniques applied to the energy management and control of microgrids*. Procedia Computer Science, vol. 52, pages 787–787, 2015. (Cité en pages 1, 17 et 35.)
- [Mohammadi 2012] M. Mohammadi, S.H. Hosseinian et G.B. Gharehpetian. *Optimization of hybrid solar energy sources/wind turbine systems integrated to utility grids as microgrid (MG) under pool/bilateral/hybrid electricity market using PSO*. Solar Energy, vol. 86, no. 1, pages 112–125, 2012. (Cité en page 41.)
- [Morales 2014] Juan M. Morales, Antonio J. Conejo, Henrik Madsen, Pierre Pinson et Marco Zugno. Integrating renewables in electricity markets - operational problems. Springer Science+Business Media New York, 2014. (Cité en pages 13, 28, 29, 31 et 32.)
- [Murnane 2017] Martin Murnane et Adel Ghaze. *A Closer Look at State of Charge (SOC) and State of Health (SOH) Estimation Techniques for Batteries*. Rapport technique, Analog Devices, Inc, 2017. (Cité en page 5.)

- [Muselli 1999] M. Muselli, G. Notton et A. Louche. *Design of Hybrid-Photovoltaic Power Generator, with Optimization of Energy Management*. International Journal of Renewable Energy Research (IJRER), vol. 65, no. 3, pages 143–157, 1999. (Cité en page 43.)
- [Natesan 2015] Chitra Natesan, SenthilKumar Ajithan, Swathi Chozhavendhan et Anitha Devendhiran. *Power Management Strategies in Microgrid: A Survey*. International Journal of Renewable Energy Research, vol. 15, no. 2, pages 334–340, 2015. (Cité en page 35.)
- [Nemati 2018] Mohsen Nemati, Martin Braun et Stefan Tenbohlen. *Optimization of unit commitment and economic dispatch in microgrids based on genetic algorithm and mixed integer linear programming*. Applied Energy, vol. 210, pages 944–963, 2018. (Cité en pages 8 et 37.)
- [Nunez 2013] Alfredo Nunez, Doris Saez et Cristian E. Cortés. Hybrid predictive control for dynamic transport problems. Springer-Verlag London, 2013. (Cité en page xx.)
- [on Public Affairs 2010] APS Panel on Public Affairs. *Integrating Renewable Electricity on the Grid*. Rapport technique, American Physical Society, 2010. (Cité en page xx.)
- [Palma-Behnke 2013] Rodrigo Palma-Behnke, Carlos Benavides, Fernando Lanas, Bernardo Severino, Lorenzo Reyes, Jacqueline Llanos et Doris Sáez. *A Microgrid Energy Management System Based on the Rolling Horizon Strategy*. IEEE Transactions on Smart Grids, vol. 4, no. 2, pages 996–1006, 2013. (Cité en pages 5, 40 et 41.)
- [Pan 2014] Ping-Qi Pan. Linear programming computation. Springer-Verlag Berlin Heidelberg, 2014. (Cité en page 16.)
- [Peter 1998] Jackson Peter. Introduction to expert systems. Addison Wesley, 1998. (Cité en page xix.)
- [Petroleum 2019] British Petroleum. *BP Statistical Review of World Energy 2019*. Rapport technique, British Petroleum (BP), 2019. (Cité en page xi.)
- [Pflaum 2017] Peter Pflaum, M. Alamir et M.Y. Lamoudi. *Battery sizing for PV power plants under regulations using randomized algorithms*. Renewable Energy, vol. 113, pages 596–607, 2017. (Cité en pages 41 et 67.)
- [Piao 2015] Hongyan Piao, Shifeng Chen, Haichao Lv et Haoming Liu. *Control strategy of battery energy storage system to participate in the second frequency regulation*. 2015 International Symposium on Smart Electric Distribution Systems and Technologies (EDST), 2015. (Cité en page 3.)
- [POIRION 2013] Pierre-Louis POIRION. *Programmation linéaire mixte robuste ; Application au dimensionnement d'un système hybride de production d'électricité*. PhD thesis, Conservatoire national des arts et métiers (CNAM), 2013. (Cité en page 78.)

- [Pop 2008] Valer Pop, Henk Jan Bergveld, Dmitry Danilov, Paul P.L. Regtien et Peter H.L. Notten. Battery management systems - accurate state-of-charge indication for battery-powered applications. Springer Science+Business Media B.V., 2008. (Cité en pages 4, 5 et 6.)
- [Pourbehzadi 2019] Motahareh Pourbehzadi, Taher Niknam, Jamshid Aghaei, Geev Mokryani, Miadreza Shafe-khah et Joao P.S. Catalao. *Optimal operation of hybrid AC/DC microgrids under uncertainty of renewable energy resources: A comprehensive review*. Electrical Power and Energy Systems, vol. 109, pages 139–159, 2019. (Cité en page 35.)
- [Powell 2016] Warren B. Powell et Stephan Meisel. *Tutorial on Stochastic Optimization in Energy-Part I: Modeling and Policies*. IEEE Transactions on Power Systems, vol. 31, pages 1459–1467, 2016. (Cité en page xx.)
- [Ravindran 2006] A. Ravindran, K. M. Ragsdell et G. V. Reklaitis. Engineering optimization - methods and applications. John Wiley & Sons, Inc., Hoboken, New Jersey, 2006. (Cité en page 16.)
- [Rong 2006] Peng Rong et Massoud Pedram. *An Analytical Model for Predicting the Remaining Battery Capacity of Lithium-Ion Batteries*. IEEE Transactions on Very Large Scale Integration (VLSI) Systems, vol. 14, no. 5, pages 441–451, 2006. (Cité en page 5.)
- [Sahyoun 2015] S. Sahyoun, S.M. Djouadi et M. Shankar. *Optimal Control of Droop Controlled Inverters in Islanded Microgrids*. IFAC-PapersOnLine, vol. 48, no. 30, pages 363–368, 2015. (Cité en page 8.)
- [Sechilariu 2014] Manuela Sechilariu, Bao Chao Wang et Fabrice Locment. *Supervision control for optimal energy cost management in DC microgrid: Design and simulation*. Electrical Power and Energy Systems, vol. 58, pages 140–149, 2014. (Cité en page 40.)
- [Sechilariu 2016] Manuela Sechilariu et Fabrice Locment. Urban dc microgrid: Intelligent control and power flow optimization. Butterworth-Heinemann, 2016. (Cité en pages 7 et 8.)
- [Seeling-Hochmuth 1998] Gabriele Seeling-Hochmuth. *Optimisation of hybrid energy systems sizing and operation control*. PhD thesis, University of Kassel, 1998. (Cité en pages 9 et 43.)
- [Shahidehpour 2002] Mohammad Shahidehpour, Hatim Yamin et Zuyi Li. Market operations in electric power systems - forecasting, scheduling, and risk management. John Wiley & Sons Singapore Pte. Ltd, 2002. (Cité en pages 11 et 12.)
- [Sichilalu 2015] Sam M. Sichilalu et Xiaohua Xia. *Optimal energy control of grid tied PV-diesel-battery hybrid system powering heat pump water heater*. Solar Energy, vol. 115, pages 243–254, 2015. (Cité en pages 8 et 43.)

- [Silvente 2018] Javier Silvente, Georgios M. Kopanos, Vivek Dua et Lazaros G. Papageorgiou. *A rolling horizon approach for optimal management of microgrids under stochastic uncertainty*. Chemical Engineering Research and Design, vol. 131, pages 293–317, 2018. (Cité en pages 40 et 69.)
- [Suchetha 2018] C. Suchetha et J. Ramprabhakar. *Optimization Techniques for Operation and Control of Microgrids - Review*. Journal of Green Engineering, vol. 84, 2018. (Cité en page 37.)
- [Taşcıkaraoglu 2019] Akin Taşcıkaraoglu et Ozan Erdinç. Pathways to a smarter power system. Academic Press, 2019. (Cité en page 7.)
- [Tazvinga 2015] Henerica Tazvinga. *Energy Optimization and Management of Off-grid Hybrid Power Supply Systems*. PhD thesis, University of Pretoria, 2015. (Cité en pages 8, 9 et 43.)
- [Twahaa 2018] Ssennoga Twahaa et Makbul A.M. Ramlib. *A review of optimization approaches for hybrid distributed energy generation systems: Off-grid and grid-connected systems*. Sustainable Cities and Society, vol. 41, pages 320–331, 2018. (Cité en pages 17 et 35.)
- [Vanderbei 2014] Robert J. Vanderbei. Linear programming - foundations and extensions. Springer Science+Business Media New York, 2014. (Cité en page 16.)
- [Viana 2013] Ana Viana et Joao Pedro Pedroso. *A new MILP-based approach for Unit Commitment in power production planning*. International Journal of Electrical Power & Energy Systems, vol. 44, pages 997–1005, 2013. (Cité en pages 8, 39, 43 et 45.)
- [Wang 2015] Ran Wang, Ping Wang et Gaoxi Xiao. *A robust optimization approach for energy generation scheduling in microgrids*. Energy Conversion and Management, vol. 106, pages 597–607, 2015. (Cité en page 83.)
- [Wong 1993] K.P. Wong. *Applications of Artificial Intelligence and Expert Systems in Power Engineering*. In S. Tzafestas, éditeur, Expert Systems in Engineering Applications, chapitre 7. Springer, Berlin, Heidelberg, 1993. (Cité en page xix.)
- [Woon 2008] Siew Fang Woon, Volker Rehbock et Ahmad Agus Setiawan. *Modeling A PV-Diesel-Battery Power System: An Optimal Control Approach*. In World Congress on Engineering and Computer Science, 2008. (Cité en pages 4, 5, 7, 8, 10 et 43.)
- [Zeng 2013] Bo Zeng et Long Zhao. *Solving two-stage robust optimization problems using a column-and-constraint generation method*. Operations Research Letters, vol. 41, pages 457–461, 2013. (Cité en page 78.)

Index

- Contrôleur, 35, 36, 40
- EMS, 43, 47, 48, 53, 67, 69–72, 75
- EMS robuste, 75
- GAMS, 37
- Gurobi, 96
- HOMER, 8
- logiciels connexes
- Contrôleur, 35, 36, 40
 - EMS, 43, 47, 48, 53, 67, 69–72, 75
 - EMS robuste, 75
 - GAMS, 37
 - Gurobi, 96
 - HOMER, 8
 - MATLAB, 96
 - MATLAB/Simulink, 48
 - MiniBatchKMeans, 83
 - Plant, XXII, XXIII, 36, 39, 40, 48, 49, 51, 59–61, 65, 66, 79
 - PMS, XXII, XXIII, 48, 49, 51, 54, 59, 60, 66, 79, 80
 - Predictor, XXIII, 69, 71, 73, 75, 79, 80, 89, 92
 - PVLIB, 59
 - Python, 83, 96
- Scikit-learn, 83
- Simulateur, 36, 40
- Simulink, 96
- Tracker, XXII, XXIII, 47–51, 54, 59–61, 63–67, 69–71, 73, 75, 79, 80, 86–89
- MATLAB, 96
- MATLAB/Simulink, 48
- MiniBatchKMeans, 83

Table des matières

Introduction	xv
1 Généralités sur les microgrids	1
1.1 Principaux composants d'un microgrid	1
1.1.1 Systèmes photovoltaïques	2
1.1.2 Batteries de stockage	2
1.1.3 Générateurs diesel	7
1.1.4 Convertisseurs électroniques et auxiliaires	8
1.2 Topologies des microgrids	8
1.3 Fonctionnement des marchés de l'électricité et du paradigme de l'AOCRE ZNI	11
1.3.1 Généralités sur les marchés et les marchés de l'électricité	11
1.3.2 Les modèles de marché de l'électricité	12
1.3.3 L'AOCRE ZNI	13
2 Littérature sur l'optimisation	15
2.1 Classification des méthodes d'optimisation	15
2.2 La programmation mathématique	17
2.2.1 Programmation linéaire et programmation quadratique convexe	17
2.2.2 Programmation linéaire en nombres entiers	19
2.3 Les métaheuristiques	21
2.3.1 Les métaheuristiques	21
2.3.2 Les algorithmes génétiques	22
2.4 L'optimisation sous incertitudes	26
2.4.1 La programmation stochastique	27
2.4.2 L'approche robuste	29
2.4.3 De la nécessité de la gestion des incertitudes	31
3 Problématique	35
3.1 Cadre général de contrôle	35
3.2 Optimisation du contrôle	36
3.2.1 Comparaison de 3 approches d'optimisation du contrôle	36
3.2.2 Garantie d'optimalité	38
3.3 Applicabilité des commandes optimales	39
3.4 Contexte AOCRE et calcul d'engagement	40
3.5 Incertitudes des données de prévision solaire	41

4 Contrôle optimal des microgrids off-grid	43
4.1 Modélisation mathématique du problème	43
4.1.1 Les contraintes	44
4.1.2 La fonction objectif	46
4.1.3 Le modèle complet	46
4.2 Résolution, résultats et discussion	47
4.2.1 Cadre de simulation	48
4.2.2 Résultats et discussion	49
4.3 Conclusion	51
5 Contrôle optimal des microgrids connectés réseau	53
5.1 Contexte	53
5.2 Modélisation mathématique du problème	54
5.2.1 Les contraintes	54
5.2.2 La fonction objectif	55
5.2.3 Modèles complets	58
5.3 Résolution, résultats et discussion	59
5.3.1 Évaluation des erreurs de modélisation du programme mathématique	59
5.3.2 Comparaison des techniques d'optimisation	65
5.4 Conclusion	66
6 Modèle d'engagement	67
6.1 Contexte	67
6.2 Le modèle	68
6.3 Résolution, résultats et discussion	68
6.3.1 Cadre de simulation	69
6.3.2 Comparaison programmation mathématique vs algorithme génétique vs système expert	69
6.4 Conclusion	73
7 Gestion des incertitudes	75
7.1 Le modèle stochastique	75
7.2 Le modèle robuste	77
7.2.1 Présentation du problème	77
7.2.2 La décomposition de Benders	78
7.3 Résolution du problème d'optimisation robuste	78
7.4 Résolution, résultats et discussion	79
7.4.1 Génération des scénarios et calcul des paramètres du programme robuste	81
7.4.2 Calcul du profit réel	83
7.4.3 Calcul de la VSS	89
7.4.4 Calcul de l'EVPI	89
7.4.5 Performance des stratégies sous incertitudes	89
7.5 Conclusion	92

Table des matières	115
Conclusion	93
A Exemple d'annexe	99
A.1 Exemple d'annexe	99
Bibliographie	101
Index	111